#### CPA - Computación Paralela

Grado en Ingeniería Informática

### S3. Programación con MPI

J. M. Alonso, P. Alonso, F. Alvarruiz, I. Blanquer, D. Guerrero, J. Ibáñez, E. Ramos, J. E. Román

Departament de Sistemes Informàtics i Computació Universitat Politècnica de València

Curso 2021/22





1

### Contenido

- 1 Conceptos Básicos
  - Modelo de Paso de Mensajes
  - El Estándar MPI
  - Modelo de Programación MPI
- 2 Comunicación Punto a Punto
  - Semántica
  - Primitivas Bloqueantes
  - Otras Primitivas
  - Ejemplos
- 3 Comunicación Colectiva
  - Sincronización
  - Difusión
  - Reparto
  - Reducción
- 4 Otras Funcionalidades
  - Tipos de Datos Derivados

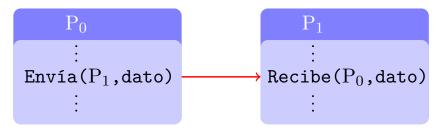
#### Apartado 1

# Conceptos Básicos

- Modelo de Paso de Mensajes
- El Estándar MPI
- Modelo de Programación MPI

### Modelo de Paso de Mensajes

Intercambio de información mediante envío y recepción explícitos de mensajes



Modelo más usado en computación a gran escala – Bibliotecas de funciones (aprendizaje más fácil que un lenguaje nuevo)

#### Ventajas:

- Universalidad
- Fácil comprensión
- Gran expresividad
- Mayor eficiencia

#### Inconvenientes:

- Programación compleja
- Control total de las comunicaciones

Ľ

#### El Estándar MPI

MPI es una especificación propuesta por un comité de investigadores, usuarios y empresas

https://www.mpi-forum.org

#### **Especificaciones**:

- MPI-1.0 (1994), última actualización MPI-1.3 (2008)
- MPI-2.0 (1997), última actualización MPI-2.2 (2009)
- MPI-3.0 (2012), última actualización MPI-3.1 (2015)
- MPI-4.0 (2020), última actualización MPI-4.1 (2021)

#### Antecedentes:

- Cada fabricante ofrecía su propio entorno (migración costosa)
- PVM (*Parallel Virtual Machine*) fue un primer intento de estandarización

#### Características de MPI

#### Características principales:

- Es portable a cualquier plataforma paralela
- Es simple (con tan sólo 6 funciones se puede implementar cualquier programa)
- Es potente (más de 300 funciones)

El estándar especifica interfaz para C y Fortran

Hay muchas implementaciones disponibles:

- Propietarias: IBM, Cray, SGI, ...
- MPICH (www.mpich.org)
- Open MPI (www.open-mpi.org)
- MVAPICH (mvapich.cse.ohio-state.edu)

### Modelo de Programación

La programación en MPI se basa en funciones de biblioteca Para su uso, se requiere una inicialización

#### Ejemplo

- Es obligatorio llamar a MPI\_Init y MPI\_Finalize
- Una vez inicializado, se pueden realizar diferentes operaciones

### Modelo de Programación - Operaciones

Las operaciones se pueden agrupar en:

- Comunicación punto a punto
   Intercambio de información entre pares de procesos
- Comunicación colectiva
   Intercambio de información entre conjuntos de procesos
- Gestión de datos

Tipos de datos derivados (p.e. datos no contiguos en memoria)

- Operaciones de alto nivel
   Grupos, comunicadores, atributos, topologías
- Operaciones avanzadas (MPI-2, MPI-3)
   Entrada-salida, creación de procesos, comunicación unilateral
- Utilidades
   Interacción con el entorno del sistema

La mayoría operan sobre comunicadores

## Modelo de Programación – Comunicadores

Un comunicador es una abstracción que engloba los siguientes conceptos:

- *Grupo*: conjunto de procesos
- Contexto: para evitar interferencias entre mensajes distintos

Un comunicador agrupa a p procesos

```
int MPI_Comm_size(MPI_Comm comm, int *size)
```

Cada proceso tiene un identificador (rango), un número entre 0 y p-1

```
int MPI_Comm_rank(MPI_Comm comm, int *rank)
```

### Modelo de Ejecución

El modelo de ejecución de MPI sigue un esquema de creación simultánea de procesos al lanzar la aplicación

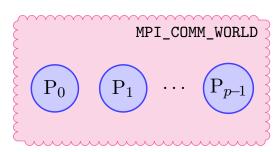
La ejecución de una aplicación suele hacerse con

```
\verb"mpiexec -n" p" programa [argumentos]"
```

Al ejecutar una aplicación:

- lacksquare Se lanzan p copias del mismo ejecutable
- Se crea un comunicador MPI\_COMM\_WORLD que engloba a todos los procesos

MPI-2 ofrece un mecanismo para crear nuevos procesos



ģ

#### Apartado 2

# Comunicación Punto a Punto

- Semántica
- Primitivas Bloqueantes
- Otras Primitivas
- Ejemplos

### Comunicación Punto a Punto – el Mensaje

Los mensajes deben ser enviados explícitamente por el emisor y recibidos explícitamente por el receptor

Envío estándar:

```
MPI_Send(buf, count, datatype, dest, tag, comm)
```

Recepción estándar:

```
MPI_Recv(buf, count, datatype, src, tag, comm, stat)
```

El contenido del mensaje viene definido por los 3 primeros argumentos:

- Un buffer de memoria donde está almacenada la información
- El número de elementos que componen el mensaje
- El tipo de datos de los elementos (p.e. MPI\_INT)

#### Comunicación Punto a Punto – el Sobre

Para efectuar la comunicación, es necesario indicar el destino (dest) y el origen (src)

- La comunicación está permitida sólo dentro del mismo comunicador, comm
- El origen y el destino se indican mediante identificadores de procesos
- En la recepción se permite utilizar src=MPI\_ANY\_SOURCE

Se puede utilizar un número entero (etiqueta o tag) para distinguir mensajes de distinto tipo

■ En la recepción se permite utilizar tag=MPI\_ANY\_TAG

En la recepción, el estado (stat) contiene información:

- Proceso emisor (stat.MPI\_SOURCE), etiqueta (stat.MPI\_TAG)
- Longitud del mensaje (explicado en p. 43)

Nota: pasar MPI\_STATUS\_IGNORE si no se requiere

Modos de Envío Punto a Punto

Existen los siguientes modos de envío:

- Modo de envío síncrono
- Modo de envío con memoria intermedia (buffer)
- Modo de envío estándar

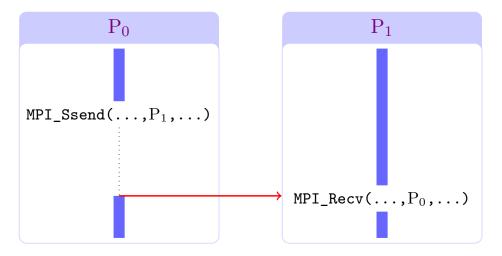
El modo estándar es el más utilizado

El resto de modos pueden ser útiles para obtener mejores prestaciones o mayor robustez

Para cada modo, existen primitivas bloqueantes y no bloqueantes

### Modo de Envío Síncrono

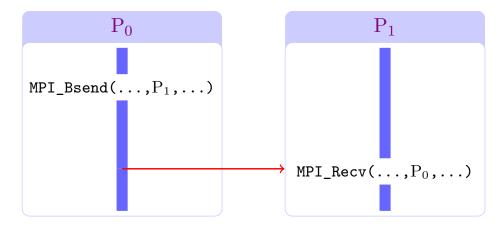
Implementa el modelo de envío con "rendezvous": el emisor se bloquea hasta que el receptor desea recibir el mensaje



■ Ineficiente: el emisor queda bloqueado sin hacer nada útil

#### Modo de Envío con Buffer

El mensaje se copia a una memoria intermedia y el proceso emisor continúa su ejecución



- Inconvenientes: copia adicional y posibilidad de fallo
- Se puede proporcionar un buffer (MPI\_Buffer\_attach)

#### Modo de Envío Estándar

```
MPI_Send(buf, count, datatype, dest, tag, comm)
```

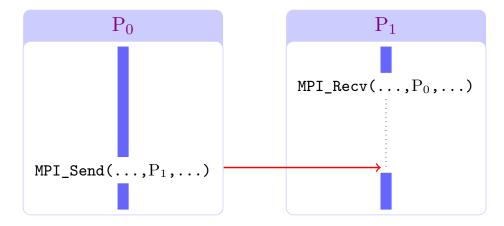
Garantiza el funcionamiento en todo tipo de sistemas ya que evita problemas de almacenamiento

- Los mensajes cortos son enviados generalmente con MPI\_Bsend
- Los mensajes largos son enviados generalmente con MPI\_Ssend

### Recepción Estándar

```
MPI_Recv(buf, count, datatype, src, tag, comm, stat)
```

Implementa el modelo de recepción con "rendezvous": el receptor se bloquea hasta que el mensaje llega



Ineficiente: el proceso receptor queda bloqueado sin hacer nada útil

### Primitivas de Envío No Bloqueantes

```
MPI_Isend(buf, count, datatype, dest, tag, comm, req)
```

Se inicia el envío, pero el emisor no se bloquea

- Tiene un argumento adicional (req)
- Para reutilizar el buffer es necesario asegurarse de que el envío se ha completado

#### Ejemplo

```
MPI_Isend(A, n, MPI_DOUBLE, dest, tag, comm, &req);
...
/* Comprobar que el envío ha terminado,
   con MPI_Test o MPI_Wait */
A[10] = 2.6;
```

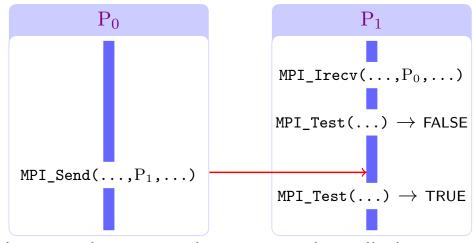
- Solapamiento de comunicación y cálculo sin copia extra
- Inconveniente: programación más difícil

### Recepción No Bloqueante

```
MPI_Irecv(buf, count, type, src, tag, comm, req)
```

Se inicia la recepción, pero el receptor no se bloquea

- Se sustituye el argumento stat por req
- Es necesario comprobar después si el mensaje ha llegado



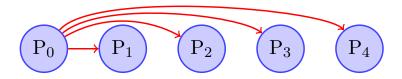
- Ventaja: solapamiento de comunicación y cálculo
- Inconveniente: programación más difícil

### Operaciones Combinadas

Realiza una operación de envío y recepción al mismo tiempo (no necesariamente con el mismo proceso)

Realiza una operación de envío y recepción al mismo tiempo sobre la misma variable

Ejemplo – Difusión



#### Difusión de un valor numérico desde $P_0$

```
double val;
MPI_Status status;
int p, rank, i;

MPI_Comm_size(MPI_COMM_WORLD, &p);
MPI_Comm_rank(MPI_COMM_WORLD, &rank);
if (rank == 0) {
  read_value(&val);    /* valor a difundir */
  for (i=1; i<p; i++)
     MPI_Send(&val,1,MPI_DOUBLE,i,0,MPI_COMM_WORLD);
} else {
  MPI_Recv(&val,1,MPI_DOUBLE,0,0,MPI_COMM_WORLD,&status);
}</pre>
```

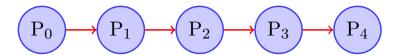
## Ejemplo – Desplazamiento en Malla 1-D (1)

Cada proceso ha de enviar su dato al vecino derecho y sustituirlo por el dato que recibe del vecino izquierdo

#### Desplazamiento en Malla 1-D – versión trivial

```
if (rank == 0) {
   MPI_Send(&val, 1, MPI_DOUBLE, rank+1, 0, comm);
} else if (rank == p-1) {
   MPI_Recv(&val, 1, MPI_DOUBLE, rank-1, 0, comm, &status);
} else {
   MPI_Send(&val, 1, MPI_DOUBLE, rank+1, 0, comm);
   MPI_Recv(&val, 1, MPI_DOUBLE, rank-1, 0, comm, &status);
}
```

Inconveniente: Secuencialización - las comunicaciones se realizan (probablemente) secuencialmente, sin concurrencia



### Ejemplo – Desplazamiento en Malla 1-D (2)

En algunos casos, la programación se puede simplificar utilizando procesos nulos

### Desplazamiento en Malla 1-D – procesos nulos

```
if (rank == 0) prev = MPI_PROC_NULL;
else prev = rank-1;
if (rank == p-1) next = MPI_PROC_NULL;
else next = rank+1;

MPI_Send(&val, 1, MPI_DOUBLE, next, 0, comm);
MPI_Recv(&val, 1, MPI_DOUBLE, prev, 0, comm, &status);
```

El envío al proceso MPI\_PROC\_NULL finaliza enseguida; la recepción de un mensaje del proceso MPI\_PROC\_NULL no recibe nada y finaliza enseguida

Esta versión no resuelve el problema de la secuencialización

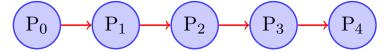
## Ejemplo – Desplazamiento en Malla 1-D (3)

Solución a la secuencialización: Protocolo Pares-Impares

#### Desplazamiento en Malla 1-D – pares-impares

```
if (rank == 0) prev = MPI_PROC_NULL;
else prev = rank-1;
if (rank == p-1) next = MPI_PROC_NULL;
else next = rank+1;

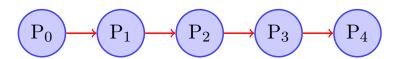
if (rank%2 == 0) {
    MPI_Send(&val, 1, MPI_DOUBLE, next, 0, comm);
    MPI_Recv(&val, 1, MPI_DOUBLE, prev, 0, comm, &status);
} else {
    MPI_Recv(&tmp, 1, MPI_DOUBLE, prev, 0, comm, &status);
    MPI_Send(&val, 1, MPI_DOUBLE, next, 0, comm);
    val = tmp;
}
```



### Ejemplo – Desplazamiento en Malla 1-D (4)

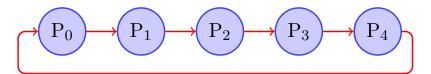
Solución a la secuencialización: Operaciones Combinadas

### Desplazamiento en Malla 1-D – sendrecv



## Ejemplo – Desplazamiento en Anillo

En el caso del anillo, todos los procesos han de enviar y recibir



### Desplazamiento en Anillo – versión trivial

```
if (rank == 0) prev = p-1;
else prev = rank-1;
if (rank == p-1) next = 0;
else next = rank+1;

MPI_Send(&val, 1, MPI_DOUBLE, next, 0, comm);
MPI_Recv(&val, 1, MPI_DOUBLE, prev, 0, comm, &status);
```

Se producirá interbloqueo en el caso de envío síncrono Soluciones: protocolo pares-impares u operaciones combinadas

27

#### Apartado 3

### Comunicación Colectiva

- Sincronización
- Difusión
- Reparto
- Reducción

## Operaciones de Comunicación Colectiva

Involucran a todos los procesos de un grupo (comunicador) – todos ellos deben ejecutar la operación

Operaciones disponibles:

- Difusión (*Bcast*)
- Recogida (*Gather*)
- Sincronización (Barrier)Multi-recogida (Allgather)
  - Todos a todos (Alltoall)
- Reparto (Scatter) Reducción (Reduce)
  - Prefijación (*Scan*)

Estas operaciones suelen tener como argumento un proceso (root) que realiza un papel especial

Prefijo "All": Todos los procesos reciben el resultado

Sufijo "v": La cantidad de datos en cada proceso es distinta

29

#### Sincronización

```
MPI Barrier(comm)
```

Operación pura de sincronización

■ Todos los procesos de comm se detienen hasta que todos ellos han invocado esta operación

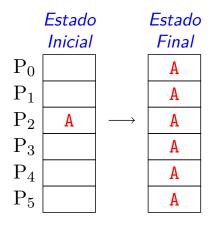
#### Ejemplo – medición de tiempos

```
MPI_Barrier(comm);
t1 = MPI_Wtime();
/*
MPI_Barrier(comm);
t2 = MPI_Wtime();
if (!rank) printf("Tiempo transcurrido: %f s.\n", t2-t1);
```

### Difusión

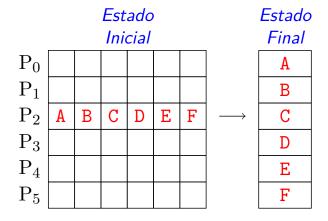
```
MPI_Bcast(buffer, count, datatype, root, comm)
```

El proceso root difunde al resto de procesos el mensaje definido por los 3 primeros argumentos



Reparto

El proceso root distribuye una serie de fragmentos consecutivos del buffer al resto de procesos (incluyendo él mismo)



Versión asimétrica: MPI\_Scatterv

### Reparto: Ejemplo

El proceso  $P_0$  reparte un vector de 15 elementos (a) entre 3 procesos que reciben los datos en el vector b

#### Ejemplo de reparto

```
int main(int argc, char *argv[])
{
  int i, myproc;
  int a[15], b[5];

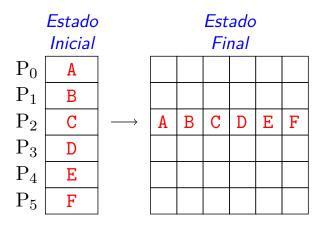
MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &myproc);
  if (myproc==0) for (i=0;i<15;i++) a[i] = i+1;

MPI_Scatter(a, 5, MPI_INT, b, 5, MPI_INT, 0, MPI_COMM_WORLD);

MPI_Finalize();
  return 0;
}</pre>
```

### Recogida

Es la operación inversa de MPI\_Scatter: Cada proceso envía un mensaje a root, el cual lo almacena de forma ordenada de acuerdo al índice del proceso en el buffer de recepción



Versión asimétrica: MPI\_Gatherv

### Multi-Recogida

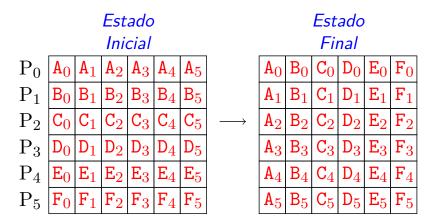
Similar a la operación MPI\_Gather, pero todos los procesos obtienen el resultado

Estado			Estado					
Inicial			Final					
$P_0$	A		A	В	C	D	E	F
$P_1$	В		A	В	C	D	E	F
$P_2$	С	$\longrightarrow$	A	В	U	D	E	F
$P_3$	D		A	В	C	D	E	F
$P_4$	E		Α	В	C	D	E	F
$P_5$	F		A	В	C	D	E	F

Versión asimétrica: MPI\_Allgatherv

#### Todos a Todos

Es una extensión de la operación MPI\_Allgather, cada proceso envía unos datos distintos y recibe datos del resto

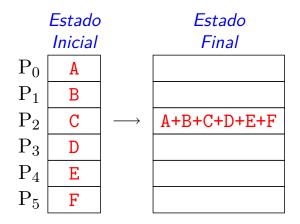


Versión asimétrica: MPI\_Alltoallv

#### Reducción

Similar a MPI\_Gather, pero en lugar de concatenación, se realiza una operación aritmética o lógica (suma, max, and, ..., o definida por el usuario)

El resultado final se devuelve en el proceso root



#### Multi-Reducción

```
MPI_Allreduce(sendbuf, recvbuf, count, type, op, comm)
```

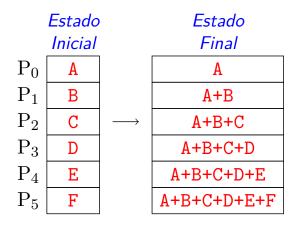
Extensión de MPI Reduce en que todos reciben el resultado

#### Producto escalar de vectores

## Prefijación

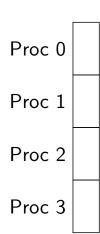
```
MPI_Scan(sendbuf, recvbuf, count, datatype, op, comm)
```

Extensión de las operaciones de reducción en que cada proceso recibe el resultado del procesamiento de los elementos de los procesos desde el 0 hasta él mismo



Ejemplo de Prefijación

Dado un vector de longitud N, distribuido entre los procesos, donde cada proceso tiene  $n_{\rm local}$  elementos consecutivos del vector, se quiere obtener la posición inicial del subvector local



#### Cálculo del índice inicial de un vector paralelo

```
int rstart, nlocal, N;
calcula_nlocal(N,&nlocal);  /* por ejemplo, nlocal=N/p */
MPI_Scan(&nlocal,&rstart,1,MPI_INT,MPI_SUM,comm);
rstart -= nlocal;
```

#### Apartado 4

### Otras Funcionalidades

■ Tipos de Datos Derivados

## Tipos de Datos Básicos

Los tipos de datos básicos en lenguaje C son los siguientes:

MPI\_CHAR signed char MPI\_SHORT signed short int MPI\_INT signed int MPI\_LONG signed long int MPI\_UNSIGNED\_CHAR unsigned char MPI\_UNSIGNED\_SHORT unsigned short int MPI\_UNSIGNED unsigned int MPI\_UNSIGNED\_LONG unsigned long int MPI\_FLOAT float MPI\_DOUBLE double MPI\_LONG\_DOUBLE long double

- Para Fortran existen definiciones similares
- Además de los anteriores, están los tipos especiales MPI\_BYTE y MPI\_PACKED

### Datos Múltiples

Se permite el envío/recepción de múltiples datos:

- El emisor indica el número de datos a enviar en el argumento count
- El mensaje lo componen los count elementos contiguos en memoria
- En el receptor, el argumento count indica el tamaño del buffer
   para saber el tamaño del mensaje:

Este sistema no sirve para:

- Componer un mensaje con varios datos de diferente tipo
- Enviar datos del mismo tipo pero que no estén contiguos en memoria

### Tipos de Datos Derivados

En MPI se permite definir tipos nuevos a partir de otros tipos

El funcionamiento se basa en las siguientes fases:

- I El programador define el nuevo tipo, indicando
  - Los tipos de los diferentes elementos que lo componen
  - El número de elementos de cada tipo
  - Los desplazamientos relativos de cada elemento
- Se registra como un nuevo tipo de datos MPI (commit)
- A partir de entonces, se puede usar para crear mensajes como si fuera un tipo de datos básico
- Cuando no se va a usar más, el tipo se destruye (free)

#### Ventajas:

- Simplifica la programación cuando se repite muchas veces
- No hay copia intermedia, se compacta sólo en el momento del envío

### Tipos de Datos Derivados Regulares

```
MPI_Type_vector(count, length, stride, type, newtype)
```

Crea un tipo de datos homogéneo y regular a partir de elementos de un *array* equiespaciados

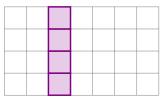
- De cuántos bloques se compone (count)
- De qué longitud son los bloques (length)
- 3 Qué separación hay entre un elemento de un bloque y el mismo elemento del siguiente bloque (stride)
- 4 De qué tipo son los elementos individuales (type)

Constructores relacionados:

- MPI\_Type\_contiguous: elementos contiguos
- MPI\_Type\_indexed: longitud y desplazamiento variable

### Tipos de Datos Derivados Regulares: Ejemplo

Queremos enviar una *columna* de una matriz A[4][7]



En C, los arrays bidimensionales se almacenan por filas

```
buffer † stride †
```

## Tipos de Datos Derivados Irregulares

```
MPI_Type_struct(count, lens, displs, types, newtype)
```

Crea un tipo de datos heterogéneo (p.e. un struct de C)

```
struct {
  char c[5];
  double x,y,z;
} miestruc;

MPI_Datatype types[2] = {MPI_CHAR,MPI_DOUBLE}, newtype;
int lengths[2] = { 5, 1 }; /* solo queremos enviar c y z */
MPI_Aint ad1,ad2,ad3,displs[2];

MPI_Get_address(&miestruc, &ad1);
MPI_Get_address(&miestruc.c[0], &ad2);
MPI_Get_address(&miestruc.z, &ad3);
displs[0] = ad2 - ad1;
displs[1] = ad3 - ad1;
MPI_Type_struct(2, lengths, displs, types, &newtype);
MPI_Type_commit(&newtype);
```