

# **Sistemas Inteligentes**

**Escuela Técnica Superior de Informática**

**Universitat Politècnica de València**

**Tema B2T6:**

**Algoritmo de Viterbi.**

**Estimación de modelos de Markov.**

**Re-estimación por Viterbi.**

# índice

- 1 *Algoritmo de Viterbi* ▷ 1
- 2 Aprendizaje: estimación de probabilidades en modelos de Markov ▷ 10
- 3 Inicialización de la re-estimación por Viterbi ▷ 19

## Aproximación de Viterbi a $P(y \mid M)$

Dado un modelo oculto de Markov  $M = (Q, \Sigma, \pi, A, B)$  con estado final  $F$ , y una cadena  $y = y_1 \cdots y_m \in \Sigma^+$ , la probabilidad de que  $M$  genere  $y$  es:

$$P(y \mid M) = \sum_{z \in Q^+} P(y, z) = \sum_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

Una aproximación a  $P(y \mid M)$  es la llamada *aproximación de Viterbi*:

$$\tilde{P}(y \mid M) = \max_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

La correspondiente *secuencia de estados más probable* es:

$$\tilde{q} = (\tilde{q}_1, \dots, \tilde{q}_m) = \operatorname{argmax}_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

# Algoritmo de Viterbi

Definimos  $V(q, t)$  como la probabilidad máxima de que un modelo oculto de Markov  $M$  alcance el estado  $q$  en el instante  $t$ , emitiendo el prefijo  $y_1 \dots y_t$ :

$$V(q, t) = \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t)$$

$V(q, t)$  puede calcularse recursivamente:

$$\begin{aligned} V(q, t) &= \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t) \\ &= \max_{q' \in Q} \max_{\substack{q_1, \dots, q_{t-1} \\ q_{t-1} = q'}} P(y_1 \dots y_{t-1}, q_1, \dots, q_{t-1}) \cdot A_{q', q} B_{q, y_t} \\ &= \max_{q' \in Q} V(q', t-1) \cdot A_{q', q} B_{q, y_t} \end{aligned}$$

*En general:*

$$V(q, t) = \begin{cases} \pi_q B_{q, y_1} & \text{si } t = 1 \\ \max_{q' \in Q} V(q', t-1) A_{q', q} B_{q, y_t} & \text{si } t > 1 \end{cases}$$

## Algoritmo de Viterbi (cont.)

Aproximación de Viterbi a  $P(y | M)$ :

$$\tilde{P}(y | M) = \max_{q \in Q} V(q, |y|) A_{q,F}$$

- La función  $V()$  puede representarse como una matriz:  $V_{q,t} \equiv V(q, t)$ .
- Esta matriz define un *grafo multietapa* denominado *trellis* y permite el *cálculo iterativo eficiente* de  $V(q, |y|)$  *por Programación Dinámica*.
- La correspondiente secuencia óptima de estados,  $\tilde{q}$ , se calcula recorriendo el *trellis* hacia atrás.
- Complejidad temporal del algoritmo:  $O(mb)$ , donde  $m$  es la longitud de la cadena y  $b$  es el número de transiciones entre estados.


# Algoritmo de Viterbi: ejemplo

b

c

b

a



# Algoritmo de Viterbi: ejercicio

Sea  $M$  un modelo con:

$$Q = \{1, 2, 3, F\}$$

$$\Sigma = \{a, b, c\}$$

$$\pi_1 = \pi_2 = \frac{1}{2}, \pi_3 = 0$$

$A$	1	2	3	$F$
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	0
3	0	0	$\frac{1}{2}$	$\frac{1}{2}$

$B$	$a$	$b$	$c$
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
3	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

1. Halla el *trellis* para la cadena  $abc$ .
2. Obtén la secuencia óptima de estados asociada.



## Ejercicio: resolución directa

$V$	$a$ $t = 1$	$b$ $t = 2$	$c$ $t = 3$	
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{48}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{72}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{6} = \frac{1}{1152}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{6} = \frac{1}{576}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{6} = 0$	
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{96}$	$\frac{1}{48} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{2} = 0$	
3		$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{48}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{4} = \frac{1}{768}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{384}$ $\frac{1}{32} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{256}$	
$F$				$\frac{1}{576} \cdot 0 = 0$ $\frac{1}{192} \cdot 0 = 0$ $\frac{1}{256} \cdot \frac{1}{2} = \frac{1}{512}$

$$\tilde{Q} = (1, 3, 3, F)$$



# Ejercicio: resolución gráfica



## Clasificación sintáctico-estadística mediante Viterbi

En la práctica, las probabilidades condicionales de las clases suelen aproximarse mediante Viterbi. Consideremos el ejercicio de la página B2T5.26:

$$\tilde{P}(y \mid M_A)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid A), \\ P(aab, q_1 q_2 q_3 = 011 \mid A), \\ P(aab, q_1 q_2 q_3 = 111 \mid A))$$

$$= \max(0.0544, 0.0086, 0.0008)$$

$$= 0.0544$$

$$\tilde{P}(y \mid M_B)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid B), \\ P(aab, q_1 q_2 q_3 = 011 \mid B))$$

$$= \max(0.0680, 0.0108)$$

$$= 0.0680$$

$$\tilde{P}(A \mid y) = \frac{\tilde{P}(y \mid M_A) P(A)}{\sum_{c'} \tilde{P}(y \mid c') P(c')} = \frac{0.0544 \cdot 0.6}{0.0544 \cdot 0.6 + 0.0680 \cdot 0.4} = 0.5455$$

$$\tilde{P}(B \mid y) = 1 - \tilde{P}(A \mid y) = 0.4545$$

$$\tilde{c}(y) = \operatorname{argmax}_{c=A,B} \tilde{P}(c \mid y) = A \quad \text{resultado idéntico al de la página B2T5.27}$$

# índice

- 1 Algoritmo de Viterbi ▷ 1
- 2 *Aprendizaje: estimación de probabilidades en modelos de Markov* ▷ 10
- 3 Inicialización de la re-estimación por Viterbi ▷ 19

# Estimación de probabilidades de un modelo de Markov

Problema básico:

Estimar las probabilidades de un modelo de Markov,  $M$ , mediante una secuencia de cadenas de entrenamiento  $Y = \{y_1, \dots, y_n\}$  extraídas independientemente de acuerdo con la ley de probabilidad  $P(y|M)$ .

Como las cadenas se han extraído independientemente:

$$P(Y|M) = \prod_{k=1}^n P(y_k|M)$$

El *estimador de máxima verosimilitud* de  $M$  es:

$$\hat{M} = \operatorname{argmax}_M \prod_{k=1}^n P(y_k|M) \approx \operatorname{argmax}_M \prod_{k=1}^n \tilde{P}(y_k|M)$$

# Estimación mediante el algoritmo de Viterbi

## *Idea básica:*

Analizar todas las cadenas  $Y$ , contabilizando las frecuencias de uso de las transiciones entre estados, de generación de símbolos en cada estado, etc. y normalizar adecuadamente.

## *Problema:*

Cómo analizar las cadenas si no se conocen las probabilidades de del modelo?

## *Una posible solución:*

1. Inicializar las probabilidades “adecuadamente”
2. Analizar cada cadena de  $Y$  mediante el algoritmo de Viterbi y obtener la secuencia de estados correspondiente
3. A partir de esta secuencia de estados, contabilizar las frecuencias requeridas.
4. Normalizar las frecuencias para obtener nuevas probabilidades del modelo
5. Repetir pasos 2-4 hasta convergencia.

# Estimación mediante el algoritmo de Viterbi: ejemplo

Se dispone de tres cadenas de contorno de 4-direcciones que representan tres dígitos “*siete*” manuscritos<sup>1</sup>.

A partir de estas cadenas se desea re-estimar las probabilidades de un modelo de Markov para estos dígitos. Utilizando el algoritmo de Viterbi se han obtenido las siguientes *secuencias óptimas de estados* para cada *cadena*:

*Cadena:* **aaaaaddcdcdcdcdccbabababccccb**  
*Secuencia óptima de estados:* **1111122222222222333333333344444F**

*Cadena:* **aaaaaddcdcdcdcdccbabababababcccdccb**  
*Secuencia óptima de estados:* **1111122222222222233333333334444444F**

*Cadena:* **aaaadcdcdcdcdcdcbababababcccdccbaab**  
*Secuencia óptima de estados:* **11112222222222222333333333444444444F**

<sup>1</sup>Para mayor claridad se representan los trazos horizontales como  $0=a$ ,  $2=c$  y los verticales como  $1=b$ ,  $3=d$ .

# Estimación mediante el algoritmo de Viterbi: ejemplo (cont.)

$$\pi_1 = 3/3 = 1 \quad \pi_2 = \pi_3 = \pi_4 = 0$$

<i>A</i>	1	2	3	4	<i>F</i>
1	4 + 4 + 3	1 + 1 + 1	0	0	0
2	0	11 + 11 + 11	1 + 1 + 1	0	0
3	0	0	9 + 9 + 8	1 + 1 + 1	0
4	0	0	0	4 + 6 + 8	1 + 1 + 1

 $\Rightarrow$ 

<i>A</i>	1	2	3	4	<i>F</i>
1	$\frac{11}{14}$	$\frac{3}{14}$	0	0	0
2	0	$\frac{33}{36}$	$\frac{3}{36}$	0	0
3	0	0	$\frac{26}{29}$	$\frac{3}{29}$	0
4	0	0	0	$\frac{18}{21}$	$\frac{3}{21}$

<i>B</i>	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>
1	5 + 5 + 4	0	0	0
2	0	0	6 + 6 + 6	6 + 6 + 6
3	5 + 5 + 4	5 + 5 + 5	0	0
4	0 + 0 + 2	1 + 2 + 2	4 + 4 + 4	0 + 1 + 1

 $\Rightarrow$ 

<i>B</i>	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>
1	$\frac{14}{14}$	0	0	0
2	0	0	$\frac{18}{36}$	$\frac{18}{36}$
3	$\frac{14}{29}$	$\frac{15}{29}$	0	0
4	$\frac{2}{21}$	$\frac{5}{21}$	$\frac{12}{21}$	$\frac{2}{21}$

# Algoritmo de reestimación por Viterbi

**Input:**  $M^0 = (Q^0, \Sigma^0, \pi^0, A^0, B^0)$

*/\* Modelo inicial \*/*

$Y = \{y_1, \dots, y_n\}$

*/\* cadenas de entrenamiento \*/*

**Output:**  $M = (Q, \Sigma, \pi, A, B)$

*/\* Modelo optimizado \*/*

$M = M^0$

**repeat**  $M' = M$ ;  $\pi = 0$ ;  $A = 0$ ;  $B = 0$

**for**  $k = 1$  **to**  $n$  **do**

$m = |y_k|$

*/\* secuencia de estados más probable para  $y_k$ , \*/*

$\tilde{q}_1, \dots, \tilde{q}_m = \operatorname{argmax}_{q_1, \dots, q_m} P(y_k, q_1, \dots, q_m \mid M')$  */\* por Viterbi \*/*

$\pi_{\tilde{q}_1}++$ ;  $B_{\tilde{q}_1, y_{k,1}}++$

*/\* actualización de contadores \*/*

**for**  $t = 2$  **to**  $m$  **do**  $A_{\tilde{q}_{t-1}, \tilde{q}_t}++$ ;  $B_{\tilde{q}_t, y_{k,t}}++$  **done**;  $A_{\tilde{q}_m, F}++$   
**done**

$s = \sum_{q \in Q} \pi_q$

**forall**  $q \in Q$  **do**

*/\* normalización de contadores \*/*

$\pi_q = \pi_q / s$

$a = \sum_{q' \in Q} A_{q, q'}$ ; **forall**  $q' \in Q$  **do**  $A_{q, q'} = A_{q, q'} / a$

$b = \sum_{\sigma \in \Sigma} B_{q, \sigma}$ ; **forall**  $\sigma \in \Sigma$  **do**  $B_{q, \sigma} = B_{q, \sigma} / b$

**done**

**until**  $M = M'$



## Algoritmo mediante el algoritmo de Viterbi: ejercicio

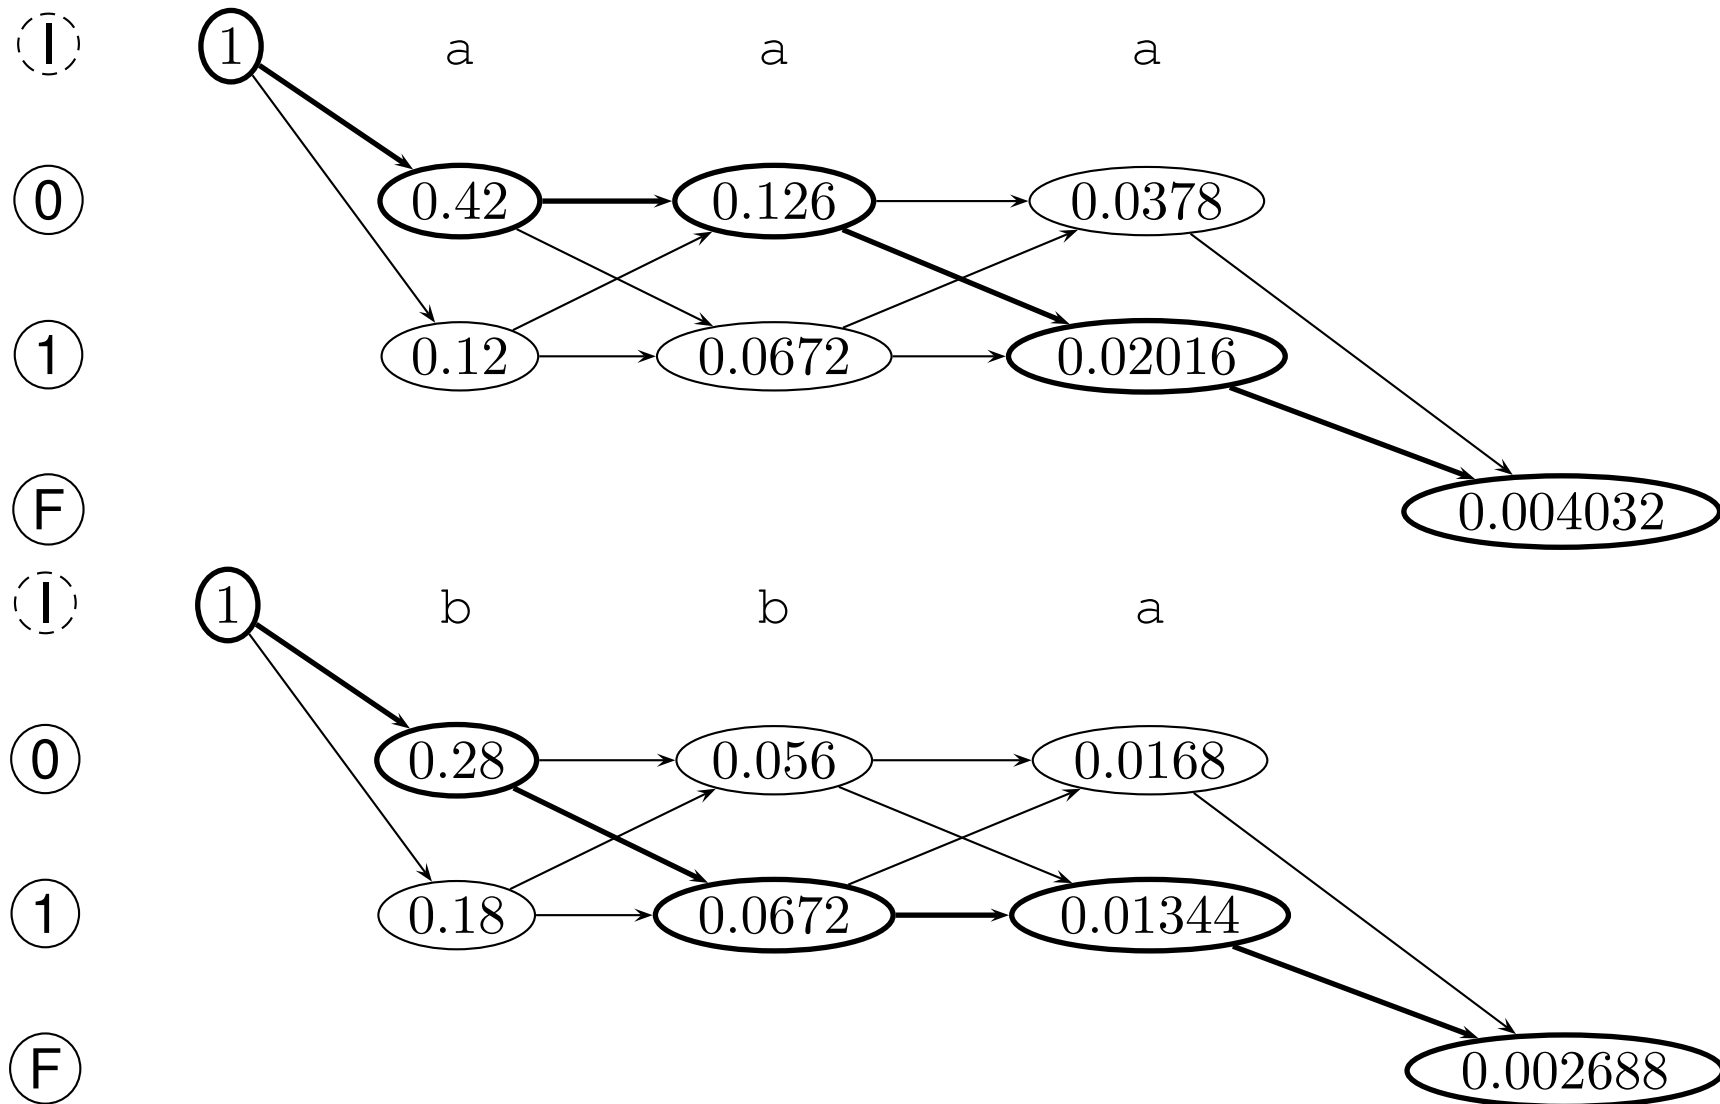
Sea  $M$  un modelo de Markov de conjunto de estados  $Q = \{0, 1, F\}$ ; alfabeto  $\Sigma = \{a, b\}$ ; probabilidades iniciales  $\pi_0(0) = 0.7, \pi_0(1) = 0.3$ ; y probabilidades de transición entre estados y de emisión de símbolos:

$A$	0	1	$F$
0	0.5	0.4	0.1
1	0.3	0.5	0.2

$B$	$a$	$b$
0	0.6	0.4
1	0.4	0.6

Reestima los parámetros de  $M$  mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “a a a” y “b b a”.

## Ejercicio: secuencias de estados mas probables



Los pares *cadena-secuencia óptima de estados* obtenidos son:

a a a	b b a
0 0 1 F	0 1 1 F

## Ejercicio: parámetros reestimados

$$\hat{\pi}_0(0) = \frac{2}{2} = 1$$

$$\hat{\pi}_0(1) = \frac{0}{2} = 0$$

$A$	0	1	$F$
0	$\frac{1}{3}$	$\frac{2}{3}$	0
1	0	$\frac{1}{3}$	$\frac{2}{3}$

$B$	$a$	$b$
0	$\frac{2}{3}$	$\frac{1}{3}$
1	$\frac{2}{3}$	$\frac{1}{3}$

# índice

- 1 Algoritmo de Viterbi ▷ 1
- 2 Aprendizaje: estimación de probabilidades en modelos de Markov ▷ 10
- 3 *Inicialización de la re-estimación por Viterbi* ▷ 19

## Inicialización de la re-estimación por Viterbi

*Una idea elemental:* Inicializar todas las probabilidades según distribuciones equiprobables.

*Problema:* Suele producir problemas de convergencia o convergencia a máximos locales inadecuados.

### ***Una idea útil para modelos lineales:***

- Segmentar cada cadena de  $Y$  en tantos segmentos de (aproximadamente) la misma longitud como estados tenga el modelo de Markov.
- Asignar los símbolos de cada segmento a su correspondiente estado
- Contabilizar las frecuencias de generación y transición
- Normalizar las frecuencias para obtener probabilidades iniciales requeridas

# Inicialización por segmentación lineal: Ejemplo

Obtener un modelo de Markov de  $N = 3$  estados mediante segmentación lineal a partir de las cadenas

$$y_1 = \text{aabbcc}$$

$$y_2 = \text{aaabbccc}$$

$$Q = \{1, 2, 3, F\} \quad \Sigma = \{a, b, c\}$$

$$q = \left\lfloor \frac{t \cdot N}{|y| + 1} \right\rfloor + 1 : \begin{array}{cc} \text{aabbcc} & \text{aaabbccc} \\ 1122233 & 11222333 \end{array}$$

$$\pi_1 = \frac{2}{2}, \quad \pi_2 = \pi_3 = 0$$

$A$	1	2	3	$F$
1	$\frac{2}{4}$	$\frac{2}{4}$	0	0
2	0	$\frac{4}{6}$	$\frac{2}{6}$	0
3	0	0	$\frac{3}{5}$	$\frac{2}{5}$

$B$	$a$	$b$	$c$
1	$\frac{4}{4}$	0	0
2	$\frac{1}{6}$	$\frac{5}{6}$	0
3	0	0	$\frac{5}{5}$

# Inicialización por segmentación lineal

**Input:**  $Y = \{y_1, \dots, y_n\}$ ,  $N$  /\* cadenas de entrenamiento, número de estados \*/

**Output:**  $M = (Q, \Sigma, \pi, A, B)$  /\* modelo \*/

$Q = \{1, 2, \dots, N, F\}$ ;  $\Sigma = \{y \in y_k \in Y\}$  /\* estados y símbolos \*/

$\pi = 0$ ;  $A = 0$ ;  $B = 0$  /\* inicialización de contadores \*/

**for**  $k = 1$  **to**  $n$  **do** /\* actualización de contadores por \*/

$q = 1$ ;  $\pi_q++$ ;  $B_{q,y_{k,1}}++$  /\* alineamiento lineal de  $y_k$  con los estados \*/

**for**  $t = 2$  **to**  $|y_k|$  **do**  $q' = q$ ;  $q = \left\lfloor \frac{t}{|y_k|+1} N \right\rfloor + 1$ ;  $A_{q',q}++$ ;  $B_{q,y_{k,t}}++$  **done**

$A_{q,F}++$

**done**

$s = \sum_{q \in Q} \pi_q$

**forall**  $q \in Q$  **do** /\* normalización de contadores \*/

$\pi_q = \pi_q / s$

$a = \sum_{q' \in Q} A_{q,q'}$ ; **forall**  $q' \in Q$  **do**  $A_{q,q'} = A_{q,q'} / a$

$b = \sum_{\sigma \in \Sigma} B_{q,\sigma}$ ; **forall**  $\sigma \in \Sigma$  **do**  $B_{q,\sigma} = B_{q,\sigma} / b$

**done**