



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Algoritmo Perceptrón¹

Jorge Civera
Alfons Juan
Albert Sanchis

DSIC

Departamento de Sistemas
Informáticos y Computación

¹Para una correcta visualización, se requiere Acrobat Reader v. 7.0 o superior

Objetivos formativos

- Aplicar el algoritmo Perceptrón a una tarea de clasificación
- Explicar el comportamiento del algoritmo Perceptrón en función de sus parámetros

Índice

1	Funciones discriminantes lineales	3
2	Algoritmo Perceptrón	4
3	Ejemplo	5
4	Convergencia y calidad de la solución	6
5	Conclusiones	7

1. Funciones discriminantes lineales

Todo clasificador puede representarse como:

$$c(x) = \arg \max_c g_c(x) \quad \leftarrow$$

donde cada clase c utiliza una **función discriminante** $g_c(x)$ que mide el grado de pertenencia de un objeto x a la clase c

Las funciones discriminantes más utilizadas son **lineales** (con x):

$$g_c(x) = w_c^t x + w_{c0} \quad \text{donde} \quad x = \begin{pmatrix} x_1 \\ \vdots \\ x_D \end{pmatrix} \quad y \quad w_c = \begin{pmatrix} w_{c1} \\ \vdots \\ w_{cD} \end{pmatrix}$$

Con notación **homogénea**:

$$g_c(x) = \underline{w_c^t} x \quad \text{donde} \quad x = \begin{pmatrix} 1 \\ x \end{pmatrix} \quad y \quad w_c = \begin{pmatrix} w_{c0} \\ w_c \end{pmatrix}$$

$$g_c(x) = (1 \ x_1 \ \dots \ x_D) \cdot \begin{pmatrix} w_{c0} \\ w_{c1} \\ \vdots \\ w_{cD} \end{pmatrix} = w_{c0} + w_{c1} \cdot x_1 + \dots + w_{cD} \cdot x_D$$

2. Algoritmo Perceptrón

$\boxed{x_1}$ $C_1 = \text{spam}$
 $\boxed{x_2}$ $C_2 = \text{spam}$
 $\boxed{x_3}$ $C_3 = \text{no-spam}$
 \vdots \vdots

Entrada: $\{(\mathbf{x}_n, c_n)\}_{n=1}^N$, $\{\mathbf{w}_c\}_{c=0}^C$, $\alpha \in \mathbb{R}^{>0}$ y $b \in \mathbb{R}$

Salida: $\{\mathbf{w}_c\}^* = \arg \min_{\{\mathbf{w}_c\}} \sum_n \left[\max_{c \neq c_n} \mathbf{w}_c^t \mathbf{x}_n + b > \mathbf{w}_{c_n}^t \mathbf{x}_n \right]$

Método:

$[P] = \begin{cases} 1 & \text{si } P = \text{verdadero} \\ 0 & \text{si } P = \text{falso} \end{cases}$

Muestra bien clasificada

$$(\underline{x}_n, \underline{c}_n) \quad \boxed{g(\underline{x}_n)_{\underline{c}_n}} > g_c(\underline{x}_n) \quad \forall c \neq c_n$$

\uparrow Función discriminante de la clase correcta x_n pertenece a c_n

repetir
 → para todo dato x_n
 $err = \text{falso}$
 → para toda clase c distinta de c_n
 si $\boxed{\mathbf{w}_c^t \mathbf{x}_n + b} > \boxed{\mathbf{w}_{c_n}^t \mathbf{x}_n}$: $\mathbf{w}_c = \mathbf{w}_c - \alpha \cdot \mathbf{x}_n$ $err = \text{verdadero}$
 si err : $\mathbf{w}_{c_n} = \mathbf{w}_{c_n} + \alpha \cdot \mathbf{x}_n$
 hasta que no quedan muestras mal clasificadas

$g_c(x_n)$ \leftarrow incorrecta
 $g_{c_n}(x_n)$ \leftarrow correcta
 0.1 \leftarrow vector de pesos de la clase incorrecta
 vector de pesos de la clase correcta
 $\hookrightarrow \eta(x_n, c_n) \Big|_{n=1}^N$

$$X_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad C_1 = 0 \quad \leftarrow g(x_1) > g(x_1)$$

$$\boxed{g_0(x_1) > g(x_1)}$$

$$g_0(x_1) = \underline{W}_0^T \cdot X_1 = (0 \ 0 \ 0) \cdot \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = 0 \cdot 1 + 0 \cdot 0 + 0 \cdot 0 = 0$$

Funci6 correcte

$$g_0(x_1) = \underline{W}_0^T \cdot X_1 = (0 \ 0 \ 0) \cdot \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = 0 \quad \leftarrow \text{Funci6 correcte}$$

$$\text{si } \underline{W}_2^T \cdot X_1 + b > \underline{W}_1^T \cdot X_1$$

$$\underline{W}_2^T \cdot X_1 + b > \underline{W}_1^T \cdot X_1$$

$$\boxed{g(x_1) + b} > \boxed{g(x_1)}$$

si se cumple modifi'camos los pesos


$$W_0 = W_0 - \alpha \cdot X_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} - 1.0 \cdot \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

$$W_0 = W_0 + \alpha \cdot X_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} + 1.0 \cdot \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 1.0 \\ 0 \\ 0 \end{pmatrix}$$

3. Ejemplo

$$X_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad C_1 = 0 \quad \underline{W}_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \quad \underline{\alpha} = 1.0$$

$$X_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad C_2 = 1 \quad \boxed{\underline{W}_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}} \quad \underline{b} = 0.1$$



$$X_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad C_2 = 1 \quad \leftarrow \text{clase correcta para } b$$

$$\text{si } \underline{g(x_2) + b} > \underline{g(x_2)} \text{ est. modifi'camos pesos}$$


$$g_0(x_2) = \underline{W}_0^T \cdot X_2 = (1 \ 0 \ 0) \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \underline{1} + b$$

$$g_0(x_2) = \underline{W}_0^T \cdot X_2 = (-1 \ 0 \ 0) \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \underline{-1}$$

$$\text{si } 1 + b \geq -1$$

$$W_0 = W_0 - \alpha \cdot X_2 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} - 1.0 \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \\ -1 \end{pmatrix}$$

$$W_0 = W_0 + \alpha \cdot X_2 = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix} + 1.0 \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$



4. Convergencia y calidad de la solución

Converge si los datos son linealmente separables y $b \leq 0$

Conviene implementarlo con un máximo número de iteraciones.

Cuando $\alpha \rightarrow 0$, la convergencia es más suave, pero más lenta.

Calidad de la solución:

Linealmente separables	$b \leq 0$	$b > 0$
SI	Fronteras con poca holgura	Fronteras <i>centradas</i>
NO	Fronteras baja calidad	Fronteras casi óptimas

5. Conclusiones

Hemos visto:

- El algoritmo Perceptrón y una traza del mismo
- La convergencia del algoritmo en función de sus parámetros y las muestras de entrenamiento utilizadas

$$g_0(x) = \underset{w_0^t}{(1 \ -1 \ -1)} \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix} = \underline{\underline{1 - x_1 - x_2}}$$

$$g_{\bullet}(x) = (-1 \ 1 \ 1) \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix} = -1 + x_1 + x_2$$

$$g_0(x) = g_{\bullet}(x) \rightarrow x_2 = \dots$$