

# **Sistemas Inteligentes**

**Escuela Técnica Superior de Informática**

**Universitat Politècnica de València**

## **Introducción a la estimación del error en Reconocimiento de Formas**

# Evaluación de un clasificador

¿Cómo utilizo mis muestras etiquetadas para entrenar y evaluar un clasificador?

- Entrenamos un clasificador con  $x_1, x_2, x_4, x_5, x_7, x_8$ 
  - Ejemplo: utilizando el algoritmo Perceptrón obtengo:

Iris Setosa

$$x_1 = (1.4 \ 0.2)^t$$

$$x_2 = (1.3 \ 0.2)^t$$

$$x_3 = (1.5 \ 0.2)^t$$

$$w_1 = (0.8 \ -1.8 \ -1)^t$$

$$w_2 = (0.6 \ -1.7 \ -1)^t$$

$$w_3 = (-2.5 \ -1.5 \ 0.6)^t$$

Iris Versicolor

$$x_4 = (4.7 \ 1.4)^t$$

$$x_5 = (4.5 \ 1.5)^t$$

$$x_6 = (4.9 \ 1.5)^t$$

- Evaluamos con  $x_3, x_6, x_9$

Iris Virgínica

$$x_7 = (6.0 \ 2.5)^t$$

$$x_8 = (5.1 \ 1.9)^t$$

$$x_9 = (5.9 \ 2.1)^t$$

- Ejemplo: un clasificador con los pesos del Perceptron

$$c(x_3) = \operatorname{argmax}(w_1^t x_3, w_2^t x_3, w_3^t x_3) = 1 \rightarrow \text{Acierto}$$

$$c(x_6) = \operatorname{argmax}(w_1^t x_6, w_2^t x_6, w_3^t x_6) = 3 \rightarrow \text{Error}$$

$$c(x_9) = \operatorname{argmax}(w_1^t x_9, w_2^t x_9, w_3^t x_9) = 3 \rightarrow \text{Acierto}$$

# Diseño de experimentos

- Necesitamos dedicar muestras a entrenamiento y muestras a evaluación (test)
- **Partición**: Si los conjuntos de entrenamiento y test son disjuntos
  - Inconveniente: las muestras de test no se pueden usar para entrenar

# Diseño de experimentos

- Necesitamos dedicar muestras a entrenamiento y muestras a evaluación (test)
- **Partición**: Si los conjuntos de entrenamiento y test son disjuntos
  - Inconveniente: las muestras de test no se pueden usar para entrenar
- **Resustitución**: Uso las mismas muestras para entrenar y para evaluar
  - Inconveniente: es muy optimista

# Diseño de experimentos

- Necesitamos dedicar muestras a entrenamiento y muestras a evaluación (test)
- **Partición**: Si los conjuntos de entrenamiento y test son disjuntos
  - Inconveniente: las muestras de test no se pueden usar para entrenar
- **Resustitución**: Uso las mismas muestras para entrenar y para evaluar
  - Inconveniente: es muy optimista
- ¿Cómo aprovechar mejor mis muestras?
- **Validación Cruzada en  $B$  bloques ( $B$ -fold Cross Validation)**: Se definen  $B$  bloques. Iterativamente, un bloque para test y el resto para entrenamiento.
  - Inconvenientes: Reduce el número de datos de entrenamiento (sobre todo cuando  $B$  es pequeño) y el coste computacional se incrementa con  $B$ .
- **Exclusión individual (Leaving One Out)**: Iterativamente, una muestra para test y el resto para entrenamiento. Equivale a Validación Cruzada en  $N$  bloques.
  - Inconvenientes: el coste computacional.

## Ejemplo: diseño de experimentos

- Validación cruzada en 3 bloques:

Iris Setosa

$$\mathbf{x}_1 = (1.4 \ 0.2)^t$$

$$\mathbf{x}_2 = (1.3 \ 0.2)^t$$

$$\mathbf{x}_3 = (1.5 \ 0.2)^t$$

$$B_1 = \{\mathbf{x}_1, \mathbf{x}_4, \mathbf{x}_7\}$$

$$B_2 = \{\mathbf{x}_2, \mathbf{x}_5, \mathbf{x}_8\}$$

$$B_3 = \{\mathbf{x}_3, \mathbf{x}_6, \mathbf{x}_9\}$$

Test	Entrenamiento
$B_1$	$B_2, B_3$
$B_2$	$B_1, B_3$
$B_3$	$B_1, B_2$

3 ejecuciones del algoritmo de entrenamiento y evaluación

Iris Versicolor

$$\mathbf{x}_4 = (4.7 \ 1.4)^t$$

$$\mathbf{x}_5 = (4.5 \ 1.5)^t$$

$$\mathbf{x}_6 = (4.9 \ 1.5)^t$$

- Exclusión individual (Leaving One Out):

Iris Virgínica

$$\mathbf{x}_7 = (6.0 \ 2.5)^t$$

$$\mathbf{x}_8 = (5.1 \ 1.9)^t$$

$$\mathbf{x}_9 = (5.9 \ 2.1)^t$$

Test	Entrenamiento
$\mathbf{x}_1$	$\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7, \mathbf{x}_8, \mathbf{x}_9$
$\mathbf{x}_2$	$\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7, \mathbf{x}_8, \mathbf{x}_9$
$\mathbf{x}_3$	$\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7, \mathbf{x}_8, \mathbf{x}_9$
...	...
$\mathbf{x}_9$	$\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7, \mathbf{x}_8$

9 ejecuciones del algoritmo de entrenamiento y evaluación

# Estimación empírica de la probabilidad de error

- La estimación empírica de la probabilidad de error es:

$$\hat{p}_{\text{error}} = \frac{N_e}{N}$$

siendo  $N_e$  el número de errores al clasificar  $N$  muestras.

- ¿Cuál sería la estimación de la *verdadera* probabilidad de error  $p_{\text{error}}$ ?
- Si  $N$  es muy grande, podemos asumir que  $\hat{p}_{\text{error}} \sim \mathcal{N} \left( p_{\text{error}}, \frac{p_{\text{error}}(1 - p_{\text{error}})}{N} \right)$
- Intervalo de confianza al 95 %:

$$p(\hat{p}_{\text{error}} - \epsilon \leq p_{\text{error}} \leq \hat{p}_{\text{error}} + \epsilon) = 0.95; \quad \epsilon = 1.96 \sqrt{\frac{\hat{p}_{\text{error}}(1 - \hat{p}_{\text{error}})}{N}}$$

- Ejemplo:* Tenemos 50 errores en 1000 muestras de test. Con una confianza del 95 % podemos afirmar que  $p_{\text{error}}$  es:

$$p_{\text{error}} = 0.05 \pm 1.96 \sqrt{\frac{0.05 \cdot 0.95}{1000}} = 0.05 \pm 0.014 \quad (5 \% \pm 1.4 \%)$$

- Ejemplo:* Si hay 5 errores en 100 muestras de test  $p_{\text{error}}$  es:

$$p_{\text{error}} = \dots = 0.05 \pm 0.043 \quad (5 \% \pm 4.3 \%)$$