

# Sistemas Inteligentes

Escuela Técnica Superior de Informática

Universitat Politècnica de València

## **Tema B2.T6:** **Programación dinámica.** **Algoritmo *Forward*.** **Algoritmo de Viterbi.**

# Índice

- 1 *Algoritmo Forward* ▷ 1
- 2 Algoritmo de Viterbi ▷ 13
- 3 Clasificación sintáctico-estadística ▷ 27

# Algoritmo Forward

Definimos  $\alpha(q, t)$  como la probabilidad de que un modelo oculto de Markov  $M$  genere el prefijo  $y_1 \cdots y_t$ , alcanzando el estado  $q$  en el instante  $t$ :

$$\alpha(q, t) = \sum_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \cdots y_t, q_1, \dots, q_t)$$

$\alpha(q, t)$  puede calcularse recursivamente:

$$\begin{aligned} \alpha(q, t) &= \sum_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \cdots y_t, q_1, \dots, q_t) \\ &= \sum_{\substack{q_1, \dots, q_{t-1} \\ q' \in Q \\ q_{t-1} = q'}} P(y_1 \cdots y_{t-1}, q_1, \dots, q_{t-1}) A_{q', q} B_{q, y_t} \\ &= \sum_{q' \in Q} \sum_{\substack{q_1, \dots, q_{t-1} \\ q_{t-1} = q'}} P(y_1 \cdots y_{t-1}, q_1, \dots, q_{t-1}) A_{q', q} B_{q, y_t} \\ &= \sum_{q' \in Q} \alpha(q', t-1) A_{q', q} B_{q, y_t} \end{aligned}$$

## Algoritmo Forward (cont.)

$$\text{En general: } \alpha(q, t) = \begin{cases} \pi_q B_{q, y_1} & \text{si } t = 1 \\ \sum_{q' \in Q} \alpha(q', t-1) A_{q', q} B_{q, y_t} & \text{si } t > 1 \end{cases}$$

La probabilidad de la cadena  $P(y \mid M)$ :

$$P(y \mid M) = \sum_{q \in Q} \alpha(q, |y|) A_{q, F}$$

- La función  $\alpha()$  puede representarse como una matriz:  $\alpha_{q,t} \equiv \alpha(q, t)$ .
- Esta matriz define un *grafo multietapa* denominado *trellis* y permite el *cálculo iterativo eficiente* de  $\alpha(q, |y|)$  *por Programación Dinámica*.
- Complejidad temporal del algoritmo:  $O(mb)$ , donde  $m$  es la longitud de la cadena y  $b$  es el número de transiciones entre estados.

# Algoritmo Forward

①

a


a

b


①

①


F

$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$



# Algoritmo Forward




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo Forward




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$



# Algoritmo Forward




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$






# Algoritmo Forward




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo Forward: ejemplo

**b      c      b      a**



# Algoritmo Forward: ejemplo

**b**      **c**      **b**      **a**



# Algoritmo forward: ejercicio

Sea  $M$  un modelo con:

$$Q = \{1, 2, 3, F\}$$

$$\Sigma = \{a, b, c\}$$

$$\pi_1 = \pi_2 = \frac{1}{2}, \pi_3 = 0$$

$A$	1	2	3	$F$
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	0
3	0	0	$\frac{1}{2}$	$\frac{1}{2}$

$B$	$a$	$b$	$c$
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
3	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

1. Aplica el algoritmo forward a la cadena  $abc$ .

## Ejercicio: resolución directa

$\alpha$	$a$ $t = 1$	$b$ $t = 2$	$c$ $t = 3$	
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{3} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{5}{144}$	$\frac{5}{144} \cdot \frac{1}{4} \cdot \frac{1}{6} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{6} +$ $\frac{5}{96} \cdot 0 \cdot \frac{1}{6} = \frac{13}{3456}$	
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{24}$	$\frac{5}{144} \cdot \frac{1}{2} \cdot \frac{1}{2} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{2} +$ $\frac{5}{96} \cdot 0 \cdot \frac{1}{2} = \frac{1}{76}$	
3		$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{2} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{5}{96}$	$\frac{5}{144} \cdot \frac{1}{4} \cdot \frac{1}{4} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{4} +$ $\frac{5}{96} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{7}{576}$	
$F$				$\frac{13}{3456} \cdot 0 +$ $\frac{1}{76} \cdot 0 +$ $\frac{7}{576} \cdot \frac{1}{2} = \frac{7}{1152}$

# Índice

- 1 Algoritmo Forward ▷ 1
- 2 *Algoritmo de Viterbi* ▷ 13
- 3 Clasificación sintáctico-estadística ▷ 27

## Aproximación de Viterbi a $P(y \mid M)$

Dado un modelo oculto de Markov  $M = (Q, \Sigma, \pi, A, B)$  con estado final  $F$ , y una cadena  $y = y_1 \cdots y_m \in \Sigma^+$ , la probabilidad de que  $M$  genere  $y$  es:

$$P(y \mid M) = \sum_{z \in Q^+} P(y, z) = \sum_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

Una aproximación a  $P(y \mid M)$  es la llamada *aproximación de Viterbi*:

$$\tilde{P}(y \mid M) = \max_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

La correspondiente *secuencia de estados más probable* es:

$$\tilde{q} = (\tilde{q}_1, \dots, \tilde{q}_m) = \operatorname{argmax}_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

# Algoritmo de Viterbi

Definimos  $V(q, t)$  como la probabilidad máxima de que un modelo oculto de Markov  $M$  alcance el estado  $q$  en el instante  $t$ , emitiendo el prefijo  $y_1 \dots y_t$ :

$$V(q, t) = \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t)$$

$V(q, t)$  puede calcularse recursivamente:

$$\begin{aligned} V(q, t) &= \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t) \\ &= \max_{q' \in Q} \max_{\substack{q_1, \dots, q_{t-1} \\ q_{t-1} = q'}} P(y_1 \dots y_{t-1}, q_1, \dots, q_{t-1}) \cdot A_{q', q} B_{q, y_t} \\ &= \max_{q' \in Q} V(q', t-1) \cdot A_{q', q} B_{q, y_t} \end{aligned}$$

*En general:*

$$V(q, t) = \begin{cases} \pi_q B_{q, y_1} & \text{si } t = 1 \\ \max_{q' \in Q} V(q', t-1) A_{q', q} B_{q, y_t} & \text{si } t > 1 \end{cases}$$



## Algoritmo de Viterbi (cont.)

Aproximación de Viterbi a  $P(y | M)$ :

$$\tilde{P}(y | M) = \max_{q \in Q} V(q, |y|) A_{q,F}$$

- La función  $V()$  puede representarse como una matriz:  $V_{q,t} \equiv V(q, t)$ .
- Esta matriz define un *grafo multietapa* denominado *trellis* y permite el *cálculo iterativo eficiente* de  $V(q, |y|)$  *por Programación Dinámica*.
- La correspondiente secuencia óptima de estados,  $\tilde{q}$ , se calcula recorriendo el *trellis* hacia atrás.
- Complejidad temporal del algoritmo:  $O(mb)$ , donde  $m$  es la longitud de la cadena y  $b$  es el número de transiciones entre estados.

# Algoritmo de Viterbi: ejemplo

I

a

a


b

0


1

F


$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo de Viterbi: ejemplo




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo de Viterbi: ejemplo




$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo de Viterbi: ejemplo



$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$




# Algoritmo de Viterbi: ejemplo




$$Q = \{001F\}$$

$$\begin{bmatrix} a \\ b \end{bmatrix} \quad \begin{bmatrix} 0.9 \\ 0.1 \end{bmatrix} \quad \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix}$$



# Algoritmo de Viterbi: ejemplo

**b      c      b      a**




# Algoritmo de Viterbi: ejemplo

b

c

b

a





# Algoritmo de Viterbi: ejercicio

Sea  $M$  un modelo con:

$$Q = \{1, 2, 3, F\}$$

$$\Sigma = \{a, b, c\}$$

$$\pi_1 = \pi_2 = \frac{1}{2}, \pi_3 = 0$$

$A$	1	2	3	$F$
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	0
3	0	0	$\frac{1}{2}$	$\frac{1}{2}$

$B$	$a$	$b$	$c$
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
3	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$



1. Halla el *trellis* para la cadena  $abc$ .
2. Obtén la secuencia óptima de estados asociada.

## Ejercicio: resolución directa

$V$	$a$ $t = 1$	$b$ $t = 2$	$c$ $t = 3$	
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{48}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{72}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{6} = \frac{1}{1152}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{6} = \frac{1}{576}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{6} = 0$	
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{96}$	$\frac{1}{48} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{2} = 0$	
3		$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{48}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{4} = \frac{1}{768}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{384}$ $\frac{1}{32} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{256}$	
$F$				$\frac{1}{576} \cdot 0 = 0$ $\frac{1}{192} \cdot 0 = 0$ $\frac{1}{256} \cdot \frac{1}{2} = \frac{1}{512}$

$$\tilde{Q} = (1, 3, 3, F)$$

# Ejercicio: resolución gráfica



# Índice

- 1 Algoritmo Forward ▷ 1
- 2 Algoritmo de Viterbi ▷ 13
- 3 *Clasificación sintáctico-estadística* ▷ 27

## Clasificación sintáctico-estadística

Suponemos  $C$  clases de objetos, representados como cadenas de  $\Sigma^+$ . Planteamiento similar al de la clasificación estadística en el caso vectorial:

- **Regla de clasificación:** Una cadena  $y \in \Sigma^+$  se asigna a la clase  $\hat{c}(y)$ :

$$\hat{c}(y) = \operatorname{argmax}_{1 \leq c \leq C} P(c \mid y)$$

- **Probabilidad a posteriori** de la clase  $c$ :  $P(c \mid y)$


$$P(c \mid y) = \frac{P(y \mid M_c)P(c)}{P(y)} \quad \text{donde} \quad P(y) = \sum_{c'=1}^C P(y \mid M_{c'})P(c')$$

- **Probabilidad condicional** de la clase  $c$ :  $P(y \mid M_c)$ , función de probabilidad que modela la distribución de las cadenas de  $c$  en  $\Sigma^*$  mediante un modelo de Markov  $M_c$ .
- **Probabilidad a priori** de una clase  $c$ :  $P(c)$ ,  $1 \leq c \leq C$


## Clasificación sintáctico-estadística: ejercicio

Se tiene un problema de clasificación en dos clases ( $A$  y  $B$ ) de objetos representados mediante cadenas de símbolos en el alfabeto  $\Sigma = \{a, b\}$ . Las probabilidades a priori de las clases son  $P(A) = 0.6$  y  $P(B) = 0.4$ . Las funciones de probabilidad condicional de las clases vienen caracterizadas por los modelos de Markov:

Modelo  $M_A: P(y \mid A) = P(y \mid M_A)$



Modelo  $M_B: P(y \mid B) = P(y \mid M_B)$



Sea  $y = aab$ . Halla  $P(y \mid c)$  y  $P(c \mid y)$  para  $c = A, B$ , y clasifica  $y$  por mínimo error.

## Ejercicio: solución

$$P(y \mid M_A)$$

$$\begin{aligned}
 &= P(aab, q_1 q_2 q_3 = 001 \mid A) \\
 &+ P(aab, q_1 q_2 q_3 = 011 \mid A) \\
 &+ P(aab, q_1 q_2 q_3 = 111 \mid A) \\
 &= (0.8 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &+ (0.8 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &+ (0.2 \cdot 0.2) (0.5 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0544 + 0.0086 + 0.0008 = 0.0638
 \end{aligned}$$

$$P(y \mid M_B)$$

$$\begin{aligned}
 &= P(aab, q_1 q_2 q_3 = 001 \mid B) \\
 &+ P(aab, q_1 q_2 q_3 = 011 \mid B) \\
 &= (1 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &+ (1 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0680 + 0.0108 \\
 &= 0.0788
 \end{aligned}$$

$$P(A \mid y) = \frac{P(y \mid M_A) P(A)}{\sum_{c'} P(y \mid M_{c'}) P(c')} = \frac{0.0638 \cdot 0.6}{0.0638 \cdot 0.6 + 0.0788 \cdot 0.4} = 0.5484$$

$$P(B \mid y) = 1 - P(A \mid y) = 0.4516$$

$$\hat{c}(y) = \operatorname{argmax}_{c=A,B} P(c \mid y) = A$$

## Clasificación sintáctico-estadística mediante Viterbi

En la práctica, las probabilidades condicionales de las clases suelen aproximarse mediante Viterbi. Consideremos el ejercicio de la página 30:

$$\tilde{P}(y \mid M_A)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid A), \\ P(aab, q_1 q_2 q_3 = 011 \mid A), \\ P(aab, q_1 q_2 q_3 = 111 \mid A))$$

$$= \max(0.0544, 0.0086, 0.0008)$$

$$= 0.0544$$

$$\tilde{P}(y \mid M_B)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid B), \\ P(aab, q_1 q_2 q_3 = 011 \mid B))$$

$$= \max(0.0680, 0.0108)$$

$$= 0.0680$$

$$\tilde{P}(A \mid y) = \frac{\tilde{P}(y \mid M_A) P(A)}{\sum_{c'} \tilde{P}(y \mid c') P(c')} = \frac{0.0544 \cdot 0.6}{0.0544 \cdot 0.6 + 0.0680 \cdot 0.4} = 0.5455$$

$$\tilde{P}(B \mid y) = 1 - \tilde{P}(A \mid y) = 0.4545$$

$$\tilde{c}(y) = \operatorname{argmax}_{c=A,B} \tilde{P}(c \mid y) = A \quad \text{resultado idéntico al de la página 30}$$