

Sistemas Inteligentes

Escuela Técnica Superior de Informática
Universitat Politècnica de València

Tema B2.T6:
Programación dinámica.
Algoritmo *Forward*.
Algoritmo de Viterbi.

Índice

- 1 *Clasificación sintáctico-estadística* ▷ 1
- 2 Algoritmo Forward ▷ 5
- 3 Algoritmo de Viterbi ▷ 11
- 4 Apéndice: cálculos en clasificación estadística (resumen) ▷ 20

Clasificación sintáctico-estadística

Suponemos C clases de objetos, representados como cadenas de Σ^+ . Planteamiento similar al de la clasificación estadística en el caso vectorial:

- **Probabilidad a priori** de una clase c : $P(c)$, $1 \leq c \leq C$
- **Probabilidad condicional** de la clase c : $P(y \mid M_c)$, función de probabilidad que modela la distribución de las cadenas de c en Σ^* mediante un modelo de Markov M_c .
- **Probabilidad a posteriori** de la clase c : $P(c \mid y)$

$$P(c \mid y) = \frac{P(y \mid M_c)P(c)}{P(y)} \quad \text{donde} \quad P(y) = \sum_{c'=1}^C P(y \mid M_{c'})P(c')$$


- **Regla de clasificación**: Una cadena $y \in \Sigma^+$ se asigna a la clase $\hat{c}(y)$:

$$\hat{c}(y) = \operatorname{argmax}_{1 \leq c \leq C} P(c \mid y)$$


Clasificación sintáctico-estadística: ejercicio

Se tiene un problema de clasificación en dos clases (A y B) de objetos representados mediante cadenas de símbolos en el alfabeto $\Sigma = \{a, b\}$. Las probabilidades a priori de las clases son $P(A) = 0.6$ y $P(B) = 0.4$. Las funciones de probabilidad condicional de las clases vienen caracterizadas por los modelos de Markov:

Modelo $M_A: P(y \mid A) = P(y \mid M_A)$



Modelo $M_B: P(y \mid B) = P(y \mid M_B)$



Sea $y = aab$. Halla $P(y \mid c)$ y $P(c \mid y)$ para $c = A, B$, y clasifica y por mínimo error.

Ejercicio: solución

$$P(y \mid M_A)$$

$$\begin{aligned}
 &= P(aab, q_1 q_2 q_3 = 001 \mid A) \\
 &+ P(aab, q_1 q_2 q_3 = 011 \mid A) \\
 &+ P(aab, q_1 q_2 q_3 = 111 \mid A) \\
 &= (0.8 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &+ (0.8 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &+ (0.2 \cdot 0.2) (0.5 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0544 + 0.0086 + 0.0008 = 0.0638
 \end{aligned}$$

$$P(y \mid M_B)$$

$$\begin{aligned}
 &= P(aab, q_1 q_2 q_3 = 001 \mid B) \\
 &+ P(aab, q_1 q_2 q_3 = 011 \mid B) \\
 &= (1 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &+ (1 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0680 + 0.0108 \\
 &= 0.0788
 \end{aligned}$$

$$P(A \mid y) = \frac{P(y \mid M_A) P(A)}{\sum_{c'} P(y \mid M_{c'}) P(c')} = \frac{0.0638 \cdot 0.6}{0.0638 \cdot 0.6 + 0.0788 \cdot 0.4} = 0.5484$$

$$P(B \mid y) = 1 - P(A \mid y) = 0.4516$$

$$\hat{c}(y) = \operatorname{argmax}_{c=A,B} P(c \mid y) = A$$

Índice

- 1 Clasificación sintáctico-estadística ▷ 1
- 2 *Algoritmo Forward* ▷ 5
- 3 Algoritmo de Viterbi ▷ 11
- 4 Apéndice: cálculos en clasificación estadística (resumen) ▷ 20

Algoritmo Forward

Definimos $\alpha(q, t)$ como la probabilidad de que un modelo oculto de Markov M genere el prefijo $y_1 \cdots y_t$, alcanzando el estado q en el instante t :

$$\alpha(q, t) = \sum_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \cdots y_t, q_1, \dots, q_t)$$

$\alpha(q, t)$ puede calcularse recursivamente:

$$\begin{aligned} \alpha(q, t) &= \sum_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \cdots y_t, q_1, \dots, q_t) \\ &= \sum_{\substack{q_1, \dots, q_{t-1} \\ q' \in Q \\ q_{t-1} = q'}} P(y_1 \cdots y_{t-1}, q_1, \dots, q_{t-1}) A_{q', q} B_{q, y_t} \\ &= \sum_{q' \in Q} \sum_{\substack{q_1, \dots, q_{t-1} \\ q_{t-1} = q'}} P(y_1 \cdots y_{t-1}, q_1, \dots, q_{t-1}) A_{q', q} B_{q, y_t} \\ &= \sum_{q' \in Q} \alpha(q', t-1) A_{q', q} B_{q, y_t} \end{aligned}$$

Algoritmo Forward (cont.)

$$\text{En general: } \alpha(q, t) = \begin{cases} \pi_q B_{q, y_1} & \text{si } t = 1 \\ \sum_{q' \in Q} \alpha(q', t-1) A_{q', q} B_{q, y_t} & \text{si } t > 1 \end{cases}$$


La probabilidad de la cadena $P(y \mid M)$:

$$P(y \mid M) = \sum_{q \in Q} \alpha(q, |y|) A_{q, F}$$

- La función $\alpha()$ puede representarse como una matriz: $\alpha_{q,t} \equiv \alpha(q, t)$.
- Esta matriz define un *grafo multietapa* denominado *trellis* y permite el *cálculo iterativo eficiente* de $\alpha(q, |y|)$ *por Programación Dinámica*.
- Complejidad temporal del algoritmo: $O(mb)$, donde m es la longitud de la cadena y b es el número de transiciones entre estados.

Algoritmo Forward: ejemplo

b c b a



Algoritmo forward: ejercicio

Sea M un modelo con:

$$Q = \{1, 2, 3, F\}$$

$$\Sigma = \{a, b, c\}$$

$$\pi_1 = \pi_2 = \frac{1}{2}, \pi_3 = 0$$

A	1	2	3	F
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	0
3	0	0	$\frac{1}{2}$	$\frac{1}{2}$

B	a	b	c
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
3	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

1. Aplica el algoritmo forward a la cadena abc .

Ejercicio: resolución directa

α	a $t = 1$	b $t = 2$	c $t = 3$	
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{3} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{5}{144}$	$\frac{5}{144} \cdot \frac{1}{4} \cdot \frac{1}{6} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{6} +$ $\frac{5}{96} \cdot 0 \cdot \frac{1}{6} = \frac{13}{3456}$	
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{24}$	$\frac{5}{144} \cdot \frac{1}{2} \cdot \frac{1}{2} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{2} +$ $\frac{5}{96} \cdot 0 \cdot \frac{1}{2} = \frac{1}{76}$	
3		$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{2} +$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{5}{96}$	$\frac{5}{144} \cdot \frac{1}{4} \cdot \frac{1}{4} +$ $\frac{1}{24} \cdot \frac{1}{3} \cdot \frac{1}{4} +$ $\frac{5}{96} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{7}{576}$	
F				$\frac{13}{3456} \cdot 0 +$ $\frac{1}{76} \cdot 0 +$ $\frac{7}{576} \cdot \frac{1}{2} = \frac{7}{1152}$

Índice

- 1 Clasificación sintáctico-estadística ▷ 1
- 2 Algoritmo Forward ▷ 5
- 3 *Algoritmo de Viterbi* ▷ 11
- 4 Apéndice: cálculos en clasificación estadística (resumen) ▷ 20

Aproximación de Viterbi a $P(y | M)$

Dado un modelo oculto de Markov $M = (Q, \Sigma, \pi, A, B)$ con estado final F , y una cadena $y = y_1 \cdots y_m \in \Sigma^+$, la probabilidad de que M genere y es:

$$P(y | M) = \sum_{z \in Q^+} P(y, z) = \sum_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

Una aproximación a $P(y | M)$ es la llamada *aproximación de Viterbi*:

$$\tilde{P}(y | M) = \max_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

La correspondiente *secuencia de estados más probable* es:

$$\tilde{q} = (\tilde{q}_1, \dots, \tilde{q}_m) = \operatorname{argmax}_{q_1, \dots, q_m \in Q^+} P(y, q_1, \dots, q_m)$$

Algoritmo de Viterbi

Definimos $V(q, t)$ como la probabilidad máxima de que un modelo oculto de Markov M alcance el estado q en el instante t , emitiendo el prefijo $y_1 \dots y_t$:

$$V(q, t) = \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t)$$

$V(q, t)$ puede calcularse recursivamente:

$$\begin{aligned} V(q, t) &= \max_{\substack{q_1, \dots, q_t \\ q_t = q}} P(y_1 \dots y_t, q_1, \dots, q_t) \\ &= \max_{q' \in Q} \max_{\substack{q_1, \dots, q_{t-1} \\ q_{t-1} = q'}} P(y_1 \dots y_{t-1}, q_1, \dots, q_{t-1}) \cdot A_{q', q} B_{q, y_t} \\ &= \max_{q' \in Q} V(q', t-1) \cdot A_{q', q} B_{q, y_t} \end{aligned}$$

En general:

$$V(q, t) = \begin{cases} \pi_q B_{q, y_1} & \text{si } t = 1 \\ \max_{q' \in Q} V(q', t-1) A_{q', q} B_{q, y_t} & \text{si } t > 1 \end{cases}$$

Algoritmo de Viterbi (cont.)

Aproximación de Viterbi a $P(y | M)$:

$$\tilde{P}(y | M) = \max_{q \in Q} V(q, |y|) A_{q,F}$$

- La función $V()$ puede representarse como una matriz: $V_{q,t} \equiv V(q, t)$.
- Esta matriz define un *grafo multietapa* denominado *trellis* y permite el *cálculo iterativo eficiente* de $V(q, |y|)$ por *Programación Dinámica*.
- La correspondiente secuencia óptima de estados, \tilde{q} , se calcula recorriendo el *trellis* hacia atrás.
- Complejidad temporal del algoritmo: $O(mb)$, donde m es la longitud de la cadena y b es el número de transiciones entre estados.


Algoritmo de Viterbi: ejemplo

b

c

b

a



Algoritmo de Viterbi: ejercicio

Sea M un modelo con:

$$Q = \{1, 2, 3, F\}$$

$$\Sigma = \{a, b, c\}$$

$$\pi_1 = \pi_2 = \frac{1}{2}, \pi_3 = 0$$

A	1	2	3	F
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$	0
3	0	0	$\frac{1}{2}$	$\frac{1}{2}$

B	a	b	c
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
3	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$



1. Halla el *trellis* para la cadena abc .
2. Obtén la secuencia óptima de estados asociada.

Ejercicio: resolución directa

V	a $t = 1$	b $t = 2$	c $t = 3$	
1	$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$	$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{3} = \frac{1}{48}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{72}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{6} = \frac{1}{1152}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{6} = \frac{1}{576}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{6} = 0$	
2	$\frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}$	$\frac{1}{4} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{96}$	$\frac{1}{48} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{192}$ $\frac{1}{32} \cdot 0 \cdot \frac{1}{2} = 0$	
3		$\frac{1}{4} \cdot \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{32}$ $\frac{1}{8} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{48}$	$\frac{1}{48} \cdot \frac{1}{4} \cdot \frac{1}{4} = \frac{1}{768}$ $\frac{1}{32} \cdot \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{384}$ $\frac{1}{32} \cdot \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{256}$	
F				$\frac{1}{576} \cdot 0 = 0$ $\frac{1}{192} \cdot 0 = 0$ $\frac{1}{256} \cdot \frac{1}{2} = \frac{1}{512}$

$$\tilde{Q} = (1, 3, 3, F)$$

Ejercicio: resolución gráfica



Clasificación sintáctico-estadística mediante Viterbi

En la práctica, las probabilidades condicionales de las clases suelen aproximarse mediante Viterbi. Consideremos el ejercicio de la página 4:

$$\tilde{P}(y \mid M_A)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid A), \\ P(aab, q_1 q_2 q_3 = 011 \mid A), \\ P(aab, q_1 q_2 q_3 = 111 \mid A))$$

$$= \max(0.0544, 0.0086, 0.0008)$$

$$= 0.0544$$

$$\tilde{P}(y \mid M_B)$$

$$= \max(P(aab, q_1 q_2 q_3 = 001 \mid B), \\ P(aab, q_1 q_2 q_3 = 011 \mid B))$$

$$= \max(0.0680, 0.0108)$$

$$= 0.0680$$

$$\tilde{P}(A \mid y) = \frac{\tilde{P}(y \mid M_A) P(A)}{\sum_{c'} \tilde{P}(y \mid c') P(c')} = \frac{0.0544 \cdot 0.6}{0.0544 \cdot 0.6 + 0.0680 \cdot 0.4} = 0.5455$$

$$\tilde{P}(B \mid y) = 1 - \tilde{P}(A \mid y) = 0.4545$$

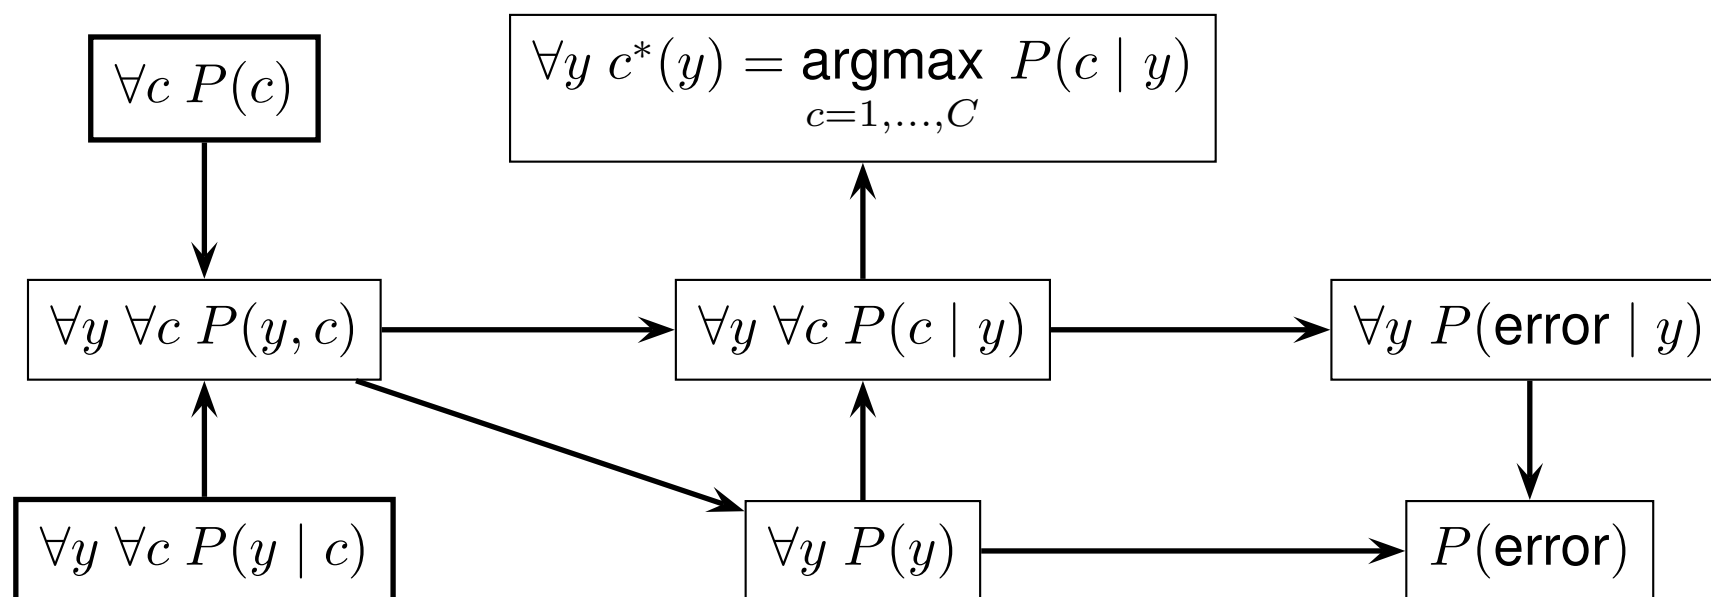
$$\tilde{c}(y) = \operatorname{argmax}_{c=A,B} \tilde{P}(c \mid y) = A \quad \text{resultado idéntico al de la página 4}$$

Índice

- 1 Clasificación sintáctico-estadística ▷ 1
- 2 Algoritmo Forward ▷ 5
- 3 Algoritmo de Viterbi ▷ 11
- 4 *Apéndice: cálculos en clasificación estadística (resumen)* ▷ 20

Apéndice: cálculos en clasificación estadística (resumen)

La aproximación estadística a la clasificación de objetos representados mediante vectores de características es igualmente válida para objetos representados mediante cadenas de símbolos de un alfabeto dado ($y \in \Sigma^+$):



Ejercicio:

- Pon nombres y ecuaciones de cálculo a los nodos del esquema.
- Calcula $P(c)$ a partir de $P(y, c) \forall y$.
- Calcula $P(y | c)$ a partir de $P(y, c)$ y $P(c)$.
- Calcula $P(y, c)$ a partir de $P(c | y)$ y $P(y)$.

Ejercicio: solución

$$P(c)$$

Probabilidad a priori de la clase c

$$P(y \mid c)$$

(Función de prob.) condicional de la clase c

$$P(y, c) = P(c) P(y \mid c)$$

(Función de) probabilidad conjunta

$$P(y) = \sum_{c=1, \dots, C} P(y, c)$$

(Función de) probabilidad incondicional

$$P(c \mid y) = \frac{P(c) P(y \mid c)}{P(y)}$$

Probabilidad a posteriori de la clase c (para y)

$$c^*(y) = \operatorname{argmax}_{c=1, \dots, C} P(c \mid y)$$

Clasificador (regla de decisión) de Bayes

$$P(\text{error} \mid y) = 1 - \max_{c=1, \dots, C} P(c \mid y)$$

Error de Bayes local (a posteriori)

$$P(\text{error}) = \sum_{y \in \Sigma^+} P(y) P(\text{error} \mid y)$$

Error de Bayes (global o a priori)

$$P(c) = \sum_{y \in \Sigma^+} P(y, c) \quad P(y \mid c) = \frac{P(y, c)}{P(c)} \quad P(y, c) = P(y) P(y \mid c)$$