

Sistemas Inteligentes

Cuestiones y ejercicios del bloque 2, temas 5, 6 y 7

Modelos de Markov

Escola Tècnica Superior d'Informàtica
Dep. de Sistemes Informàtics i Computació
Universitat Politècnica de València


10 de noviembre de 2014

1. Cuestiones

1.1. Modelos de Markov: definición, topologías, usos, etc.

- 1 **B** Los siguientes enunciados se refieren al clasificador basado en modelos de Markov. ¿Cuál de ellos es incorrecto?
- A) Puede verse como una particularización del clasificador de Bayes para cadenas, en la que las funciones de probabilidad condicionales de las clases vienen dadas por modelos de Markov.
 - B) En reconocimiento por Viterbi, aplicaremos la regla de Bayes sustituyendo probabilidades exactas por aproximaciones de Viterbi; esto es, la cadena a clasificar se asignará a la clase cuyo modelo obtenga mayor probabilidad de generarla según el algoritmo de Viterbi.
 - C) En aprendizaje por Viterbi, aplicaremos el algoritmo de re-estimación por Viterbi en cada clase por separado. Cada modelo tendrá una probabilidad comparativamente alta de generar las cadenas de entrenamiento de su clase.
 - D) Un problema de diseño crucial será la elección del número de estados y topología de cada modelo de Markov. Asimismo, tendremos que escoger un criterio adecuado de inicialización para el algoritmo de re-estimación por Viterbi.
- 2 **C** Identifica el enunciado incorrecto: los modelos de Markov...
- A) son equivalentes a las gramáticas regulares estocásticas.
 - B) son adecuados para procesos unidimensionales variantes con el tiempo.
 - C) no son aplicables a tareas de OCR ya que las imágenes son objetos bidimensionales.
 - D) son útiles en reconocimiento del habla para lo que generalmente se usan topologías izquierda-derecha.


- 3 **D** Sean M un modelo de Markov de representación gráfica:



¿Cuántas cadenas distintas de longitud 3 puede generar M ?


- A) Ninguna.
 - B) Entre 1 y 3.
 - C) Entre 3 y 6.
 - D) Más de 6.
- 4 **C** Sea M un modelo de Markov de probabilidades de transición no nulas, $A_{q,q'} > 0$, para todo estado no final q y todo estado q' (incluido el final). Decimos que la topología de M es...
- A) Lineal.
 - B) Estrictamente lineal.
 - C) Ergódica.
 - D) No se puede decir nada mientras no conozcamos también las probabilidades iniciales y las de emisión.

5 **C** Sean M un modelo de Markov de representación gráfica:



- A) No puede generar la cadena $abaa$.
- B) Existe más de un camino que genera la cadena $aaabaa$.
- C) Existe sólo un camino que genera la cadena $bbaa$.
- D) No puede generar cadenas de longitud mayor que 5 y que empiecen por b .

6 **C** Sean M un modelo de Markov de representación gráfica:



- A) No puede generar cadenas que empiecen por el símbolo a
- B) Existe sólo un camino que genera la cadena $bbaa$
- C) Existe sólo un camino que genera la cadena $baba$
- D) No puede generar cadenas de longitud mayor que 5 y que empiecen por a

7 **D** Sea M un modelo de Markov, con conjunto de estados $Q = \{1, 2, \dots, F\}$, de probabilidades de transición no nulas, $A_{q,q'} > 0$ si y solo si $q < q'$, para todo estado no final q y todo estado q' (incluido el final q_F , $q_F > q, \forall q$). Además se tiene que $\pi_1 = 1$. Decimos que la topología de M es...

- A) Lineal.
- B) Estrictamente lineal.
- C) Ergódica.
- D) Izquierda-derecha

8 **C** Los siguientes enunciados se refieren al clasificador basado en modelos de Markov. ¿Cuál de ellos es incorrecto?

- A) Un problema de diseño crucial será la elección del número de estados y topología de cada modelo de Markov.
- B) Puede verse como una particularización del clasificador de Bayes para cadenas, en la que las funciones de probabilidad condicionales de las clases vienen dadas por modelos de Markov.
- C) En reconocimiento por Viterbi, aplicaremos la regla de Bayes y la cadena a clasificar se asignará a la clase cuyo modelo la genere con mayor probabilidad, según la aproximación de Viterbi.
- D) En aprendizaje por Viterbi, aplicaremos el algoritmo de re-estimación por Viterbi en cada clase por separado. Este algoritmo garantiza que la verosimilitud de las muestras de entrenamiento no decrece en las sucesivas iteraciones

1.2. Modelos de Markov: probabilidad de (generar) una cadena y aproximación de Viterbi

1 **C** Identifica el enunciado incorrecto: dado un modelo de Markov M y una cadena $x \in \Sigma^*$, la probabilidad $P(x|M)$ es...

- A) igual a la suma de probabilidades de analizar x mediante todos los caminos posibles para x en M .
- B) igual a 0 si \bar{x} no se puede analizar mediante M .
- C) menor que $P(xa|M)$ para cualquier $a \in \Sigma$.
- D) siempre mayor que $\hat{P}(x|M)$ (aproximación de Viterbi).

2 **B** Los siguientes enunciados se refieren a la aproximación por Viterbi a la probabilidad de que un modelo de Markov genere una cadena dada, $\tilde{P}(y|M)$,

- A) $\tilde{P}(y|M)$ es siempre mayor que 0.
- B) $\tilde{P}(y|M)$ es menor que la verdadera probabilidad de generación de la cadena, $P(y|M)$.
- C) $\tilde{P}(y|M)$ tiene mucho interés porque es una probabilidad muy cercana a 1.
- D) El coste de calcular $\tilde{P}(y|M)$ es exponencial con el número de estados del modelo.

3 **B** Sea el siguiente modelo de Markov M : $Q = \{1, 2, F\}$, $\pi_1 = 0$, $\pi_2 = 1$, $\Sigma = \{a, b\}$,

A	1	2	F	B	a	b
1	0.2	0.8	0.0	1	0	1
2	0.1	0.7	0.2	2	1	0

Calcula $P(aba|M)$ e indica el resultado:

- A) 0.128
- B) 0.016
- C) 0.002
- D) 0.0

4 **A** Los siguientes enunciados se refieren a la aproximación por Viterbi $\tilde{P}(y|M)$ a la probabilidad $P(y|M)$ con que un modelo de Markov genere una cadena dada. Indica cuál es correcto.

- A) $\tilde{P}(y|M) \leq P(y|M)$
- B) $\tilde{P}(y|M) \approx P(y|M)$
- C) $\tilde{P}(y|M) \approx 1$
- D) $\tilde{P}(y|M)$ tiene mucho interés ya que su coste computacional es polinómico con el número de estados del modelo, mientras que el coste de calcular $P(y|M)$ es exponencial en el peor de los casos.

5 **C** Sea el siguiente modelo de Markov M : $Q = \{1, 2, F\}$, $\pi_1 = 0$, $\pi_2 = 1$, $\Sigma = \{a, b\}$,

A	1	2	F	B	a	b
1	0.2	0.8	0.0	1	0	1
2	0.1	0.7	0.2	2	1	0

Calcula $P(abba|M)$ e indica el resultado:

- A) 0.0128
- B) 0.0016
- C) 0.0032
- D) 0.0

6 **D** Sea el siguiente modelo de Markov M : $Q = \{1, 2, F\}$, $\pi_1 = 0$, $\pi_2 = 1$, $\Sigma = \{a, b\}$,

A	1	2	F	B	a	b
1	0.4	0.6	0.0	1	0	1
2	0.5	0.4	0.1	2	1	0

Calcula $P(aba|M)$ e indica en qué intervalo de los siguientes se halla:

- A) Menor que 0.001.
- B) Mayor que 0.001 y menor que 0.005.
- C) Mayor que 0.005 y menor que 0.010.
- D) Mayor que 0.010.

7 **D** Sea p la probabilidad con la que un modelo de Markov genera cierta cadena x y q la correspondiente aproximación de Viterbi. Se puede afirmar que:

- A) $p < q$ en cualquier caso.
- B) $p > q$ si y solo si x es suficientemente corta.
- C) $p \leq q$ si y solo si x es suficientemente larga.
- D) $p \geq q$ en cualquier caso.

8 **B** Sean M un modelo de Markov de alfabeto Σ , $x \in \Sigma^*$ una cadena arbitraria, $p_M(x)$ la probabilidad de que M genere x y $\tilde{p}_M(x)$ la aproximación de Viterbi a $p_M(x)$. Se cumple que:

- A) $\tilde{p}_M(x)$ es siempre menor que $p_M(x)$.
- B) $\tilde{p}_M(x)$ es menor que $p_M(x)$ cuando en M existe más de un camino que genera x ; es igual cuando sólo existe un camino generador de x .
- C) $\tilde{p}_M(x)$ es siempre menor o igual que $p_M(x)$, pero el ser una cosa u otra no depende del número de caminos distintos que generan x .
- D) Ninguna de las anteriores.

9 [D] La probabilidad exacta de que un modelo de Markov M genere una cadena $x \dots$

- A) no se suele calcular ya que su coste de cálculo es al menos exponencial con la longitud de x .
- B) se calcula mediante el algoritmo de Viterbi.
- C) se calcula mediante el algoritmo de re-estimación por Viterbi.
- D) Ninguna de las anteriores.

10 [D] La aproximación por Viterbi a la probabilidad exacta de que un modelo de Markov M genere una cadena x , $\hat{P}(x | M)$:


- A) Sólo se puede calcular en modelos de Markov de topología lineal o ergódica.
- B) Siempre sera mayor o igual que la verdadera probabilidad $P(x | M)$.
- C) Siempre sera menor que la verdadera probabilidad $P(x | M)$.
- D) Será nula sólo si la probabilidad $P(x, z | M)$ también es nula para cualquier secuencia de estados z .

11 [D] La aproximación por Viterbi a la probabilidad exacta de que un modelo de Markov M genere una cadena x , $\hat{P}(x | M)$:

- A) Será nula si la probabilidad $P(x, z | M)$ es nula para una secuencia cualquiera de las secuencias de estados z .
- B) Siempre sera mayor o igual que la verdadera probabilidad $P(x | M)$.
- C) Será no nula sólo si la probabilidad $P(x, z | M)$ es no nula para toda secuencia de estados z .
- D) Siempre sera menor o igual que la verdadera probabilidad $P(x | M)$.

12 [C] Sea M el modelo de Markov representado en la figura a la derecha. Considérese una cadena arbitraria de longitud T , $x = x_1 x_2 \dots x_T \in \{a, b\}^T$, la probabilidad de que M la genere, $p_M(x)$, así como la aproximación de Viterbi a esta probabilidad, $\tilde{p}_M(x)$. Entonces:

- A) $p_M(x) = \tilde{p}_M(x)$
- B) $\frac{\tilde{p}_M(x)}{p_M(x)} < 1$, aumentando esta relación al aumentar T
- C) $\frac{\tilde{p}_M(x)}{p_M(x)} < 1$, disminuyendo esta relación al aumentar T
- D) Ninguna de los anteriores



13 [C] Sea el siguiente modelo de Markov M : $Q = \{1, 2, F\}$, $\pi_1 = 0$, $\pi_2 = 1$, $\Sigma = \{a, b\}$,

A	1	2	F
1	0.2	0.8	0.0
2	0.1	0.7	0.2


B	a	b
1	0	1
2	1	0

Calcula $P(abba|M)$:

- A) 0.0128
- B) 0.0016
- C) 0.0032
- D) 0.0

14 [D] Sea M el modelo de Markov representado en la figura de la derecha. Sea $\tilde{P}(y | M)$ la aproximación por Viterbi a la verdadera probabilidad $P(y | M)$. Cuál de las siguientes afirmaciones es cierta:

- A) $\tilde{P}(a^n b^n | M) < P(a^n b^n | M), n > 0$
- B) $P(a^n | M) > 0, n > 0$
- C) $P(b^n | M) > 0, n > 0$
- D) $\tilde{P}((abab)^n | M) = P((abab)^n | M), n > 0$



15 [B] Los siguientes enunciados se refieren a la aproximación por Viterbi a la probabilidad de que un modelo de Markov M genere una cadena y , $\tilde{P}(y|M)$, indica cuál de las siguientes afirmaciones es verdadera:

- A) $\tilde{P}(y|M)$ es siempre mayor que 0
- B) $\tilde{P}(y|M)$ nunca es mayor que la verdadera probabilidad de generación de la cadena, $P(y|M)$
- C) $\tilde{P}(y|M)$ nunca puede llegar a 1
- D) El coste de calcular $\tilde{P}(y|M)$ es exponencial con el número de estados del modelo, pero mediante técnicas de programación dinámica el coste es lineal con el número de estados de M para cualquier M

16 [A] Sea $P(y)$ la probabilidad con que un modelo de Markov genere una cadena dada y sea $\tilde{P}(y)$ la aproximación de Viterbi a $P(y)$. ¿Cuál de los siguientes enunciados es cierto?

- A) $\tilde{P}(y) \leq \sum_z P(z)P(y|z) = P(y)$, donde z denota una secuencia de estados del modelo
- B) $\tilde{P}(y) > 0 \forall y$
- C) $\tilde{P}(y) \approx 0$
- D) El coste de calcular $\tilde{P}(y)$ es cuadrático con la longitud (número de símbolos) de y

17 [B] Sea \mathcal{M} un modelo de Markov ergódico con $Q = \{1, 2, F\}$, $\Sigma = \{a, b\}$, y probabilidades equiprobables de *estado inicial*, de *transición* y de *generación*.

Calcula $P(\text{"ab"} | \mathcal{M})$:

- A) 0.0333
- B) 1/18
- C) 1/3
- D) 4/27


18 [D] ¿Cuál de los siguientes enunciados sobre la aproximación por Viterbi, $\tilde{P}(y|M)$, a la probabilidad de que un modelo de Markov genere una cadena dada es correcto?

- A) $\tilde{P}(y|M)$ es siempre mayor que 0
- B) $\tilde{P}(y|M)$ tiene mucho interés porque es una probabilidad muy cercana a 1
- C) El coste de calcular $\tilde{P}(y|M)$ es exponencial con el número de estados del modelo
- D) $\tilde{P}(y|M)$ es siempre algo menor o igual que la verdadera probabilidad de generación de la cadena, $P(y|M)$

19 [A] (Examen de SIN del 18 de enero de 2013)

Al analizar la cadena *aabb* con el modelo de Markov adjunto, ¿Cuál es la probabilidad de generación de la cadena por el modelo y cuál es la probabilidad de generar la cadena por la mejor secuencia de estados en el modelo?:


- A) Total 0.00225; mejor camino 0.00225.
- B) Total 0.0045; mejor camino 0.00225.
- C) Total 0.00225; mejor camino 0.000225.
- D) Total 0.00225; mejor camino 0.0045.




20 [B] (Examen de SIN del 18 de enero de 2013)

Dados los dos modelos ocultos de Markov M_1 y M_2 siguientes:

Modelo M_1



Modelo M_2



¿Qué modelo producirá la mayor probabilidad para la cadena "aaaabb"? ¿Y para "aaab"?

- A) Los dos modelos igual para cada una de las cadenas.
- B) M_1 para la primera y M_2 para la segunda.
- C) M_2 para la primera y M_1 para la segunda.
- D) M_1 para las dos cadenas.


21 **C** (Examen de SIN del 15 de enero de 2014; examen del bloque 2; cuestión 15)

Dado un Modelo Oculto de Markov Θ y una cadena y reconocida por dicho modelo, indica cuál de las siguientes afirmaciones es cierta:

- A) Siempre se cumple que $P(y|\Theta) = \tilde{P}(y|\Theta)$.
- B) Siempre se cumple que $P(y|\Theta) \leq \tilde{P}(y|\Theta)$.
- C) Siempre se cumple que $P(y|\Theta) \geq \tilde{P}(y|\Theta)$.
- D) Siempre se cumple que $P(y|\Theta) \neq \tilde{P}(y|\Theta)$.

22 **C** (Examen de SIN del 15 de enero de 2014; examen del bloque 2; cuestión 16)

Dado el Modelo Oculto de Markov Θ



con $\pi_{q_1} = 1, \pi_{q_2} = \pi_{q_3} = \pi_{q_4} = 0$ y las cadenas $y_1 = \text{"babb"}$ y $y_2 = \text{"aaaa"}$, indica cuál de las siguientes afirmaciones es cierta:

- A) $P(y_1|\Theta) = P(y_2|\Theta)$.
- B) $P(y_1|\Theta) < P(y_2|\Theta)$.
- C) $P(y_1|\Theta) > P(y_2|\Theta)$.
- D) $P(y_1|\Theta) = P(y_2|\Theta) = 0$.

23 **C** (Examen de SIN del 15 de enero de 2014; examen del bloque 2; cuestión 18)

En relación al algoritmo *forward* definido para Modelos Ocultos de Markov indica cuál de la siguientes afirmaciones es verdadera:

- A) Calcula la probabilidad de una cadena teniendo en cuenta sólo la secuencia de análisis de máxima probabilidad.
- B) Calcula la probabilidad de una cadena sin incluir la probabilidad de la secuencia de estados más probable.
- C) Calcula la probabilidad de una cadena incluyendo todas las secuencias de estados.
- D) Nunca calcula la probabilidad de una cadena.

24 **B** (Examen de SIN del 28 de enero de 2014; examen final; cuestión 6)

Dado un Modelo Oculto de Markov Θ y una cadena y aceptada por dicho modelo, ¿cuál de las siguientes afirmaciones sobre los algoritmos *forward* y Viterbi es verdadera?


- A) *Forward* y Viterbi calculan $P(y|\Theta)$.
- B) *Forward* calcula $P(y|\Theta)$ y Viterbi $\tilde{P}(y|\Theta)$.
- C) *Forward* calcula $\tilde{P}(y|\Theta)$ y Viterbi $P(y|\Theta)$.
- D) *Forward* y Viterbi calculan $\tilde{P}(y|\Theta)$.

1.3. Modelos de Markov: re-estimación por Viterbi

1 **C** (Examen de SIN del 30 de enero de 2013)

Si se utiliza sólo la cadena *aabb* para entrenar un modelo de Markov partiendo del modelo adjunto, ¿Cuántas iteraciones sin contar la de verificación final dará el algoritmo de estimación por Viterbi?:

- A) Ninguna
- B) 2
- C) 1
- D) 5



2 **D** (Examen de SIN del 15 de enero de 2014; examen del bloque 2; cuestión 17)

Dado el Modelo Oculto de Markov Θ de la cuestión 22 de la sección 1.2, si lo estimamos con una sola iteración con la muestra $Y = \{baba, abab\}$ utilizando el algoritmo de Viterbi indica cuál de las siguientes afirmaciones es cierta:

- A) El modelo estimado tiene todos los parámetros a 0.0.
- B) Ninguna probabilidad de transición entre estados en el modelo estimado toma valor 0.0.
- C) El modelo obtenido tiene todos los parámetros igual al modelo inicial.
- D) El modelo obtenido queda con varios parámetros con valor 0.



2. Problemas

1. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_1 = 0.8, \pi_2 = 0.2, \pi_F = 0.0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	1	2	F
1	0.5	0.5	0
2	0	0.5	0.5

B	a	b
1	0.9	0.1
2	0.1	0.9

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “aabb” y “baab”.



Los pares *cadena-secuencia óptima de estados* a considerar son:

aabb	baab
1122F	1112F

Los parámetros reestimados son:

$$\hat{\pi}_1 = \frac{2}{2} = 1$$

$$\hat{\pi}_2 = \frac{0}{2} = 0$$

A	1	2	F
1	$\frac{3}{5}$	$\frac{2}{5}$	0
2	0	$\frac{1}{3}$	$\frac{2}{3}$


B	a	b
1	$\frac{4}{5}$	$\frac{1}{5}$
2	0	1

2. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, 3, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_1 = 1$, $\pi_2 = \pi_3 = \pi_F = 0$; y probabilidades de transición y de emisión:

A	1	2	3	F
1	0.9	0.1	0.0	0.0
2	0.0	0.9	0.1	0.0
3	0.0	0.0	0.9	0.1

B	a	b
1	0.9	0.1
2	0.1	0.9
3	0.9	0.1

- a) Representa gráficamente el modelo M .



- b) Determina las secuencias de estados que generan cadenas de 4 ó menos símbolos.

Cadenas de menos de 3 de símbolos: no pueden generarse

Cadenas de 3 símbolos: (1, 2, 3)

Cadenas de 4 símbolos: (1, 1, 2, 3), (1, 2, 2, 3) y (1, 2, 3, 3)

- c) Calcula las probabilidades con las que M genera las cadenas “aaa” y “aab”.

$$P(\text{aaa}|M) = (1 \cdot 0.9) (0.1 \cdot 0.1) (0.1 \cdot 0.9) 0.1 = 0.000081$$


$$P(\text{aab}|M) = (1 \cdot 0.9) (0.1 \cdot 0.1) (0.1 \cdot 0.1) 0.1 = 0.000009$$

- d) Calcula la probabilidad de que M genere una cadena de 3 símbolos (arbitraria).

Puede calcularse exhaustivamente, sumando las probabilidades con las que M genera cada una de las 8 cadenas posibles. Más directamente:

$$\begin{aligned} \sum_{x_1 x_2 x_3 \in \Sigma^+} P(x_1 x_2 x_3 | M) &= \sum_{x_1 x_2 x_3 \in \Sigma^+} \pi_1 B_{1,x_1} A_{1,2} B_{2,x_2} A_{2,3} B_{3,x_3} A_{3,F} \\ &= \pi_1 A_{1,2} A_{2,3} A_{3,F} \sum_{x_1 x_2 x_3 \in \Sigma^+} B_{1,x_1} B_{2,x_2} B_{3,x_3} \\ &= 1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 1 = 0.001 \end{aligned}$$

- e) Realiza una traza del algoritmo de Viterbi para obtener la secuencia de estados más probable con la que M genera la cadena “abba”.





3. Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(0) = 0.8, \pi_0(1) = 0.2, \pi_0(F) = 0.0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	0	1	F
0	0.7	0.3	0
1	0	0.5	0.5

B	a	b
0	0.9	0.1
1	0.2	0.8

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “aaabb” y “babb”.



Los pares *cadena-secuencia óptima de estados* a considerar son:

aaabb	babb
00011F	0011F

Los parámetros reestimados son:

$$\hat{\pi}_0(0) = 1$$

$$\hat{\pi}_0(1) = 0$$

A	0	1	F
0	$\frac{3}{5}$	$\frac{2}{5}$	0
1	0	$\frac{2}{4}$	$\frac{2}{4}$


B	a	b
0	$\frac{4}{5}$	$\frac{1}{5}$
1	0	1

4. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, 3, 4, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(1) = \pi_0(2) = \pi_0(4) = \frac{1}{3}$, $\pi_0(3) = \pi_0(F) = 0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	1	2	3	4	F
1	$\frac{1}{2}$	0	0	0	$\frac{1}{2}$
2	0	$\frac{1}{2}$	$\frac{1}{2}$	0	0
3	0	0	$\frac{1}{2}$	0	$\frac{1}{2}$
4	0	0	0	$\frac{1}{2}$	$\frac{1}{2}$

B	a	b
1	1	0
2	1	0
3	0	1
4	0	1

- a) Representa gráficamente el modelo M .



- b) Sean n y m dos enteros positivos. Halla las probabilidades: $P(a^n | M)$, $P(a^n b^m | M)$ y $P(b^n | M)$.

$$P(a^n | M) = \frac{1}{3} \frac{1}{2^n}$$

$$P(a^n b^m | M) = \frac{1}{3} \frac{1}{2^{n+m}}$$

$$P(b^n | M) = \frac{1}{3} \frac{1}{2^n}$$

- c) Calcula la probabilidad de que M genere una cadena cualquiera de longitud 7.
El conjunto de cadenas de longitud 7 que M puede generar es:


$$S = \{a^7, a^6b, a^5b^2, a^4b^3, a^3b^4, a^2b^5, ab^6, b^7\}$$

Cada cadena de S se genera con probabilidad $\frac{1}{3} \frac{1}{2^7}$.

Por tanto,

$$P(x \in S | M) = 8 \frac{1}{3} \frac{1}{2^7} = 0.0208$$

- d) Diseña un modelo de Markov M' de conjunto de estados $Q' = \{1, 2, F\}$ y alfabeto $\Sigma' = \Sigma$ que genere el mismo lenguaje probabilístico que M .





5. Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(0) = 0.5, \pi_0(1) = 0.5, \pi_0(F) = 0.0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	0	1	F
0	0.5	0.4	0.1
1	0.3	0.5	0.2

B	a	b
0	0.6	0.4
1	0.4	0.6

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “bab” y “aba”.



Los pares *cadena-secuencia óptima de estados* a considerar son: $\begin{matrix} \text{bab} & \text{aba} \\ 111F & 011F \end{matrix}$

Los parámetros reestimados son:


$$\hat{\pi}_0(0) = 0.5$$

$$\hat{\pi}_0(1) = 0.5$$

A	0	1	F
0	0	1	0
1	0	$\frac{3}{5}$	$\frac{2}{5}$

B	a	b
0	1	0
1	$\frac{2}{5}$	$\frac{3}{5}$

6. Se tiene un problema de clasificación en dos clases (A y B) de objetos representados mediante cadenas de símbolos en el alfabeto $\Sigma = \{a, b\}$. Las probabilidades a priori de las clases son $P(A) = 0.6$ y $P(B) = 0.4$. Las funciones de probabilidad condicional de las clases vienen caracterizadas por los modelos de Markov:



- a) Calcula las probabilidades de que M_A y M_B generen la cadena “aab”.

$$\begin{aligned}
 P(aab | M_A) &= P(aab, q_1 = 0, q_2 = 0, q_3 = 1 | M_A) \\
 &\quad + P(aab, q_1 = 0, q_2 = 1, q_3 = 1 | M_A) \\
 &\quad + P(aab, q_1 = 1, q_2 = 1, q_3 = 1 | M_A) \\
 &= (0.8 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &\quad + (0.8 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &\quad + (0.2 \cdot 0.2) (0.5 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0544 + 0.0086 + 0.0008 \\
 &= 0.0638
 \end{aligned}$$

$$\begin{aligned}
 P(aab | M_B) &= P(aab, q_1 = 0, q_2 = 0, q_3 = 1 | M_B) \\
 &\quad + P(aab, q_1 = 0, q_2 = 1, q_3 = 1 | M_B) \\
 &= (1 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.8) 0.5 \\
 &\quad + (1 \cdot 0.9) (0.3 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.0680 + 0.0108 \\
 &= 0.0788
 \end{aligned}$$

- b) Determina las probabilidades a posteriori de que la cadena “aab” pertenezca a las clases A y B .

$$P(aab | A) P(A) = 0.0638 \cdot 0.6 = 0.0383$$

$$P(aab | B) P(B) = 0.0788 \cdot 0.4 = 0.0315$$

$$P(x) = P(aab | M_A) P(A) + P(aab | M_B) P(B) = 0.0383 + 0.0315 = 0.0698$$

$$P(A | aab) = \frac{P(aab | A) P(A)}{P(x)} = \frac{0.0383}{0.0698} = 0.5487$$

$$P(B | aab) = \frac{P(aab | B) P(B)}{P(x)} = \frac{0.0315}{0.0698} = 0.4513$$

- c) Clasifica la cadena “aab” por mínima probabilidad de error.


$$\omega^*(aab) = \arg \max_{\omega=A,B} P(\omega | aab) = A$$

7. Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(0) = 0.4, \pi_0(1) = 0.6, \pi_0(F) = 0.0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	0	1	F
0	0.5	0.4	0.1
1	0.4	0.5	0.1

B	a	b
0	0.6	0.4
1	0.4	0.6

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “bbab” y “abba”.



Los pares *cadena-secuencia óptima de estados* a considerar son:

bbab	abba
1111F	1110F

Los parámetros reestimados son:

$$\hat{\pi}_0(0) = 0$$

$$\hat{\pi}_0(1) = \frac{2}{2}$$

A	0	1	F
0	0	0	1
1	$\frac{1}{7}$	$\frac{5}{7}$	$\frac{1}{7}$

B	a	b
0	1	0
1	$\frac{2}{7}$	$\frac{5}{7}$


8. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, 3, F\}$; alfabeto $\Sigma = \{a, b, c\}$; probabilidades iniciales $\pi_0(1) = \pi_0(2) = \frac{1}{2}$ y $\pi_0(3) = \pi_0(F) = 0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	1	2	3	F
1	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	0
2	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$	0
3	$\frac{2}{5}$	$\frac{1}{5}$	$\frac{1}{5}$	$\frac{1}{5}$

B	a	b	c
1	$\frac{1}{4}$	$\frac{3}{4}$	0
2	0	$\frac{1}{2}$	$\frac{1}{2}$
3	$\frac{1}{2}$	0	$\frac{1}{2}$

Se pide:


- a) Representa gráficamente el modelo M .



- b) Calcula la probabilidad de que M genere la cadena "bc".

$$p(bc | M) = p(bc, q_1 = 1, q_2 = 3 | M) + p(bc, q_1 = 2, q_2 = 3 | M) = \frac{1}{2} \frac{3}{4} \frac{1}{4} \frac{1}{2} \frac{1}{5} + \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{1}{5} = \frac{3}{640} + \frac{1}{80} = \frac{11}{640}$$

- c) Realiza una iteración del proceso de reestimación por Viterbi. con el conjunto de entrenamiento $R = \{ "bc", "bba" \}$.



Los pares *cadena-secuencia óptima de estados* a considerar son:

bc	bba
23F	123F

Los parámetros reestimados son:

$$\begin{aligned}\pi_0(1) &= \frac{1}{2} \\ \pi_0(2) &= \frac{1}{2} \\ \pi_0(3) &= 0\end{aligned}$$

A	1	2	3	F
1	0	1	0	0
2	0	0	1	0
3	0	0	0	1

B	a	b	c
1	0	1	0
2	0	1	0
3	$\frac{1}{2}$	0	$\frac{1}{2}$


9. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, 3, 4, F\}$; alfabeto $\Sigma = \{a, b, c\}$; probabilidades iniciales $\pi_0(1) = \pi_0(2) = \frac{1}{2}$ y $\pi_0(3) = \pi_0(4) = \pi_0(F) = 0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	1	2	3	4	F
1	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$		
2		$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$	
3			$\frac{2}{3}$	$\frac{1}{3}$	
4				$\frac{1}{2}$	$\frac{1}{2}$


B	a	b	c
1	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$
2	$\frac{2}{7}$	$\frac{3}{7}$	$\frac{2}{7}$
3	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{1}{2}$
4	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

Se pide:

- a) Representa gráficamente el modelo M .



- b) Realiza una iteración del proceso de reestimación por Viterbi con el conjunto de entrenamiento $R = \{ "abc", "aab" \}$.



Los pares *cadena-secuencia óptima de estados* a considerar son: $\begin{matrix} abc & aab \\ 224F & 244F \end{matrix}$

Los parámetros reestimados son:

$$\begin{aligned} \pi_0(2) &= 1 \\ \pi_0(1) &= \pi_0(3) = \pi_0(4) = 0 \end{aligned}$$

A	1	2	3	4	F
1	0	0	0	0	0
2	0	$\frac{1}{3}$	1	$\frac{2}{3}$	0
3	0	0	0	0	0
4	0	0	0	$\frac{1}{3}$	$\frac{2}{3}$


B	a	b	c
1	0	0	0
2	$\frac{2}{3}$	$\frac{1}{3}$	0
3	0	0	0
4	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

10. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.7, \pi_2 = \pi_F = 0, \pi_3 = 0.3$ y las matrices A y B:

A	1	2	3	F
1	0.9	0.1	0.0	0.0
2	0.0	0.7	0.3	0.0
3	0.0	0.0	0.9	0.1

B	a	b
1	0.9	0.1
2	0.2	0.8
3	0.9	0.1

- a) Representa gráficamente el modelo.



- b) Determina cuántas cadenas diferentes, de longitud 3, puede generar \mathcal{M} con probabilidad mayor de cero.
Las posibles secuencias de estados son: $z_1 = "1,2,3,F"$ y $z_2 = "3,3,3,F"$. Como en cada estado se pueden emitir dos símbolos, por cada secuencia de estados se pueden generar $2^3 = 8$ cadenas distintas; sin embargo, estas 8 cadenas serán las mismas en las dos secuencias de estados. Por tanto, el número de cadenas diferentes es 8.
- c) Determina las probabilidades de que \mathcal{M} produzca las secuencias de estados $z_1 = "1,2,3,F"$ y $z_2 = "3,3,3,F"$.

$$Pr("1, 2, 3, F'') = \pi_1 A_{1,2} A_{2,3} A_{3,F} = 0.7 \cdot 0.1 \cdot 0.3 \cdot 0.1 = 0.0021$$

$$Pr("3, 3, 3, F'') = \pi_3 A_{3,3} A_{3,3} A_{3,F} = 0.3 \cdot 0.9 \cdot 0.9 \cdot 0.1 = 0.0243$$

- d) Determina la probabilidad de que \mathcal{M} genere una cadena de longitud 3.

$$\begin{aligned} Pr(x | \text{long}(x) = 3) &= \sum_{i=1}^2 Pr(z_i) \\ &= \pi_1 A_{1,2} A_{2,3} A_{3,F} + \pi_3 A_{3,3} A_{3,3} A_{3,F} \\ &= 0.7 \cdot 0.1 \cdot 0.3 \cdot 0.1 + 0.3 \cdot 0.9 \cdot 0.9 \cdot 0.1 \\ &= 0.0021 + 0.0243 = 0.0264 \end{aligned}$$

- e) Realiza una traza del algoritmo de Viterbi para obtener la secuencia de estados mas probable con la que \mathcal{M} genera la cadena "b a a b".

Valores en los nodos del *trellis*:

	b	a	a	b
1	0.07	0.0567	0.0459	0.00414
2		0.0014	0.0011	0.00368
3	0.03	0.0243	0.0197	0.00177
F				0.000177

Secuencia óptima de estados:


$$\tilde{q} = 3, 3, 3, 3, F$$

11. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.4, \pi_2 = \pi_F = 0, \pi_3 = 0.6$ y las matrices A y B:

A	1	2	3	F
1	0.8	0.2	0.0	0.0
2	0.0	0.9	0.1	0.0
3	0.1	0.0	0.8	0.1

B	a	b
1	0.3	0.7
2	0	1
3	0.6	0.4


- a) Representa gráficamente el modelo.



- b) Determina cuál es la probabilidad de que el modelo genere la cadena "b b b b b a" siguiendo la secuencia de estados 112233F.

$$\begin{aligned}
 p(bbbba|112233F) &= \pi_1 B_{1b} \cdot A_{11} B_{1b} \cdot A_{12} B_{2b} \cdot A_{22} B_{2b} \cdot A_{23} B_{3b} \cdot A_{33} B_{3a} \cdot A_{3F} \\
 &= 0.4 \cdot 0.7 \cdot 0.8 \cdot 0.7 \cdot 0.2 \cdot 1 \cdot 0.9 \cdot 1 \cdot 0.1 \cdot 0.4 \cdot 0.8 \cdot 0.6 \cdot 0.1 \\
 &= 0.00005419
 \end{aligned}$$

- c) Realiza una traza del algoritmo de Viterbi para obtener la secuencia de estados mas probable con la que \mathcal{M} genera la cadena "b b b b b a".



$$\tilde{Q} = (1, 2, 2, 2, 2, 3, F)$$

- d) Determina la probabilidad de que una cadena comience por a.

$$p(x_1 = a) = \pi_1 B_{1a} + \pi_3 B_{3a} = 0.4 \cdot 0.3 + 0.6 \cdot 0.6 = 0.48$$

- e) Determina la probabilidad de que una cadena termine por b.

$$p(x_{|x|} = b) = B_{3b} = 0.4$$

12. En un problema de clasificación en dos clases u y v , cada objeto a clasificar está representado mediante una cadena, y , sobre un alfabeto de dos primitivas; es decir $y \in \Sigma = \{a, b\}$. Las probabilidades a priori de las clases son $P(u) = 0.7$ y $P(v) = 0.3$. Las probabilidades condicionales, $P(y|u)$ y $P(y|v)$, vienen dadas por modelos de Markov de tres estados, $\mathcal{M}_u, \mathcal{M}_v$:

$$\mathcal{M}_u = (Q_u, \Sigma, \pi_u, A_u, B_u), \quad \mathcal{M}_v = (Q_v, \Sigma, \pi_v, A_v, B_v), \quad \text{donde:}$$

$$Q_u = Q_v = \{1, 2, F\}, \quad \pi_u[1] = 0.8, \quad \pi_u[2] = 0.2, \quad \pi_v[1] = 0.2, \quad \pi_v[2] = 0.8$$

$$A_u = A_v = \begin{bmatrix} 0.3 & 0.2 & 0.5 \\ 0 & 0.5 & 0.5 \end{bmatrix}, \quad B_u = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \end{bmatrix}, \quad B_v = \begin{bmatrix} 0.5 & 0.5 \\ 0.6 & 0.4 \end{bmatrix}$$

Dada la cadena $y = abb$,

- a) Calcula la aproximación de Viterbi a las probabilidades de generar y mediante \mathcal{M}_u y \mathcal{M}_v . En ambos casos, realiza una traza del algoritmo de Viterbi y determina la secuencia de estados más probable. En los apartados siguientes supondremos que las aproximaciones calculadas son suficientemente precisas.

$$P(y|u) \approx \tilde{P}(y|\mathcal{M}_u) = 0.0072,$$

$$P(y|v) \approx \tilde{P}(y|\mathcal{M}_v) = 0.0096$$

\mathcal{M}_u	a	b	b	
1	0.40	0.060	0.0090	
2	0.08	0.048	0.0144	
F				0.0072
\hat{z}	1	2	2	F

\mathcal{M}_v	a	b	b	
0	0.10	0.015	0.00225	
1	0.48	0.096	0.01920	
F				0.0096
\hat{z}	2	2	2	F

- b) Halla la probabilidad incondicional de y .

$$P(y) = P(u)P(y|u) + P(v)P(y|v) = 0.00504 + 0.00288 = 0.00792$$

- c) Calcula las probabilidades a posteriori de las clases u y v tras observar y .

$$P(u|y) = P(u)P(y|u)/P(y) = 0.636 \quad P(v|y) = P(v)P(y|v)/P(y) = 0.364$$

- d) Clasifica y mediante la regla de Bayes.

$$\hat{w} = \operatorname{argmax}_{w \in \{u, v\}} P(w|y) = u$$

- e) Determina la probabilidad de que la clasificación del apartado anterior sea errónea.

$$P(\text{error}|y) = 1 - \max_{w \in \{u, v\}} P(w|y) = 0.364$$

13. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.4, \pi_2 = \pi_F = 0, \pi_3 = 0.6$ y las matrices A y B:

A	1	2	3	F
1	0.8	0.2	0.0	0.0
2	0.0	0.4	0.6	0.0
3	0.4	0.0	0.5	0.1

B	a	b
1	0.3	0.7
2	0	1
3	0.6	0.4

- a) Determina la probabilidad de que el modelo genere la cadena $y = \text{"a b b b"}$.

Hay tres secuencias de estados que pueden generar y con probabilidad no nula:

$$z_1 = \langle 3 \ 1 \ 2 \ 3 \rangle, \ z_2 = \langle 1 \ 2 \ 3 \ 3 \rangle, \ z_3 = \langle 1 \ 1 \ 2 \ 3 \rangle.$$

$$P(y, z_1) = 0.000484, \ P(y, z_2) = 0.0001152, \ P(y, z_3) = 0.00013824,$$

$$P(y | \mathcal{M}) = 0.000484 + 0.0001152 + 0.00013824 = 0.00073744.$$

- b) Realiza una traza del algoritmo de Viterbi para determinar la secuencia de estados que con mayor probabilidad genera la cadena y . Obtén también la probabilidad correspondiente (aproximación de Viterbi) y el error con respecto a la probabilidad obtenida en el punto anterior.

y	=	a	b	b	b	
1	0.120000	0.100800	0.056448	0.031611		
2		0.024000	0.020160	0.011290		
3	0.360000	0.072000	0.014400	0.004838		
F					0.000484	
z	=	3	1	2	3	F

$$\tilde{P}(y | \mathcal{M}) = P(y, \langle 3 \ 1 \ 2 \ 3 \rangle) \approx 0.000484$$

$$\text{Error} = 0.00073744 - 0.000484 = 0.00025344 \quad (34\%)$$

- c) Se dispone del siguiente conjunto de cadenas de entrenamiento, Y , cada una de las cuales acompañada de la secuencia de estados con la que ha sido generada por \mathcal{M} con mayor probabilidad (secuencia óptima de Viterbi):

cadenas:	a b b b a	a b b	b b b a	b b a
estados:	3 1 1 2 3	3 3 3	1 1 2 3	1 2 3

Usando estas cadenas (y secuencias de estados) y \mathcal{M} como modelo inicial, realiza una iteración del algoritmo de reestimación de Viterbi para obtener el modelo reestimado \mathcal{M}'

El modelo \mathcal{M}' tiene la misma topología que \mathcal{M} y los siguientes parámetros:

$$\pi_1 = 2/4, \ \pi_2 = \pi_F = 0, \ \pi_3 = 2/4$$

A	1	2	3	F
1	2/5	3/5	0	0
2	0	0	1	0
3	1/7	0	2/7	4/7

B	a	b
1	1/6	5/6
2	1/4	3/4
3	5/7	2/7

- d) Calcula la (aproximación de Viterbi a la) verosimilitud del conjunto de cadenas de entrenamiento con \mathcal{M} .

$$\begin{aligned} \tilde{P}(Y | \mathcal{M}) &= \tilde{P}(abba | \mathcal{M}) \cdot \tilde{P}(abb | \mathcal{M}) \cdot \tilde{P}(bbba | \mathcal{M}) \cdot \tilde{P}(bba | \mathcal{M}) = \\ &= 0.000407 \cdot 0.001440 \cdot 0.001129 \cdot 0.002017 \approx 0.00000000000133 \end{aligned}$$

14. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.4, \pi_2 = \pi_F = 0, \pi_3 = 0.6$ y las matrices A y B:

A	1	2	3	F
1	0.8	0.2	0.0	0.0
2	0.0	0.6	0.3	0.1
3	0.4	0.0	0.5	0.1

B	a	b
1	0.3	0.7
2	0	1
3	0.6	0.4

- a) Determina la probabilidad de que el modelo genere una cadena de longitud 2.

Hay solo dos secuencias de dos estados con probabilidad mayor que cero:

$$z_1 = \langle 1 \ 2 \rangle, \ z_2 = \langle 3 \ 3 \rangle; \ P(z_1) = 0.4 \cdot 0.2 \cdot 0.1 = 0.008, \ P(z_2) = 0.6 \cdot 0.5 \cdot 0.1 = 0.03.$$

Hay cuatro posibles cadenas de $\{a, b\}$ de longitud 2: aa, ab, ba, bb . Por tanto, la probabilidad de que \mathcal{M} genere una cadena de longitud 2 es:

$$\begin{aligned} & P(aa, z_1) + P(aa, z_2) + P(ab, z_1) + P(ab, z_2) + P(ba, z_1) + P(ba, z_2) + P(bb, z_1) + P(bb, z_2) \\ &= 0.008 \cdot 0.3 \cdot 0 + 0.03 \cdot 0.6 \cdot 0.6 + 0.008 \cdot 0.3 \cdot 1 + 0.03 \cdot 0.6 \cdot 0.4 + 0.008 \cdot 0.7 \cdot 0 + 0.03 \cdot 0.4 \cdot 0.6 + 0.008 \cdot 0.7 \cdot 1 + 0.03 \cdot 0.4 \cdot 0.4 \\ &= P(z_1) + P(z_2) = 0.038 \end{aligned}$$

- b) Realiza una traza del algoritmo de Viterbi para determinar la secuencia de estados que con mayor probabilidad genera la cadena $abbb$. Obtén también la probabilidad correspondiente (aproximación de Viterbi).

y	=	a	b	b	b	
1	0.120000	0.100800	0.056448	0.031611		
2		0.024000	0.020160	0.012096		
3	0.360000	0.072000	0.014400	0.002880		
F					0.0012096	
z	=	3	1	2	2	F

$$\tilde{P}(y \mid \mathcal{M}) = P(y, \langle 3 \ 1 \ 2 \ 2 \rangle) \approx 0.00121$$

- c) Se dispone del siguiente conjunto de cadenas de entrenamiento, Y , cada una de las cuales acompañada de la secuencia de estados con la que ha sido generada por \mathcal{M} con mayor probabilidad (secuencia óptima de Viterbi):

cadenas:	a b b b a	a b b	b b b a	b b a
estados:	3 1 2 2 3	3 1 2	1 2 2 3	3 3 3

Usando estas cadenas (y secuencias de estados) y \mathcal{M} como modelo inicial, realiza una iteración del algoritmo de reestimación de Viterbi para obtener el modelo reestimado \mathcal{M}'

El modelo \mathcal{M}' tiene la misma topología que \mathcal{M} y los siguientes parámetros:

$$\pi_1 = 1/4, \ \pi_2 = \pi_F = 0, \ \pi_3 = 3/4$$

A	1	2	3	F
1	0	1	0	0
2	0	2/5	2/5	1/5
3	2/7	0	2/7	3/7

B	a	b
1	1/4	3/4
2	1/6	5/6
3	5/7	2/7

- d) Calcula la (aproximación de Viterbi a la) verosimilitud del conjunto de cadenas de entrenamiento con \mathcal{M} .


$$\begin{aligned} \tilde{P}(Y \mid \mathcal{M}) &= \tilde{P}(abbb \mid \mathcal{M}) \cdot \tilde{P}(abb \mid \mathcal{M}) \cdot \tilde{P}(bbba \mid \mathcal{M}) \cdot \tilde{P}(bba \mid \mathcal{M}) = \\ &0.000218 \cdot 0.00144 \cdot 0.000605 \cdot 0.00144 \approx .0000000000002734871 \end{aligned}$$

15. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.4, \pi_2 = \pi_F = 0, \pi_3 = 0.6$ y las matrices A y B:

A	1	2	3	F
1	0.2	0.8	0.0	0.0
2	0.0	0.1	0.5	0.4
3	0.8	0.0	0.1	0.1

B	a	b
1	0.3	0.7
2	0.0	1.0
3	0.6	0.4


- a) Representa gráficamente el modelo.



- b) Determina cuál es la probabilidad de que el modelo genere la cadena "abbbba" siguiendo la secuencia de estados 112233F.

$$\begin{aligned}
 p(abbbba, 112233F) &= \pi_1 B_{1a} \cdot A_{11} B_{1b} \cdot A_{12} B_{2b} \cdot A_{22} B_{2b} \cdot A_{23} B_{3b} \cdot A_{33} B_{3a} \cdot A_{3F} \\
 &= 0.4 \cdot 0.3 \cdot 0.2 \cdot 0.7 \cdot 0.8 \cdot 1.0 \cdot 0.1 \cdot 1.0 \cdot 0.5 \cdot 0.4 \cdot 0.1 \cdot 0.6 \cdot 0.1 \\
 &= 0.0000016128
 \end{aligned}$$

- c) Realiza una traza del algoritmo de Viterbi para obtener la secuencia de estados mas probable con la que \mathcal{M} genera la cadena "aabb".



Hay dos caminos óptimos (cualquiera de ellos es solución al problema):

$$\tilde{z} = (3, 1, 1, 2, F) \quad \text{y} \quad \tilde{z}' = (3, 3, 1, 2, F)$$

$$p(aabb, \tilde{z}) = p(aabb, \tilde{z}') = 0.00387072$$

- d) Realiza una iteración de reestimación por Viterbi de \mathcal{M} a partir de las cadenas de aprendizaje

ab, ba, aab, aba,

sabiendo que las secuencias de estados óptimas para estas cadenas son, respectivamente,

12F, 33F, 312F, 123F.

Contadores:

π'	1	2	3
	2	0	2

A'	1	2	3	F
1	0	3	0	0
2	0	0	1	2
3	1	0	1	2

B'	a	b
1	3	0
2	0	3
3	3	1

Normalizando:

π	1	2	3
	1/2	0	1/2

A	1	2	3	F
1	0	1	0	0
2	0	0	1/3	2/3
3	1/4	0	1/4	1/2


B	a	b
1	1	0
2	0	1
3	3/4	1/4

16. Sea \mathcal{M} un modelo de Markov de cuatro estados sobre $\Sigma = \{a, b\}$, definido por $\pi_1 = 0.4, \pi_2 = \pi_F = 0, \pi_3 = 0.6$ y las matrices A y B:

A	1	2	3	F
1	0.2	0.8	0.0	0.0
2	0.0	0.1	0.5	0.4
3	0.8	0.0	0.1	0.1

B	a	b	c
1	0.0	0.5	0.5
2	0.9	0.0	0.1
3	0.1	0.1	0.8


- a) Representa gráficamente el modelo.



- b) Determina cuál es la probabilidad de que el modelo genere la cadena "abab".

$$\begin{aligned}
 p(abab) &= p(abab, 3123F) + p(abab, 3333F) \\
 &= 0.6 \cdot 0.1 \cdot 0.8 \cdot 0.5 \cdot 0.8 \cdot 0.9 \cdot 0.5 \cdot 0.1 \cdot 0.1 + 0.6 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \cdot 0.1 \\
 &= 0.0000864 + 0.000000006 \\
 &= 0.000086406
 \end{aligned}$$

- c) Realiza una traza del algoritmo de Viterbi para obtener la secuencia de estados mas probable con la que \mathcal{M} genera la cadena "bccc".



Hay dos caminos óptimos (cualquiera de ellos es solución al problema):

$$\tilde{z} = (3, 1, 1, 2, F) \quad \text{y} \quad \tilde{z}' = (3, 1, 2, 3, F)$$

$$p(bccc, \tilde{z}) = p(bccc, \tilde{z}') = 0.0000768$$

17. Se pretende aprender un Modelo de Markov lineal de conjunto de estados $Q = \{0, 1, 2, F\}$ y conjunto de símbolos $\Sigma = \{a, b, c\}$, a partir del siguiente conjunto de cadenas de aprendizaje:

$$A = \{acbbcc, aabbbc, abcc\}$$

- a) Obtén un modelo inicial M_0 por segmentación lineal de las cadenas de A ,

Una segmentación lineal reparte uniforme y secuencialmente los símbolos de cada cadena entre los 3 estados disponibles. Esto corresponde a la secuencia de estados 112233 para $acbbcc$, $aabbbc$ y 1223 para $abcc$, de longitudes 6 y 4, respectivamente. Como 4 no es múltiplo exacto 3, dependiendo de como se haga el redondeo, hay otras secuencias de estados posibles para $abcc$. Por ejemplo, 1123, 1233 son adecuadas, e incluso 1122 o 2233, siempre que las probabilidades iniciales y/o de estados finales se calculen correctamente. Los resultados que siguen corresponden a la secuencia 1223.

$$M_0 = (\pi_0, A_0, B_0):$$

A_0	1	2	3	F	B_0	a	b	c
1	2/5	3/5	0	0	1	4/5	0	1/5
2	0	1/2	1/2	0	2	0	5/6	1/6
3	0	0	2/5	3/5	3	0	1/5	4/5

- b) Calcula la aproximación de Viterbi a la probabilidad de que M_0 genere el conjunto de aprendizaje A .

$$\tilde{P}(A | M_0) = \tilde{P}(acbbcc | M_0) \cdot \tilde{P}(aabbbc | M_0) \cdot \tilde{P}(abcc | M_0) \approx 0.0011 \cdot 0.0053 \cdot 0.0307 \approx 1.7 \cdot 10^{-7}$$

$$\tilde{P}(acbbcc | M_0) \approx 0.0011:$$

	a	c	b	b	c	c
0	0.800	0.064				
1		0.080	0.0333	0.0139	0.0012	0.0001
2			0.0080	0.0033	0.0056	0.0018
Q:	1	2	2	2	3	3

$$\tilde{P}(aabbbc | M_0) \approx 0.0053:$$

	a	a	b	b	b	c
0	0.8	0.256				
1			0.128	0.0530	0.0222	0.0018
2				0.0128	0.0053	0.0088
Q:	0	0	1	1	1	2

$$\tilde{P}(abcc | M_0) \approx 0.0307:$$

	a	b	c	c
0	0.8			
1		0.4	0.0333	0.0028
2			0.1600	0.0512
Q:	0	1	2	2

- c) Obtén un nuevo modelo M_1 , mediante una iteración de re-estimación por Viterbi a partir de M_0 ,

$$M_1 = (\pi_1, A_1, B_1):$$

A_1	1	2	3	F	B_1	a	b	c
1	1/4	3/4	0	0	1	1	0	0
2	0	4/7	3/7	0	2	0	6/7	1/7
3	0	0	2/5	3/5	3	0	0	1

- d) Calcula la aproximación de Viterbi a la probabilidad de que M_1 genere el conjunto de aprendizaje A .

$$\tilde{P}(A | M_1) = \tilde{P}(acbbcc | M_1) \cdot \tilde{P}(aabbbc | M_1) \cdot \tilde{P}(abcc | M_1) \approx 0.0026 \cdot 0.0099 \cdot 0.0661 \approx 1.7 \cdot 10^{-6}$$

$$\tilde{P}(acbbcc | M_1) \approx 0.0026:$$

	a	c	b	b	c	c
0	1.0					
1		0.1071	0.0525	0.0257	0.0021	0.0002
2					0.0110	0.0044
Q:	0	1	1	1	2	2

$$\tilde{P}(aabbbc | M_1) \approx 0.0099:$$


	a	a	b	b	b	c
0	1.0	0.25				
1			0.1607	0.0787	0.0386	0.0031
2					0.0165	0.0099
Q:	0	0	1	1	1	2

$$\tilde{P}(abcc | M_1) \approx 0.0661:$$

	a	b	c	c
0	1.0			
1		0.6429	0.0524	0.0042
2			0.2755	0.1102
Q:	0	1	2	2

- e) Representa gráficamente M_1 e indica cuál ha sido el cambio cualitativo más significativo que ha ocurrido entre M_0 y M_1 .

M_1 genera las cadenas de aprendizaje con una verosimilitud 10 veces mayor que M_0 . Además de esto, el cambio cualitativo más significativo de M_0 a M_1 ha sido un aumento de la especialización de los estados en la emisión de símbolos: En M_0 el estado 1 emite a 's y c 's, y el 2 y 3 emiten b 's y c 's. Sin embargo, en M_1 el estado 1 emite solo a 's el 2 (casi) solo b 's y el 3 solo c 's. La representación gráfica se muestra a continuación:



18. Se tiene un problema de clasificación en dos clases X e Y , con probabilidades a priori respectivas de 0.3 y 0.7. Se dispone de modelos de Markov para cada clase, M_X y M_Y , cuyos parámetros son:

	A_X	1	2	F	B_X	a	b	A_Y	1	2	F	B_Y	a	b
$\pi_{X1} = \pi_{Y1} = 1$	1	0.8	0.2	0	1	0.9	0.1	1	0.8	0.2	0	1	0.1	0.9
$\pi_{X2} = \pi_{Y2} = 0$	2	0.7	0	0.3	2	0.1	0.9	2	0.7	0	0.3	2	0.9	0.1

- a) Calcular la aproximación de Viterbi a las probabilidades de generar la cadena $y = \text{"b b a b"}$ por M_X y M_Y . Presentar las trazas de ejecución correspondientes.
- b) Trazas del algoritmo de Viterbi para el cálculo de $\tilde{P}(y | M_X)$ y $\tilde{P}(y | M_Y)$:

Traza Mx:	b	b	a	b		Traza My:	b	b	a	b	
1	0.10000	0.00800	0.01134	0.00091		1	0.90000	0.64812	0.05185	0.07352	
2		0.01800	0.00016	0.00204	0.00061	2		0.01800	0.11667	0.00104	0.00031
Q:	1	2	1	2	F	Q:	1	1	1	2	F

$$\tilde{P}(y | M_X) \approx 0.00061, \quad \tilde{P}(y | M_Y) \approx 0.00031$$

- c) Clasificar y usando esta aproximación.
 $P(X | y) = P(y | M_X)P(X)/P(y) \approx 0.46$, $P(Y | y) = P(y | M_Y)P(Y)/P(y) \approx 0.54$.
 Por tanto, y se clasifica en el clase Y .
- d) Calcular la verdadera probabilidad de generar y mediante M_X y el error de la aproximación de Viterbi.
 Aparte de la secuencia de estados óptima (de Viterbi) $\langle 1, 2, 1, 2 \rangle$, hay otra secuencia, $\langle 1, 1, 1, 2 \rangle$, mediante la que M_X también puede generar y con probabilidad $0.00031 > 0$. Por tanto la verdadera probabilidad de generación de y por M_X es $0.00061 + 0.00031 = 0.00092$ y el error de la aproximación es 0.00031 (34%).
- e) Determinar cuáles son las dos cadenas (de 3 o menos símbolos) que se generan con mayor probabilidad (verdadera) mediante cada uno de los modelos M_X y M_Y . Calcular el error de la aproximación de Viterbi para cada una de estas cuatro cadenas.
 Para M_X : $\{\text{"a b"}, \text{"a a b"}\}$; Para M_Y : $\{\text{"b a"}, \text{"b b a"}\}$
 $P(\text{a b} | M_X) = P(\text{b a} | M_Y) \approx 0.049$, $P(\text{a a b} | M_X) = P(\text{b b a} | M_Y) \approx 0.035$
 El error de la aproximación de Viterbi es 0 en todos los casos, ya que las cuatro cadenas se generan mediante secuencias de estados únicas.

19. Considérese una tarea de clasificación de cadenas según sus longitudes en dos clases, \mathcal{S} (cadenas cortas) y \mathcal{L} (cadenas largas), con probabilidades a priori $P(\mathcal{S}) = 0.8$ y $P(\mathcal{L}) = 0.2$, respectivamente. Para simplificar, supongamos que las cadenas constan de un único símbolo, a . Para ello, se utilizan dos modelos de Markov de un solo estado, $M_{\mathcal{S}}$ y $M_{\mathcal{L}}$, cuyos parámetros son:

$\frac{\pi_{\mathcal{S}}}{1} \mid \frac{A_{\mathcal{S}}}{1} \mid \frac{1}{0.4} \mid \frac{F}{0.6}$	$\frac{B_{\mathcal{S}}}{1} \mid \frac{a}{1.0}$	$\frac{\pi_{\mathcal{L}}}{1} \mid \frac{A_{\mathcal{L}}}{1} \mid \frac{1}{0.6} \mid \frac{F}{0.4}$	$\frac{B_{\mathcal{L}}}{1} \mid \frac{a}{1.0}$
--	--	--	--

- a) Sean $y_1 = "aaaaa"$, $y_2 = "aaaaaa"$. Determinar las probabilidades con la que cada modelo genera estas cadenas, $P(y \mid c)$, $y \in \{y_1, y_2\}$, $c \in \{\mathcal{S}, \mathcal{L}\}$. Indicar también los valores de las correspondientes aproximaciones de Viterbi a estas probabilidades.

Las longitudes de y_1 e y_2 son 5 y 6, respectivamente. Por tanto:

$$P(y_1 \mid \mathcal{S}) = 0.4^4 \cdot 0.6 = 0.015360 \quad P(y_2 \mid \mathcal{S}) = 0.4^5 \cdot 0.6 = 0.006144$$

$$P(y_1 \mid \mathcal{L}) = 0.6^4 \cdot 0.4 = 0.051840 \quad P(y_2 \mid \mathcal{L}) = 0.6^5 \cdot 0.4 = 0.031104$$

Como estos modelos son no-ambiguos, la aproximación de Viterbi produce estas mismas probabilidades exactas.

- b) Determinar las probabilidades a posteriori $P(\mathcal{S} \mid y)$, $P(\mathcal{L} \mid y)$, $y \in \{y_1, y_2\}$.

$$P(y_1) = 0.8 \cdot P(y_1 \mid \mathcal{S}) + 0.2 \cdot P(y_1 \mid \mathcal{L}) = 0.022656$$

$$P(y_2) = 0.8 \cdot P(y_2 \mid \mathcal{S}) + 0.2 \cdot P(y_2 \mid \mathcal{L}) = 0.011136$$

$$P(\mathcal{S} \mid y_1) = \frac{0.8}{P(y_1)} \cdot P(y_1 \mid \mathcal{S}) = 0.542373 \quad P(\mathcal{S} \mid y_2) = \frac{0.8}{P(y_2)} \cdot P(y_2 \mid \mathcal{S}) = 0.441379$$

$$P(\mathcal{L} \mid y_1) = \frac{0.2}{P(y_1)} \cdot P(y_1 \mid \mathcal{L}) = 0.457627 \quad P(\mathcal{L} \mid y_2) = \frac{0.2}{P(y_2)} \cdot P(y_2 \mid \mathcal{L}) = 0.558621$$

- c) Clasificar y_1 e y_2 mediante el clasificador de mínimo riesgo de error o de Bayes. Determinar las probabilidades de que estas clasificaciones sean erróneas.

La clasificación de mínimo riesgo de error de y_1 es \mathcal{S} y la de y_2 es \mathcal{L} . La probabilidad de que estas clasificaciones sean erróneas son, respectivamente, $1 - 0.542373 = 0.457627$ y $1 - 0.558621 = 0.441379$.

- d) Calcular la probabilidad de error de este clasificador. Para este cálculo, pueden resultar útiles las siguientes fórmulas de sumas de series geométricas (en las que las i es se corresponden con las longitudes de las cadenas):

$$\sum_{i=m}^n r^i = \frac{r^m - r^{(n+1)}}{1 - r} \quad \sum_{i=1}^{\infty} r^i = \frac{r}{1 - r}$$

Sea i la longitud de una cadena y . La probabilidad de error viene dada por:

$$P(\text{error}) = \sum_{y:i=1}^{\infty} P(\text{error} \mid y) \cdot P(y)$$

Para $i \leq 5$, todas las cadenas se clasifican en la clase \mathcal{S} , mientras que para $i > 5$, la clasificación es \mathcal{L} . Por tanto:

$$\begin{aligned} P(\text{error}) &= \sum_{y:i=1}^5 P(\mathcal{L} \mid y) \cdot P(y) + \sum_{y:i=6}^{\infty} P(\mathcal{S} \mid y) \cdot P(y) \\ &= \sum_{i=1}^5 0.2 \cdot 0.6^{i-1} \cdot 0.4 + \sum_{i=6}^{\infty} 0.8 \cdot 0.4^{i-1} \cdot 0.6 \\ &= 0.2 \cdot 0.4 \cdot \sum_{i=0}^4 0.6^i + 0.8 \cdot 0.6 \cdot \sum_{i=5}^{\infty} 0.4^i \\ &= 0.2 \cdot 0.4 \cdot \frac{1 - 0.6^5}{1 - 0.6} + 0.8 \cdot 0.6 \cdot \left(\sum_{i=0}^{\infty} 0.4^i - \sum_{i=0}^4 0.4^i \right) \\ &= 0.2 \cdot (1 - 0.6^5) + 0.8 \cdot 0.6 \cdot \left(\frac{1}{1 - 0.4} - \frac{1 - 0.4^5}{1 - 0.4} \right) \\ &= 0.2 \cdot (1 - 0.6^5) + 0.8 \cdot 0.4^5 \\ &= 0.184448 + 0.36 = 0.544448 \end{aligned}$$

20. Considérese una tarea de clasificación de cadenas de símbolos del alfabeto $\Sigma = \{a, b\}$ en dos clases, V y W , con probabilidades a priori $P(V) = 0.6$ y $P(W) = 0.4$. Para ello, se utilizan dos modelos de Markov, M_V y M_W , ambos con dos estados ($Q = \{1, 2, F\}$), cuyos parámetros son:

q	π_V	A_V	1	2	F	B_V	a	b	q	π_W	A_W	1	2	F	B_W	a	b
1	0.8	1	0.7	0.3	0.0	1	0.9	0.1	1	1.0	1	0.7	0.3	0.0	1	0.9	0.1
2	0.2	2	0.0	0.5	0.5	2	0.8	0.2	2	0.0	2	0.0	0.5	0.5	2	0.8	0.2

- a) Calcula las probabilidades exactas (*no* la aproximación de Viterbi) de que M_V y M_W generen la cadena “aab”. Hay tres secuencias de estados en M_V que generan la cadena *aab*: $z_1 = 1, 1, 2, F$, $z_2 = 1, 2, 2, F$, $z_3 = 2, 2, 2, F$; análogamente, en M_W hay dos secuencias: $z_1 = 1, 1, 2, F$, $z_2 = 1, 2, 2, F$. Por tanto:

$$\begin{aligned}
 P(aab | V) &= (0.8 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.2) 0.5 \\
 &\quad + (0.8 \cdot 0.9) (0.3 \cdot 0.8) (0.5 \cdot 0.2) 0.5 \\
 &\quad + (0.2 \cdot 0.8) (0.5 \cdot 0.8) (0.5 \cdot 0.2) 0.5 \\
 &= 0.01361 + 0.00864 + 0.0032 = \mathbf{0.02545}
 \end{aligned}
 \quad
 \begin{aligned}
 P(aab | W) &= (1 \cdot 0.9) (0.7 \cdot 0.9) (0.3 \cdot 0.2) 0.5 \\
 &\quad + (1 \cdot 0.9) (0.3 \cdot 0.8) (0.5 \cdot 0.2) 0.5 \\
 &= 0.01701 + 0.0108 = \mathbf{0.02781}
 \end{aligned}$$

- b) Clasifica la cadena “aab” por mínima probabilidad de error.

$$c^*(aab) = \arg \max_{c \in \{V, W\}} P(c | aab) = \arg \max_{c \in \{V, W\}} P(aab | c) \cdot P(c)$$

$$P(aab | V) P(V) = 0.02545 \cdot 0.6 = \mathbf{0.015270} > P(aab | W) P(W) = 0.02781 \cdot 0.4 = \mathbf{0.011124}$$

Por tanto, $c^*(aab) = V$.

- c) Determina la probabilidad de error de la clasificación obtenida en el apartado anterior.

$$P(\text{error} | aab) = 1 - \max_{c \in \{V, W\}} P(c | aab) = 1 - P(V | aab) = P(W | aab) = \frac{P(aab | W) P(W)}{P(aab)}$$

$$P(aab) = P(aab | V) P(V) + P(aab | W) P(W) = 0.011124 + 0.015270 = 0.026394$$

$$P(\text{error} | aab) = \frac{0.011124}{0.026394} = \mathbf{0.42145}$$

- d) Repite los cálculos de los dos apartados anteriores, utilizando las probabilidades obtenidas mediante la aproximación de Viterbi en lugar de las probabilidades exactas.

$$\tilde{P}(aab | V) = \max_{z \in Q^+} P(aab, z | V) = \max(0.01361, 0.00864, 0.0032) = \mathbf{0.01361}$$

$$\tilde{P}(aab | W) = \max_{z \in Q^+} P(aab, z | W) = \max(0.01701 + 0.0108) = \mathbf{0.01701}$$

$$\tilde{c}^*(aab) = \arg \max_{c \in \{V, W\}} P(c | aab) \approx \arg \max_{c \in \{V, W\}} \tilde{P}(aab | c) \cdot P(c)$$

$$\tilde{P}(aab | V) P(V) = 0.01361 \cdot 0.6 = \mathbf{0.008166} > \tilde{P}(aab | W) P(W) = 0.01701 \cdot 0.4 = \mathbf{0.006804}$$

Por tanto, $\tilde{c}^*(aab) = V$.

$$P(\text{error} | aab) = 1 - \max_{c \in \{V, W\}} P(c | aab) = 1 - P(V | aab) = P(W | aab) \approx \frac{\tilde{P}(aab | W) P(W)}{\tilde{P}(aab)}$$

$$\tilde{P}(aab) = \tilde{P}(aab | V) P(V) + \tilde{P}(aab | W) P(W) = 0.008166 + 0.006804 = 0.01497$$

$$P(\text{error} | aab) \approx \frac{0.006804}{0.01497} = \mathbf{0.45451}$$

21. Los modelos de Markov discretos que se estudian en SIN pueden extenderse fácilmente para que, en lugar de generar secuencias de *símbolos*, generen secuencias de *vectores* definidos en \mathbb{R}^d . Para ello basta asociar a cada estado no final una densidad condicional sobre \mathbb{R}^d . Así pues, estos modelos se definen mediante una cuádrupla (Q, π, A, D) , donde Q, π y A son los usuales y D (que sustituye a la matriz de probabilidades de emisión de símbolos, B) representa ahora a las *densidades condicionales* $p(\mathbf{y} | q)$, $\mathbf{y} \in \mathbb{R}^d$, $q \in Q - \{F\}$. La probabilidad con la que uno de estos modelos genera una secuencia de *vectores* $Y = \mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_m$ se calcula de forma similar al caso de modelos discretos, con la diferencia de que la probabilidad de emisión de cada vector \mathbf{y}_t se obtienen mediante $p(\mathbf{y}_t | q_t)$, en vez de B_{q_t, y_t} .

Sea M uno de estos modelos definidos en \mathbb{R}^1 (recta real), con $Q = \{1, 2, F\}$, $\pi(1) = 1.0$, $\pi(2) = 0.0$,

A	1	2	F
1	0.0	1.0	0.0
2	0.5	0.2	0.3

$$p(\mathbf{y} | 1) = \begin{cases} 1/4 & -3 \leq y < 1 \\ 0 & \text{en otros casos} \end{cases} \quad p(\mathbf{y} | 2) = \begin{cases} 1/5 & -1 \leq y < 4 \\ 0 & \text{en otros casos} \end{cases}$$

Por ejemplo, M genera la secuencia $X = 0.0, 0.3, 0.0$ mediante una *única* secuencia de estados $z = 1, 2, 2, F$, con probabilidad no nula:

$$\begin{aligned} p(X | M) &= p(X, z) = p(z) \cdot p(X | z) = (\pi(1) \cdot A_{1,2} \cdot A_{2,2} \cdot A_{2,F}) \cdot (p(0.0 | 1) \cdot p(0.3 | 2) \cdot p(0.0 | 2)) \\ &= (1.0 \cdot 1.0 \cdot 0.2 \cdot 0.3) \cdot (1/4 \cdot 1/5 \cdot 1/5) \\ &= 0.06 \cdot 0.01 = 0.0006 \end{aligned}$$

- a) Encontrar dos secuencias de estados z', z'' que generen la secuencia $Y = 0.0, 0.0, 0.0, 0.0$ con probabilidad no nula. ¿Hay más secuencias de estados que generen Y con probabilidad no nula?

$z' = 1, 2, 1, 2, F$; $z'' = 1, 2, 2, 2, F$. Cualquier otra secuencia de estados tiene probabilidad nula de generar Y .

- b) Calcular $p(Y | z')$, $p(Y | z'')$, $\tilde{p}(Y | M)$ y $p(Y | M)$ (las dos últimas son la aproximación de Viterbi y la verdadera probabilidad de generar Y mediante M).

$$\begin{aligned} p(z') &= 1.0 \cdot 1.0 \cdot 0.5 \cdot 1.0 \cdot 0.3 = 0.15; \quad p(z'') = 1.0 \cdot 1.0 \cdot 0.2 \cdot 0.2 \cdot 0.3 = 0.012; \\ p(Y | z') &= 1/4 \cdot 1/5 \cdot 1/4 \cdot 1/5 = 0.0025; \quad p(Y | z'') = 1/4 \cdot 1/5 \cdot 1/5 \cdot 1/5 = 0.0020; \\ \tilde{p}(Y | M) &= \max(0.15 \cdot 0.0025, 0.012 \cdot 0.002) = 0.000375 \\ p(Y | M) &= 0.15 \cdot 0.0025 + 0.012 \cdot 0.002 = 0.000399. \end{aligned}$$

- c) Sea $Y' = -2.0, -0.5, 0.0, 0.5, 2.0$. ¿Cuántas secuencias de estados de M generan Y' con probabilidad no nula? Sólo hay tres secuencias de estados que pueden generar cadenas de longitud 5 (número de vectores de Y'): $z^1 = 1, 2, 1, 2, 2$, $z^2 = 1, 2, 2, 1, 2$, $z^3 = 1, 2, 2, 2, 2$. Todas ellas generan Y' con probabilidad mayor que cero.
- d) Calcular la aproximación de Viterbi a la probabilidad con la que M genera Y' .

Podría utilizarse el algoritmo de Viterbi pero, dado que solo hay tres secuencias de estados, es preferible hacer el cálculo exhaustivo:

$$\begin{aligned} p(Y' | z^1) &= 1.0 \cdot 1.0 \cdot 0.5 \cdot 1.0 \cdot 0.2 \cdot 0.3 \cdot 1/4 \cdot 1/5 \cdot 1/4 \cdot 1/5 \cdot 1/5 = 0.03 \cdot 0.0005 = 0.000015 \\ p(Y' | z^2) &= 1.0 \cdot 1.0 \cdot 0.2 \cdot 0.5 \cdot 1.0 \cdot 0.3 \cdot 1/4 \cdot 1/5 \cdot 1/5 \cdot 1/4 \cdot 1/5 = 0.03 \cdot 0.0005 = 0.000015 \\ p(Y' | z^3) &= 1.0 \cdot 1.0 \cdot 0.2 \cdot 0.2 \cdot 0.2 \cdot 0.3 \cdot 1/4 \cdot 1/5 \cdot 1/5 \cdot 1/5 \cdot 1/5 = 0.0024 \cdot 0.0004 = 0.00000096 \\ \tilde{p}(Y' | M) &= \max(0.000015, 0.000015, 0.00000096) = 0.000015 \end{aligned}$$

22. Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, 3, 4, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(1) = \pi_0(2) = \pi_0(4) = \frac{1}{3}$, $\pi_0(3) = \pi_0(F) = 0$; y probabilidades de transición entre estados y de emisión de símbolos:

A	1	2	3	4	F
1	$\frac{1}{2}$	0	0	0	$\frac{1}{2}$
2	0	$\frac{1}{2}$	$\frac{1}{2}$	0	0
3	0	0	$\frac{1}{2}$	0	$\frac{1}{2}$
4	0	0	0	$\frac{1}{2}$	$\frac{1}{2}$

B	a	b
1	1	0
2	1	0
3	0	1
4	0	1

- a) Sean n y m dos enteros positivos. Halla las probabilidades $P(a^n | M)$, $P(a^n b^m | M)$ y $P(b^n | M)$.

$$\begin{aligned} P(a^n | M) &= \frac{1}{3} \frac{1}{2^n} \\ P(a^n b^m | M) &= \frac{1}{3} \frac{1}{2^{n+m}} \\ P(b^n | M) &= \frac{1}{3} \frac{1}{2^n} \end{aligned}$$

- b) Calcula la probabilidad de que M genere una cadena cualquiera de longitud comprendida entre 5 y 7.

El conjunto de cadenas de longitud 7 que M puede generar es:

$$S_7 = \{a^7, a^6b, a^5b^2, a^4b^3, a^3b^4, a^2b^5, ab^6, b^7\}$$

Cada una de las 8 cadenas de S_7 se genera con probabilidad $\frac{1}{3} \frac{1}{2^7}$.

Análogamente:

hay 7 cadenas de longitud 6 que se generan con probabilidad $\frac{1}{3} \frac{1}{2^6}$

hay 6 cadenas de longitud 5 que se generan con probabilidad $\frac{1}{3} \frac{1}{2^5}$

Por tanto, si S es el conjunto de cadenas de longitudes comprendidas entre 5 y 7,

$$P(x \in S | M) = 8 \frac{1}{3} \frac{1}{2^7} + 7 \frac{1}{3} \frac{1}{2^6} + 6 \frac{1}{3} \frac{1}{2^5} \approx 0.02083 + 0.03646 + 0.06250 \approx 0.11979$$

23. En la figura se pueden ver muestras generadas por un Modelo de Markov de 7 estados con topología lineal. Cada trazo elemental de estas muestras corresponde a un símbolo del *código de contorno de 8 direcciones* $\Sigma = \{“0”, “1”, \dots, “8”\}$, que también se puede ver en la figura.



Sea \mathcal{M}_0 un Modelo de Markov lineal de 7 estados $Q = \{1, 2, 3, 4, 5, 6, 7, F = 8\}$, con los siguientes parámetros:

$$\pi_q = \begin{cases} 1/2 & \text{si } q \in \{1, 2\} \\ 0 & \text{en otros casos} \end{cases}$$

$$A_{q'q} = \begin{cases} 1 & \text{si } q' = 1, q = 2 \\ 1/2 & \text{si } q \in \{q', q' + 1\}, 2 \leq q' \leq 5 \\ 1/3 & \text{si } q' = 6, q \geq 6 \\ 1 & \text{si } q' = 7, q = 8 \\ 0 & \text{en otros casos} \end{cases}$$

$$B_{q\sigma} = \begin{cases} 1 & \text{si } (q, \sigma) \in \{(1, “1”), (2, “0”), (3, “5”), (4, “0”), (5, “6”), (6, “4”), (7, “3”) \} \\ 0 & \text{en otros casos} \end{cases}$$

- a) Calcular la aproximación de Viterbi a la probabilidad con la que \mathcal{M}_0 genera cada una de las muestras de la figura. Cadenas de entrenamiento: “0 5 0 6 4”, “0 5 0 6 4 4”, “0 0 5 0 0 6 4 4 4”, “1 0 0 5 0 6 6 4 4 3”.

HMM inicial \mathcal{M}_0 :

q	1	2	3	4	5	6	7	8=F
π_q	1/2	1/2	0	0	0	0	0	–
$q' \backslash q$	1	2	3	4	5	6	7	8=F
1	0	1	0	0	0	0	0	0
2	0	1/2	1/2	0	0	0	0	0
3	0	0	1/2	1/2	0	0	0	0
4	0	0	0	1/2	1/2	0	0	0
5	0	0	0	0	1/2	1/2	0	0
6	0	0	0	0	0	1/3	1/3	1/3
7	0	0	0	0	0	0	0	1

$q \backslash \sigma$	“0”	“1”	“2”	“3”	“4”	“5”	“6”	“7”
1	0	1	0	0	0	0	0	0
2	1	0	0	0	0	0	0	0
3	0	0	0	0	0	1	0	0
4	1	0	0	0	0	0	0	0
5	0	0	0	0	0	0	1	0
6	0	0	0	0	1	0	0	0
7	0	0	0	1	0	0	0	0

Aproximación de Viterbi a la probabilidad con la que \mathcal{M}_0 genera las muestras: 0.01042, 0.00347, 0.00029, 0.00087.

- b) Calcular la verdadera probabilidad con la que \mathcal{M}_0 genera cada una de las muestras de la figura. Las verdaderas probabilidades con la que \mathcal{M}_0 genera las muestras son las mismas que en el apartado a), ya que \mathcal{M}_0 es determinista.
- c) Calcular la verosimilitud con la que \mathcal{M}_0 genera todas las muestras. Verosimilitud de todas las muestras: $9.1 \cdot 10^{-12}$.
- d) Partiendo de \mathcal{M}_0 , realizar una iteración del algoritmo de reestimación por Viterbi con estas muestras.

Secuencias de estados correspondientes a los cálculos de a):

$\langle 2, 3, 4, 5, 6, F \rangle$, $\langle 2, 3, 4, 5, 6, 6, F \rangle$, $\langle 2, 2, 3, 4, 4, 5, 6, 6, 6, F \rangle$, $\langle 1, 2, 2, 3, 4, 5, 5, 6, 6, 7, F \rangle$

HMM reestimado a partir de estas secuencias:

q	1	2	3	4	5	6	7	8=F
π_q	1/2	1/2	0	0	0	0	0	–
$q' \backslash q$	1	2	3	4	5	6	7	8=F
1	0	1	0	0	0	0	0	0
2	0	1/3	2/3	0	0	0	0	0
3	0	0	0	1	0	0	0	0
4	0	0	0	1/5	4/5	0	0	0
5	0	0	0	0	1/5	4/5	0	0
6	0	0	0	0	0	1/2	1/8	3/8
7	0	0	0	0	0	0	0	1

$q \backslash \sigma$	“0”	“1”	“2”	“3”	“4”	“5”	“6”	“7”
1	0	1	0	0	0	0	0	0
2	1	0	0	0	0	0	0	0
3	0	0	0	0	0	1	0	0
4	1	0	0	0	0	0	0	0
5	0	0	0	0	0	0	1	0
6	0	0	0	0	1	0	0	0
7	0	0	0	1	0	0	0	0


24. Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(0) = 0.7, \pi_0(1) = 0.3$; y probabilidades de transición entre estados y de emisión de símbolos:

A	0	1	F
0	0.5	0.4	0.1
1	0.3	0.5	0.2

B	a	b
0	0.6	0.4
1	0.4	0.6

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “a a a” y “b b a”.

Primero determinamos la secuencia de estados mas probable para cada cadena mediante el algoritmo de Viterbi:



Los pares *cadena-secuencia óptima de estados* obtenidos son:

a a a	b b a
0 0 1 F	0 1 1 F

Los parámetros reestimados a partir de estos pares son:

$$\hat{\pi}_0(0) = \frac{2}{2} = 1$$

$$\hat{\pi}_0(1) = \frac{0}{2} = 0$$

A	0	1	F
0	$\frac{1}{3}$	$\frac{2}{3}$	0
1	0	$\frac{1}{3}$	$\frac{2}{3}$

B	a	b
0	$\frac{2}{3}$	$\frac{1}{3}$
1	$\frac{2}{3}$	$\frac{1}{3}$

25. A continuación se dan 4 cadenas generadas por un modelo de Markov, cada una junto a una posible secuencias de estados:

“a c c” “c c a” “c b b a” “a b b c”
“0 1 2” “3 4 5” “3 4 4 5” “0 1 1 2”

Usando probabilidades aproximadas por Viterbi cuando sea necesario:

- a) Inicializa un modelo de markov \mathcal{M}_0 a partir de estos datos. Representa gráficamente \mathcal{M}_0 .

$$\mathcal{M}_0 = (Q\Sigma, \pi, A, B); \quad Q = \{0, 1, 2, 3, 4, 5\}, \quad \pi(0) = \pi(3) = 1/2, \quad \pi_1 = \pi_2 = \pi_4 = \pi_5 = 0,$$

A	0	1	2	3	4	5	F
0	0	1	0	0	0	0	0
1	0	1/3	2/3	0	0	0	0
2	0	0	0	0	0	0	1
3	0	0	0	0	1	0	0
4	0	0	0	0	1/3	2/3	0
5	0	0	0	0	0	0	1

B	a	b	c
0	1	0	0
1	0	2/3	1/3
2	0	0	1
3	0	0	1
4	0	2/3	1/3
5	1	0	0

- b) Obtén la versimilitud con la que \mathcal{M}_0 genera las dos primeras cadenas (“a c c”, “c c a”).

$$P(\text{“acc”, “cca”} \mid \mathcal{M}_0) \approx \tilde{P}(\text{“acc”} \mid \mathcal{M}_0) \cdot \tilde{P}(\text{“cca”} \mid \mathcal{M}_0) = 0.111111 \cdot 0.111111 = 0.012345679$$

	a	c	c
0	0.5	-	-
1	-	0.166666	0.018518
2	-	-	0.111111
3	-	-	-
4	-	-	-
5	-	-	-
z:	0	1	2
			0.111111

	c	c	a
0	-	-	-
1	-	-	-
2	-	-	-
3	0.5	-	-
4	-	0.166666	-
5	-	-	0.111111
z:	3	4	5
			0.111111

- c) Obtén la versimilitud con la que las dos primeras cadenas (“a c c”, “c c a”) son generadas por un modelo \mathcal{M}' , definido como:

$$Q' = \{0, 1, F\}; \text{ alfabeto } \Sigma = \{a, b, c\}; \text{ probabilidades iniciales } \pi'(0) = 4/5, \pi'_0(1) = 1/5;$$

y probabilidades de transición entre estados y de emisión de símbolos:

A'	0	1	F
0	0	1/2	1/2
1	1/5	0	4/5

B'	a	b	c
0	1/5	1/5	3/5
1	3/5	1/5	1/5

$$P(\text{“acc”, “cca”} \mid \mathcal{M}') \approx \tilde{P}(\text{“acc”} \mid \mathcal{M}') \cdot \tilde{P}(\text{“cca”} \mid \mathcal{M}') = 0.001152 \cdot 0.001152 = 0.000001327$$

	a	c	c
0	0.16	0.0144	0.00192
1	0.12	0.0160	0.00144
z:	1	0	1
			0.001152

	c	c	a
0	0.48	0.0048	0.00192
1	0.04	0.0480	0.00144
z:	1	0	1
			0.001152

26. Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a\}$; probabilidades iniciales $\pi_0 = 0.6$, $\pi_1 = 0.4$; y probabilidades de transición entre estados:

A	0	1	F
0	0.0	0.3	0.7
1	0.7	0.0	0.3

- a) Calcular la probabilidad con la que M genera la cadena “a a”

Como solo hay un símbolo, la probabilidad de generarlo en cualquier estado ha de ser 1.0.

Solo hay dos caminos que generan $x = \text{“a a”}$: $z_1 = 0, 1, F$ y $z_2 = 1, 0, F$. Por tanto, la probabilidad de generar x mediante M es:

$$\begin{aligned}
 P(x \mid M) &= P(x, z_1) + P(x, z_2) \\
 &= P(z_1)P(x \mid z_1) + P(z_2)P(x \mid z_2) \\
 &= P(z_1) \cdot 1 + P(z_2) \cdot 1 \\
 &= 0.6 \cdot 0.3 \cdot 0.3 + 0.4 \cdot 0.7 \cdot 0.7 \\
 &= 0.054 + 0.196 \\
 &= 0.25
 \end{aligned}$$

- b) Calcular la probabilidad aproximada por Viterbi con la que M genera la cadena “a a a”. Presentar una traza de ejecución del algoritmo de Viterbi con la que se obtiene esta probabilidad.

Solo hay dos caminos que generan $y = \text{“a a a”}$: $z_1 = 0, 1, 0, F$ y $z_2 = 1, 0, 1, F$. En ambos caminos hay un bucle formado por los arcos “0, 1” y “1, 0”. Por tanto el camino de mayor probabilidad será aquél en el que la probabilidad inicial por la final sea mayor; es decir, $z = 0, 1, 0, F$:

$$\begin{aligned}
 \tilde{P}(y \mid M) &= P(y, z) \\
 &= P(z) \cdot 1 \\
 &= 0.6 \cdot 0.3 \cdot 0.7 \cdot 0.7 \\
 &= 0.0882
 \end{aligned}$$

Mediante el algoritmo de Viterbi:

	a	a	a	
0	0.6	0.28	0.126	
1	0.4	0.18	0.084	
F				0.0882
z:	0	1	0	F

- c) Obtener una expresión de la probabilidad aproximada por Viterbi con la que M genera una cadena de longitud n en función de dicha longitud, n .

Hacemos los cálculos para varias longitudes y generalizamos por inducción:

$$\begin{aligned}
 \tilde{P}(a^2 \mid M) &= 0.4 \cdot 0.7 \cdot 0.7 \\
 \tilde{P}(a^4 \mid M) &= 0.4 \cdot 0.7 \cdot (0.3 \cdot 0.7)^1 \cdot 0.7 \\
 \tilde{P}(a^6 \mid M) &= 0.4 \cdot 0.7 \cdot (0.3 \cdot 0.7)^2 \cdot 0.7 \\
 \tilde{P}(a^8 \mid M) &= 0.4 \cdot 0.7 \cdot (0.3 \cdot 0.7)^3 \cdot 0.7 \\
 &\dots \dots \\
 \tilde{P}(a^n \mid M) &= 0.4 \cdot 0.7 \cdot (0.3 \cdot 0.7)^{(n/2-1)} \cdot 0.7 \\
 &= 0.196 \cdot (0.3 \cdot 0.7)^{(n/2-1)}
 \end{aligned}$$

- d) Reestimar los parámetros de M mediante una iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “a a” y “a a a”.

Las secuencias de estados óptimas para estas cadenas son $0, 1, 0, F$ y $1, 0, F$. Los correspondientes parámetros reestimados de M son: $\pi_0 = \pi_1 = 1/2$, $B_{0, \text{“a”}} = B_{1, \text{“a”}} = 1$, y matriz de probabilidades de transición:

A	0	1	F
0	0	1/3	2/3
1	1	0	0

27. Se dispone del siguiente conjunto de cadenas de entrenamiento, Y , cada una de las cuales acompañada de la secuencia de estados con la que ha sido generada por \mathcal{M} con mayor probabilidad (secuencia óptima de Viterbi):

cadenas: a b b b a a b b b b b a b b a
 estados: 3 1 1 2 3 3 3 3 1 1 2 3 1 2 3

- a) Usando estas cadenas y secuencias de estados, realiza una iteración del algoritmo de reestimación de Viterbi para obtener un modelo \mathcal{M}

El modelo \mathcal{M} tiene tres estados además del estado final y un alfabeto de dos símbolos, $\Sigma = \{a, b\}$. Los restantes parámetros se estiman como:

$$\pi_1 = \pi_3 = 1/2, \quad \pi_2 = \pi_F = 0$$

A	1	2	3	F
1	2/5	3/5	0	0
2	0	0	1	0
3	1/7	0	2/7	4/7

B	a	b
1	0	1
2	0	1
3	5/7	2/7

- b) Calcula la verosimilitud (aproximada por Viterbi) del conjunto de cadenas de entrenamiento con \mathcal{M} .

$$\begin{aligned}
 \tilde{P}(Y | \mathcal{M}) &= \tilde{P}(\text{abbbba} | \mathcal{M}) \cdot \tilde{P}(\text{abb} | \mathcal{M}) \cdot \tilde{P}(\text{bbba} | \mathcal{M}) \cdot \tilde{P}(\text{bba} | \mathcal{M}) \\
 &\approx 0.005 \cdot 0.00136 \cdot 0.049 \cdot 0.1225 \approx 0.000000041
 \end{aligned}$$

- c) Calcula la verdadera probabilidad de generación de la cadena “b b a” y el error cometido por la aproximación de Viterbi.

Solo hay dos secuencias de estados que generan la cadena “b b a”: $\langle 1, 2, 3, F \rangle$ y $\langle 3, 3, 3, F \rangle$. Por tanto,

$$P(\text{“b b a”} | \mathcal{M}) = \frac{1}{2} \cdot \frac{3}{5} \cdot 1 \cdot \frac{4}{7} \cdot 1 \cdot 1 \cdot \frac{5}{7} + \frac{1}{2} \cdot \frac{2}{7} \cdot \frac{2}{7} \cdot \frac{4}{7} \cdot \frac{2}{7} \cdot \frac{2}{7} \cdot \frac{5}{7} \approx 0.171 \cdot 0.714 + 0.023 \cdot 0.0583 \approx 0.124$$

El error de la aproximación de Viterbi es aproximadamente: $0.124 - 0.1225 = 0.0015$

28. Considera un problema de clasificación en dos clases U y V , con probabilidades a priori $P(U) = 0.7, P(V) = 0.3$, representadas mediante modelos de Markov $\mathcal{M}_U, \mathcal{M}_V$, ambos definidos sobre el conjunto de primitivas $\{a, b\}$:

A_U	1	2	F
1	0.6	0.4	0
2	0	0.5	0.5

B_U	a	b
1	0.9	0.1
2	0.2	0.8

$$\pi_{U_1} = 0.8, \quad \pi_{U_2} = 0.2$$

A_V	1	2	F
1	0.4	0.6	0
2	0	0.5	0.5

B_V	a	b
1	0.9	0.1
2	0.2	0.8

$$\pi_{V_1} = 1, \quad \pi_{V_2} = 0$$

- a) Calcula la aproximación por Viterbi a la probabilidad de que \mathcal{M}_U genere la cadena “aab” y la correspondiente secuencia óptima de estados.

$$\tilde{P}(\text{aab} | \mathcal{M}_U) = 0.062208 \quad \tilde{q}_1 = 1, \tilde{q}_2 = 1, \tilde{q}_3 = 2, \tilde{q}_4 = F \quad (\text{Ver respuesta al apartado b})$$

- b) Calcula las verdaderas probabilidades de que \mathcal{M}_U y \mathcal{M}_V generen la cadena “aab”.

$$\begin{aligned}
 P(\text{aab} | \mathcal{M}_U) &= P(\text{aab}, q_1 = 1, q_2 = 1, q_3 = 2 | \mathcal{M}_U) \\
 &+ P(\text{aab}, q_1 = 1, q_2 = 2, q_3 = 2 | \mathcal{M}_U) \\
 &+ P(\text{aab}, q_1 = 2, q_2 = 2, q_3 = 2 | \mathcal{M}_U) \\
 &= (0.8 \cdot 0.9) (0.6 \cdot 0.9) (0.4 \cdot 0.8) 0.5 \\
 &+ (0.8 \cdot 0.9) (0.4 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &+ (0.2 \cdot 0.2) (0.5 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.062208 + 0.0115200 + 0.0008 \\
 &= 0.074528
 \end{aligned}$$

$$\begin{aligned}
 P(\text{aab} | \mathcal{M}_V) &= P(\text{aab}, q_1 = 1, q_2 = 1, q_3 = 2 | \mathcal{M}_V) \\
 &+ P(\text{aab}, q_1 = 1, q_2 = 2, q_3 = 2 | \mathcal{M}_V) \\
 &= (1 \cdot 0.9) (0.4 \cdot 0.9) (0.6 \cdot 0.8) 0.5 \\
 &+ (1 \cdot 0.9) (0.6 \cdot 0.2) (0.5 \cdot 0.8) 0.5 \\
 &= 0.07776 + 0.021600 \\
 &= 0.09936
 \end{aligned}$$

- c) Determina las probabilidades a posteriori de que la cadena “aab” pertenezca a las clases U y V .

$$P(\text{aab} | U) P(U) = 0.074528 \cdot 0.7 = 0.0521696$$

$$P(\text{aab} | V) P(V) = 0.09936 \cdot 0.3 = 0.029808$$

$$P(x) = P(\text{aab} | \mathcal{M}_U) P(U) + P(\text{aab} | \mathcal{M}_V) P(V) = 0.0521696 + 0.029808 = 0.0819776$$


$$P(U | \text{aab}) = \frac{P(\text{aab} | U) P(U)}{P(x)} = \frac{0.0521696}{0.0819776} \approx 0.6364$$

$$P(V | \text{aab}) = \frac{P(\text{aab} | V) P(V)}{P(x)} = \frac{0.029808}{0.0819776} \approx 0.3636$$

- d) Clasifica la cadena “aab” por mínima probabilidad de error.

$$c^*(\text{aab}) = \arg \max_{c \in \{U, V\}} P(c | \text{aab}) = U$$

29. (Examen de SIN del 18 de enero de 2013; tiempo estimado: 30 minutos)
 Sea M un modelo de Markov de conjunto de estados $Q = \{1, 2, F\}$; topología:



alfabeto $\Sigma = \{a, b\}$; y “aaabb” una muestra de entrenamiento. Obtener el correspondiente modelo oculto de Markov estimado inicializando con una segmentación lineal.

SOLUCIÓN:

Segmentación inicial

a a a b b
 1 1 2 2 2 F

Inicialización a partir de la segmentación inicial

π	1	2
	1	0

A	1	2	F
1	0.5	0.5	0
2	0	0.66	0.34

B	a	b
1	1	0
2	0.34	0.66

Primera iteración

Análisis por Viterbi

		a	a	a	b	b	
I	1						
1		1	0.5	0.25	0.0	0.0	
2		0	0.16	0.085	0.085	0.037	
F							0.012

Secuencia de estados óptima: 1 1 1 2 2

Restimación

π	1	2
	1	0

A	1	2	F
1	0.66	0.34	0
2	0	0.5	0.5

B	a	b
1	1	0
2	0	1

Segunda iteración

Análisis por Viterbi

		a	a	a	b	b	
I	1						
1		1	0.66	0.436	0.0	0.0	
2		0	0	0	0.148	0.07	
F							0.035

Secuencia de estados óptima: 1 1 1 2 2

Restimación

π	1	2
	1	0

A	1	2	F
1	0.66	0.34	0
2	0	0.5	0.5

B	a	b
1	1	0
2	0	1

Final porque el modelo no ha cambiado

30. (Examen de SIN del 30 de enero de 2013; tiempo estimado: 30 minutos)

Supongamos que disponemos de tres cadenas de símbolos de entrenamiento para estimar las probabilidades de un modelo de Markov y que en una iteración determinada del algoritmo de reestimación por Viterbi se obtienen las siguientes secuencias de estados óptimas:

a a a d d d c c c c a a a a c c b
1 1 1 2 2 2 2 3 3 3 2 2 2 4 4 4 4 F

a a d d c a b a b a b c c c d c b b
1 1 2 2 2 4 4 4 4 4 2 2 2 2 2 1 1 1 1 F


a a a a d c d c d a b a b a b c c c a a b
3 3 3 3 4 4 4 4 4 2 2 2 2 2 4 4 4 4 2 2 2 F

A partir de esas secuencias, se pide:

- dibujar la topología (estados y transiciones con probabilidad distinta de cero) del modelo de Markov que se está utilizando;
- calcular las probabilidades de ser estado inicial;
- calcular las probabilidades de transición entre estados; y
- calcular las probabilidades de emisión en los estados.

SOLUCIÓN:

a) Topología del modelo de Markov



b) Probabilidades de estados iniciales

π	1	2	3	4
	2/3	0	1/3	0

c) Probabilidades de transición entre estados

#	1	2	3	4	F	Total
1	2+4+0=6	1+1+0=2			0+1+0=1	9
2	0+1+0=1	5+6+6=17	1+0+0=1	1+1+1=3	0+0+1=1	23
3		1+0+0=1	2+0+3=5	0+0+1=1		7
4		0+1+2=3		4+4+7=15	0+0+0=1	19

A	1	2	3	4	F
1	2/3	2/9	0	0	1/9
2	1/23	17/23	1/23	3/23	1/23
3	0	1/7	5/7	1/7	0
4	0	3/19	0	15/19	1/19


d) Probabilidades de emisión

#	a	b	c	d	Total
1	3+2+0=5	0+2+0=2	0+1+0=1	0+1+0=1	9
2	3+1+5=9	0+1+4=4	1+4+0=5	3+2+0=5	23
3	0+0+4=4	0+0+0=0	3+0+0=3	0+0+0=0	7
4	2+3+0=5	1+2+1=4	2+2+1=7	0+0+2=3	19

B	a	b	c	d
1	5/9	2/9	1/9	1/9
2	9/23	4/23	5/23	5/23
3	4/7	0	3/7	0
4	5/19	4/19	7/19	3/19

31. (Examen de SIN del 28 de enero de 2014; problema 1; tiempo estimado: 30 minutos)

Dado el siguiente modelo oculto de Markov M




con $\pi_{q_1} = 0.6, \pi_{q_2} = 0.4, \pi_{q_3} = \pi_{q_4} = 0$ y la cadena $aabb$, se pide:

- a) Obtén la secuencia de estados que con mayor probabilidad genera dicha cadena aplicando el algoritmo de Viterbi.

Solución


	a	a	b	b	
q_1	.30	.090	.0270	.0081	
q_2	.24	.072	.0144	.00432	
q_3		.036	.0126	.00441	
q_4					.001728



- b) Dibuja cómo quedaría el modelo de Markov y sus probabilidades después de estimarlo mediante una iteración con los resultados obtenidos en el apartado anterior.

Solución

La probabilidades iniciales quedarían como: $\pi_{q_1} = 1.0, \pi_{q_2} = \pi_{q_3} = \pi_{q_4} = 0$



32. (Examen de SIN del 28 de enero de 2014; problema 2; tiempo estimado: 30 minutos)

Tenemos un problema de clasificación de cadenas en dos clases equiprobables c_0 y c_1 . Las cadenas son de tres símbolos $x_0x_1x_2$, tal que $x_0, x_1, x_2 \in \{a, b\}$. Dado el modelo oculto de Markov M_0 asociado a la clase c_0 que aparece a la izquierda y el modelo oculto de Markov M_1 asociado a la clase c_1 que aparece a la derecha:




tal que en ambos modelos $\pi_{q_1} = 1, \pi_{q_2} = \pi_{q_3} = 0$, se pide:

- Calcula la probabilidad de la cadena abb mediante el algoritmo *forward* con ambos modelos.
- Indica en qué clase quedaría clasificada dicha cadena por máxima probabilidad a *posteriori*.

Solución

Para el primer modelo M_0 tenemos que:

	a	b	b	
q_1	.5	.125	.03125	
q_2		.175	.11725	
q_4				.0469



con una probabilidad total $p(abb|M_0) = 0.0469$. Mientras que para el segundo modelo M_1 tenemos que:

	a	b	b	
q_1	.6	.168	.04704	
q_2		.054	.02322	
q_4				.01161



con una probabilidad total $p(abb|M_1) = 0.0116$. Por lo que la cadena quedaría clasificada en la clase c_0 .