

Sistemas Inteligentes

Escuela Técnica Superior de Informática

Universitat Politècnica de València

Tema B2T7: Estimación de modelos de Markov.

índice

- 1 *Aprendizaje: estimación de probabilidades en modelos de Markov* ▷ 1
- 2 Inicialización de la re-estimación por Viterbi ▷ 10

Estimación de probabilidades de un modelo de Markov

Problema básico:

Estimar las probabilidades de un modelo de Markov, M , mediante una secuencia de cadenas de entrenamiento $Y = \{y_1, \dots, y_n\}$ extraídas independientemente de acuerdo con la ley de probabilidad $P(y|M)$.

Como las cadenas se han extraído independientemente:

$$P(Y|M) = \prod_{k=1}^n P(y_k|M)$$

El *estimador de máxima verosimilitud* de M es:

$$\hat{M} = \operatorname{argmax}_M \prod_{k=1}^n P(y_k|M) \approx \operatorname{argmax}_M \prod_{k=1}^n \tilde{P}(y_k|M)$$

Estimación mediante el algoritmo de Viterbi

Idea básica:

Analizar todas las cadenas Y , contabilizando las frecuencias de uso de las transiciones entre estados, de generación de símbolos en cada estado, etc. y normalizar adecuadamente.

Problema:

Cómo analizar las cadenas si no se conocen las probabilidades de del modelo?

Una posible solución:

1. Inicializar las probabilidades “adecuadamente”
2. Analizar cada cadena de Y mediante el algoritmo de Viterbi y obtener la secuencia de estados correspondiente
3. A partir de esta secuencia de estados, contabilizar las frecuencias requeridas.
4. Normalizar las frecuencias para obtener nuevas probabilidades del modelo
5. Repetir pasos 2-4 hasta convergencia.

Estimación mediante el algoritmo de Viterbi: ejemplo

Se dispone de tres cadenas de contorno de 4-direcciones que representan tres dígitos “*siete*” manuscritos¹.

A partir de estas cadenas se desea re-estimar las probabilidades de un modelo de Markov para estos dígitos. Utilizando el algoritmo de Viterbi se han obtenido las siguientes *secuencias óptimas de estados* para cada *cadena*:

Cadena: **aaaaaddcdcdcdcdccbabababccccb**
Secuencia óptima de estados: **1111122222222222333333333344444F**

Cadena: **aaaaaddcdcdcdccdcbbabababababcccdcb**
Secuencia óptima de estados: **111112222222222233333333334444444F**

Cadena: **aaaadcdcdcdcdcdcbabababababcccdccbaab**
Secuencia óptima de estados: **11112222222222223333333333444444444F**

¹Para mayor claridad se representan los trazos horizontales como $0=a$, $2=c$ y los verticales como $1=b$, $3=d$.

Estimación mediante el algoritmo de Viterbi: ejemplo (cont.)

$$\pi_1 = 3/3 = 1 \quad \pi_2 = \pi_3 = \pi_4 = 0$$

<i>A</i>	1	2	3	4	<i>F</i>
1	4 + 4 + 3	1 + 1 + 1	0	0	0
2	0	11 + 11 + 11	1 + 1 + 1	0	0
3	0	0	9 + 9 + 8	1 + 1 + 1	0
4	0	0	0	4 + 6 + 8	1 + 1 + 1

 \Rightarrow

<i>A</i>	1	2	3	4	<i>F</i>
1	$\frac{11}{14}$	$\frac{3}{14}$	0	0	0
2	0	$\frac{33}{36}$	$\frac{3}{36}$	0	0
3	0	0	$\frac{26}{29}$	$\frac{3}{29}$	0
4	0	0	0	$\frac{18}{21}$	$\frac{3}{21}$

<i>B</i>	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>
1	5 + 5 + 4	0	0	0
2	0	0	6 + 6 + 6	6 + 6 + 6
3	5 + 5 + 4	5 + 5 + 5	0	0
4	0 + 0 + 2	1 + 2 + 2	4 + 4 + 4	0 + 1 + 1

 \Rightarrow

<i>B</i>	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>
1	$\frac{14}{14}$	0	0	0
2	0	0	$\frac{18}{36}$	$\frac{18}{36}$
3	$\frac{14}{29}$	$\frac{15}{29}$	0	0
4	$\frac{2}{21}$	$\frac{5}{21}$	$\frac{12}{21}$	$\frac{2}{21}$

Algoritmo de reestimación por Viterbi

Input: $M^0 = (Q^0, \Sigma^0, \pi^0, A^0, B^0)$ /* Modelo inicial */
 $Y = \{y_1, \dots, y_n\}$ /* cadenas de entrenamiento */
Output: $M = (Q, \Sigma, \pi, A, B)$ /* Modelo optimizado */

$M = M^0$
repeat $M' = M$; $\pi = 0$; $A = 0$; $B = 0$
 for $k = 1$ **to** n **do**
 $m = |y_k|$ /* secuencia de estados más probable para y_k , */
 $\tilde{q}_1, \dots, \tilde{q}_m = \operatorname{argmax}_{q_1, \dots, q_m} P(y_k, q_1, \dots, q_m \mid M')$ /* por Viterbi */
 $\pi_{\tilde{q}_1}++$; $B_{\tilde{q}_1, y_{k,1}}++$ /* actualización de contadores */
 for $t = 2$ **to** m **do** $A_{\tilde{q}_{t-1}, \tilde{q}_t}++$; $B_{\tilde{q}_t, y_{k,t}}++$ **done**; $A_{\tilde{q}_m, F}++$
 done
 $s = \sum_{q \in Q} \pi_q$
 forall $q \in Q$ **do** /* normalización de contadores */
 $\pi_q = \pi_q / s$
 $a = \sum_{q' \in Q} A_{q, q'}$; **forall** $q' \in Q$ **do** $A_{q, q'} = A_{q, q'} / a$
 $b = \sum_{\sigma \in \Sigma} B_{q, \sigma}$; **forall** $\sigma \in \Sigma$ **do** $B_{q, \sigma} = B_{q, \sigma} / b$
 done
until $M = M'$

Algoritmo mediante el algoritmo de Viterbi: ejercicio

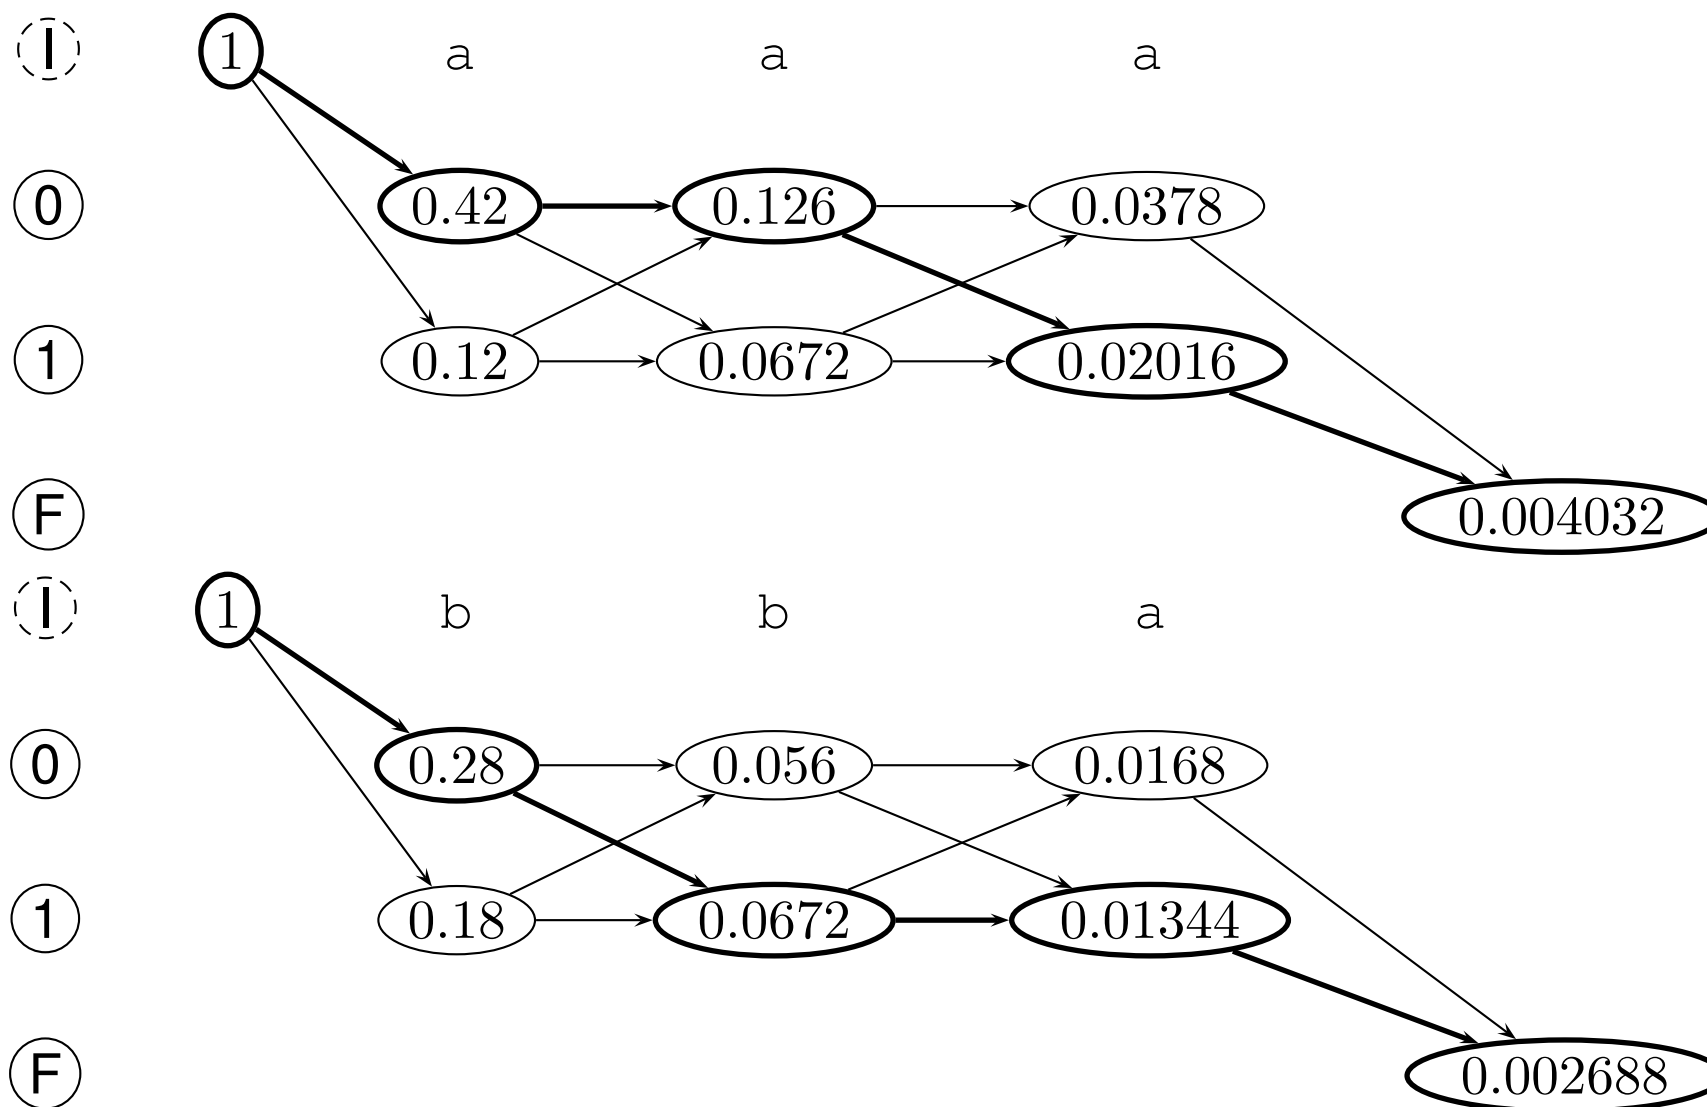
Sea M un modelo de Markov de conjunto de estados $Q = \{0, 1, F\}$; alfabeto $\Sigma = \{a, b\}$; probabilidades iniciales $\pi_0(0) = 0.7, \pi_0(1) = 0.3$; y probabilidades de transición entre estados y de emisión de símbolos:

A	0	1	F
0	0.5	0.4	0.1
1	0.3	0.5	0.2

B	a	b
0	0.6	0.4
1	0.4	0.6

Reestima los parámetros de M mediante *una* iteración de reestimación por Viterbi, a partir de las cadenas de entrenamiento “a a a” y “b b a”.

Ejercicio: secuencias de estados mas probables



Los pares *cadena-secuencia óptima de estados* obtenidos son:

a a a	b b a
0 0 1 F	0 1 1 F

Ejercicio: parámetros reestimados

$$\hat{\pi}_0(0) = \frac{2}{2} = 1$$

$$\hat{\pi}_0(1) = \frac{0}{2} = 0$$

A	0	1	F
0	$\frac{1}{3}$	$\frac{2}{3}$	0
1	0	$\frac{1}{3}$	$\frac{2}{3}$

B	a	b
0	$\frac{2}{3}$	$\frac{1}{3}$
1	$\frac{2}{3}$	$\frac{1}{3}$

índice

- 1 Aprendizaje: estimación de probabilidades en modelos de Markov ▷ 1
- 2 *Inicialización de la re-estimación por Viterbi* ▷ 10

Inicialización de la re-estimación por Viterbi

Una idea elemental: Inicializar todas las probabilidades según distribuciones equiprobables.

Problema: Suele producir problemas de convergencia o convergencia a máximos locales inadecuados.

Una idea útil para modelos lineales:

- Segmentar cada cadena de Y en tantos segmentos de (aproximadamente) la misma longitud como estados tenga el modelo de Markov.
- Asignar los símbolos de cada segmento a su correspondiente estado
- Contabilizar las frecuencias de generación y transición
- Normalizar las frecuencias para obtener probabilidades iniciales requeridas

Inicialización por segmentación lineal: Ejemplo

Obtener un modelo de Markov de $N = 3$ estados mediante segmentación lineal a partir de las cadenas

$$y_1 = \text{aabbbcc}$$

$$y_2 = \text{aaabbccc}$$

$$Q = \{1, 2, 3, F\} \quad \Sigma = \{a, b, c\}$$

$$q = \left\lfloor \frac{t \cdot N}{|y| + 1} \right\rfloor + 1 : \begin{array}{cc} \text{aabbbcc} & \text{aaabbccc} \\ 1122233 & 11222333 \end{array}$$

$$\pi_1 = \frac{2}{2}, \quad \pi_2 = \pi_3 = 0$$

A	1	2	3	F
1	$\frac{2}{4}$	$\frac{2}{4}$	0	0
2	0	$\frac{4}{6}$	$\frac{2}{6}$	0
3	0	0	$\frac{3}{5}$	$\frac{2}{5}$

B	a	b	c
1	$\frac{4}{4}$	0	0
2	$\frac{1}{6}$	$\frac{5}{6}$	0
3	0	0	$\frac{5}{5}$

Inicialización por segmentación lineal

Input: $Y = \{y_1, \dots, y_n\}$, N /* cadenas de entrenamiento, número de estados */

Output: $M = (Q, \Sigma, \pi, A, B)$ /* modelo */

$Q = \{1, 2, \dots, N, F\}$; $\Sigma = \{y \in y_k \in Y\}$ /* estados y símbolos */

$\pi = 0$; $A = 0$; $B = 0$ /* inicialización de contadores */

for $k = 1$ **to** n **do** /* actualización de contadores por */

$q = 1$; π_q++ ; $B_{q,y_{k,1}}++$ /* alineamiento lineal de y_k con los estados */

for $t = 2$ **to** $|y_k|$ **do** $q' = q$; $q = \left\lfloor \frac{t}{|y_k|+1} N \right\rfloor + 1$; $A_{q',q}++$; $B_{q,y_{k,t}}++$ **done**

$A_{q,F}++$

done

$s = \sum_{q \in Q} \pi_q$

forall $q \in Q$ **do** /* normalización de contadores */

$\pi_q = \pi_q / s$

$a = \sum_{q' \in Q} A_{q,q'}$; **forall** $q' \in Q$ **do** $A_{q,q'} = A_{q,q'} / a$

$b = \sum_{\sigma \in \Sigma} B_{q,\sigma}$; **forall** $\sigma \in \Sigma$ **do** $B_{q,\sigma} = B_{q,\sigma} / b$

done