

# Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2017

Apellidos:

Nombre:

Profesor: ☐ Jorge Civera ☐ Carlos Martínez

Cuestiones (2 puntos, 30 minutos, sin apuntes)

**A** Se define la función kernel  $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y})+1}$  siendo  $d(\mathbf{x}, \mathbf{y})$  la distancia de Hamming  $\left(d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^D 1 - \delta(x_i, y_i)\right)$ , ¿cuál de las siguientes funciones **no** es un kernel?

- A)  $K(\mathbf{x}, \mathbf{y}) = d(\mathbf{x}, \mathbf{y}) + 1$
- B)  $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y})+1} + 1$
- C)  $K(\mathbf{x}, \mathbf{y}) = e^{\frac{1}{d(\mathbf{x}, \mathbf{y})+1}}$
- D)  $K(\mathbf{x}, \mathbf{y}) = \frac{1}{2 \cdot d(\mathbf{x}, \mathbf{y})+2}$

**B** Sea el conjunto de datos:

$x_1$	0	1	1	0	0	1	1	1	1	0
$x_2$	0	0	0	1	0	1	0	0	1	1
$x_3$	1	1	0	0	1	0	0	0	1	0
c	A	A	A	A	A	B	B	B	B	B

Indica la estimación por máxima verosimilitud de los parámetros de las distribuciones de Bernoulli para las clases A y B con ese conjunto de datos.

- A)  $\mathbf{p}_A = \left(\frac{3}{5} \frac{4}{5} \frac{2}{5}\right), \mathbf{p}_B = \left(\frac{4}{5} \frac{3}{5} \frac{1}{5}\right)$
- B)  $\mathbf{p}_A = \left(\frac{2}{5} \frac{1}{5} \frac{3}{5}\right), \mathbf{p}_B = \left(\frac{4}{5} \frac{3}{5} \frac{1}{5}\right)$
- C)  $\mathbf{p}_A = \left(\frac{2}{5} \frac{1}{5} \frac{3}{5}\right), \mathbf{p}_B = \left(\frac{1}{5} \frac{2}{5} \frac{4}{5}\right)$
- D)  $\mathbf{p}_A = \left(\frac{7}{15} \frac{7}{15} \frac{7}{15}\right), \mathbf{p}_B = \left(\frac{8}{15} \frac{8}{15} \frac{8}{15}\right)$

**C** Dados el prototipo multinomial  $\hat{p} = (0.3 \ 0.0 \ 0.4 \ 0.0 \ 0.5)^t$  estimado a partir de un conjunto de vectores de cuentas, y su correspondiente prototipo multinomial suavizado  $\tilde{p} = (0.2 \ 0.15 \ 0.3 \ 0.15 \ 0.4)^t$ . ¿Qué tipo de suavizado ha sido aplicado?

- A) Laplace con  $\epsilon = 0.1$
- B) Laplace con  $\epsilon = 0.2$
- C) Descuento absoluto con  $\epsilon = 0.1$  aplicando backing-off con distribución uniforme
- D) Descuento absoluto con  $\epsilon = 0.1$  aplicando interpolación con distribución uniforme

**D** ¿Cuál de las siguientes expresiones representa un clasificador basado en el vecino más cercano?

- A)  $\hat{c}(y) = \arg \min_c \max_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- B)  $\hat{c}(y) = \arg \max_c \max_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- C)  $\hat{c}(y) = \arg \max_c \min_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- D)  $\hat{c}(y) = \arg \min_c \min_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$

**B** A diferencia de los clasificadores basados en Bayes, el clasificador  $k$ -NN:

- A) Sólo puede aplicarse a datos no vectoriales.
- B) Estima directamente  $\hat{P}(c|x)$ .
- C) Alcanza una cota de error inferior a Bayes.
- D) Crea un modelo basado en inferencia sobre los prototipos.

**D** Para que el clasificador  $k$ -NN alcance el error de Bayes, siendo  $n$  el número de prototipos:

- A) Debe usar un valor  $n$  potencialmente infinito, independientemente del  $k$  usado.
- B) Debe usar un valor  $k$  potencialmente infinito, independientemente de  $n$ .
- C) Debe usar un valores  $k$  y  $n$  potencialmente infinitos, con relación constante entre ellos.
- D) Debe usar un valores  $k$  y  $n$  potencialmente infinitos, pero con  $k$  de crecimiento mucho más lento que  $n$ .

**A** La distancia de Mahalanobis-diagonal:

- A) Equivale a prenormalizar cada componente por la desviación típica y usar distancia euclídea.
- B) Asigna pesos distintos por cada prototipo considerado.
- C) Usa las varianzas por clase.
- D) Incrementa la medida de distancia para las componentes que presentan una mayor dispersión.

**C** En general, ¿cuál de las siguientes enumeraciones de clasificadores está ordenada de mayor a menor *variance* (de izquierda a derecha)?

- A)  $k$ -NN, Multinomial, Gaussiano
- B) Gaussiano,  $k$ -NN, Multinomial
- C)  $k$ -NN, Gaussiano, Multinomial
- D) Gaussiano, Multinomial,  $k$ -NN

# Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2017

Apellidos:

Nombre:

Profesor: ☐ Jorge Civera ☐ Carlos Martínez

## Problemas (4 puntos, 90 minutos, con apuntes)

1. (1.5 puntos) Sea  $A$  y  $B$  dos clases con priors  $p(A) = 1/4$  y  $p(B) = 3/4$ , y f.d.p. condicionales de clase gaussianas  $p(\mathbf{x} | A) \sim N_2(\mu_A, \Sigma_A)$  y  $p(\mathbf{x} | B) \sim N_2(\mu_B, \Sigma_B)$

$$\mu_A = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

- a) Calcula funciones discriminantes para  $A$  y  $B$ . (0.5 puntos)  
b) Calcula la frontera de decisión entre las clases  $A$  y  $B$ . (0.5 puntos)  
c) Representa gráficamente la frontera y las regiones de decisión. (0.5 puntos)

### Solución:

- a) En el caso de matrices de covarianza común, la función discriminante se define como:

$$g_c(\mathbf{x}) = \mathbf{w}_c^t \mathbf{x} + b_c$$

donde

$$\mathbf{w}_c = \Sigma^{-1} \mu_c \quad b_c = \log P(c) - \frac{1}{2} \mu_c^t \Sigma^{-1} \mu_c$$

Las funciones discriminantes de las clases serían:

$$g_A(\mathbf{x}) = \mathbf{w}_A^t \mathbf{x} + b_A$$

$$\mathbf{w}_A = \Sigma^{-1} \mu_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$b_A = \log P(A) - \frac{1}{2} \mu_A^t \Sigma^{-1} \mu_A = \log \frac{1}{4} - \frac{1}{2} \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = -\log 4$$

$$g_A(\mathbf{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \log 4 = -\log 4$$

$$g_B(\mathbf{x}) = \mathbf{w}_B^t \mathbf{x} + b_B$$

$$\mathbf{w}_B = \Sigma^{-1} \mu_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$b_B = \log P(B) - \frac{1}{2} \mu_B^t \Sigma^{-1} \mu_B = \log \frac{3}{4} - \frac{1}{2} \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \log \frac{3}{4} - 1$$

$$g_B(\mathbf{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \log \frac{3}{4} - 1 = x_1 + x_2 + \log 3 - \log 4 - 1$$

- b) La frontera de decisión entre las clases  $A$  y  $B$  se obtiene igualando sus respectivas funciones discriminantes

$$g_A(\mathbf{x}) = g_B(\mathbf{x})$$

Por tanto,


$$-\log 4 = x_1 + x_2 + \log 3 - \log 4 - 1$$

$$0 = x_1 + x_2 + \log 3 - 1$$

$$x_2 = -x_1 - \log 3 + 1 = -x_1 - 0.1$$

que es una frontera lineal.


c)



2. (1.5 puntos) Sea la función Kernel  $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y}) + 1}$  siendo  $d(\mathbf{x}, \mathbf{y})$  la distancia de Hamming  $\left(d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^D 1 - \delta(x_i, y_i)\right)$ . Sea el conjunto de entrenamiento  $\mathbf{x}_1 = (0, 0)$ ,  $\mathbf{x}_2 = (0, 1)$ ,  $\mathbf{x}_3 = (1, 0)$ ,  $\mathbf{x}_4 = (1, 1)$ , siendo  $\mathbf{x}_1, \mathbf{x}_4 \in +1$  y  $\mathbf{x}_2, \mathbf{x}_3 \in -1$ .
- Representa gráficamente el conjunto de entrenamiento y di si es o no linealmente separable. (0.25 puntos)
  - Aplica una iteración de Kernel Perceptron partiendo de  $\alpha = (0, 0, 0, 0)$ , indicando el valor final de  $\alpha$ . (0.75 puntos)
  - ¿Cuál es el error de clasificación de la función  $g(x)$  resultante del apartado anterior sobre el conjunto de entrenamiento? (0.5 puntos)

**Solución:**

- a) Como se puede observar en la figura el conjunto de entrenamiento no es linealmente separable.



- b) La matriz de Gramm sobre el conjunto de entrenamiento para la función Kernel definida en el enunciado es

$$\mathbf{K} = \begin{matrix} & \begin{matrix} (0, 0) & (0, 1) & (1, 0) & (1, 1) \end{matrix} \\ \begin{matrix} (0, 0) \\ (0, 1) \\ (1, 0) \\ (1, 1) \end{matrix} & \begin{bmatrix} 1 & 1/2 & 1/2 & 1/3 \\ 1/2 & 1 & 1/3 & 1/2 \\ 1/2 & 1/3 & 1 & 1/2 \\ 1/3 & 1/2 & 1/2 & 1 \end{bmatrix} \end{matrix}$$

La traza del algoritmo Kernel Perceptron es la siguiente:

	$g(x)$	$g(x_i)$	$c_i$	error	$\alpha$
$x_1$	0	0	+1	Sí	(1, 0, 0, 0)
$x_2$	$K(x_1, x) + 1$	3/2	-1	Sí	(1, 1, 0, 0)
$x_3$	$K(x_1, x) + 1 - K(x_2, x) - 1$	1/6	-1	Sí	(1, 1, 1, 0)
$x_4$	$K(x_1, x) + 1 - K(x_2, x) - 1 - K(x_3, x) - 1$	-5/3	+1	Sí	(1, 1, 1, 1)

c) Considerando el vector de pesos  $\alpha = (1, 1, 1, 1)$  obtenidos, la función discriminante es:

$$g(x) = K(x_1, x) + 1 - K(x_2, x) - 1 - K(x_3, x) - 1 + K(x_4, x) + 1 \\ = K(x_1, x) - K(x_2, x) - K(x_3, x) + K(x_4, x)$$

	$g(x_i)$					$c_i$	error
$x_1$	1	-1/2	-1/2	+1/3	=	1/3	+1 No
$x_2$	1/2	-1	-1/2	+1/2	=	-1/2	-1 No
$x_3$	1/2	-1/2	-1	+1/2	=	-1/2	-1 No
$x_4$	1/3	-1/2	-1/2	+1	=	1/3	+1 No

Por tanto, el error de clasificación es cero y la función Kernel empleada proyecta el conjunto de entrenamiento a un espacio donde son linealmente separables.

3. (1 punto) Sean las siguientes muestras y clasificadores:

$$\mathbf{x}_1 = (0, 0) \in +1 \quad \mathbf{x}_2 = (2, 2) \in -1 \quad \mathbf{x}_3 = (1, 2) \in +1 \quad \mathbf{x}_4 = (0, 1) \in -1 \quad \mathbf{x}_5 = (-1, 1) \in +1$$

$$g_1(\mathbf{z}) = \begin{cases} +1 & z_1 > 0 \\ -1 & z_1 \leq 0 \end{cases} \quad g_2(\mathbf{z}) = \begin{cases} +1 & z_2 > 1 \\ -1 & z_2 \leq 1 \end{cases} \quad g_3(\mathbf{z}) = \begin{cases} +1 & z_2 - z_1 > 0 \\ -1 & z_2 - z_1 \leq 0 \end{cases} \quad g_4(\mathbf{z}) = \begin{cases} +1 & z_1 + z_2 \leq 3 \\ -1 & z_1 + z_2 > 3 \end{cases}$$

Aplica una iteración de AdaBoost para ese conjunto de datos y clasificadores indicando:

- Clasificador escogido  $C_1$ .
- Valor de  $\epsilon_1$ .
- Valor de  $\alpha_1$ .
- Actualización de los pesos para la siguiente iteración ( $w^{(2)}$ ).

**Solución:**

Tabla de acierto/fallo:

	$g_1$	$g_2$	$g_3$	$g_4$
$\mathbf{x}_1$	X	X	X	✓
$\mathbf{x}_2$	X	X	✓	✓
$\mathbf{x}_3$	✓	✓	✓	✓
$\mathbf{x}_4$	✓	✓	X	X
$\mathbf{x}_5$	X	X	✓	✓

Pesos iniciales:  $w^{(1)} = (\frac{1}{5}, \frac{1}{5}, \frac{1}{5}, \frac{1}{5}, \frac{1}{5})$

Sumatorio de los  $w^{(1)}$  de las muestras incorrectas:

$g_1$	$g_2$	$g_3$	$g_4$
$\frac{3}{5}$	$\frac{3}{5}$	$\frac{2}{5}$	$\frac{1}{5}$

$$C_1 = g_4 \\ \epsilon_1 = \frac{1}{5} \\ \alpha_1 = \frac{1}{2} \ln 4 = \ln 2$$

	$w^{(1)} \exp(-y_i \alpha_1 C_1(x_i))$
$\mathbf{x}_1$	$\frac{1}{10}$
$\mathbf{x}_2$	$\frac{1}{10}$
$\mathbf{x}_3$	$\frac{1}{10}$
$\mathbf{x}_4$	$\frac{2}{5} = \frac{4}{10}$
$\mathbf{x}_5$	$\frac{1}{10}$
Suma total	$\frac{4}{5} = \frac{8}{10}$

$$w^{(2)} = (\frac{1}{8}, \frac{1}{8}, \frac{1}{8}, \frac{1}{2}, \frac{1}{8})$$