

Derivación del problema de optimización de PCA

Percepción - ETSInf

Equivalencia del error de reconstrucción

La reconstrucción de la muestra de entrenamiento $\hat{\mathbf{x}}_n$ se formula como:

$$\hat{\mathbf{x}}_n = \bar{\mathbf{x}} + WW^t(\mathbf{x}_n - \bar{\mathbf{x}}) \quad (1)$$

donde $W \in \mathbb{R}^{D \times k}$ es la matriz proyección a k dimensiones, $(\mathbf{x}_n - \bar{\mathbf{x}}) \in \mathbb{R}^{D \times 1}$, y $\hat{\mathbf{x}}_n \in \mathbb{R}^{D \times 1}$. Teniendo en cuenta que $W = (\mathbf{w}_1 \mathbf{w}_2 \dots \mathbf{w}_k)$ es ortonormal ($\mathbf{w}_i \cdot \mathbf{w}_j = 0$ si $i \neq j$ y $\mathbf{w}_j \cdot \mathbf{w}_j = 1$), tendremos:

$$W \cdot W^t(\mathbf{x}_n - \bar{\mathbf{x}}) = \sum_{j=1}^k \mathbf{w}_j^t(\mathbf{x}_n - \bar{\mathbf{x}}) \mathbf{w}_j$$

siendo $\mathbf{w}_j \in \mathbb{R}^{D \times 1}$ y $(\mathbf{x}_n - \bar{\mathbf{x}}) \in \mathbb{R}^{D \times 1}$, el resultado de ese primer producto es un escalar resultado de proyectar $(\mathbf{x}_n - \bar{\mathbf{x}})$ por \mathbf{w}_j^t . Al escalar resultante le llamaremos z_j^n , y es el valor de la dimensión $j \in \{1, \dots, k\}$ de la proyección de \mathbf{x}_n . Por tanto, reescribimos Ec. 1 como

$$\hat{\mathbf{x}}_n = \bar{\mathbf{x}} + \sum_{j=1}^k z_j^n \mathbf{w}_j$$

donde se suma el producto de z_j^n por \mathbf{w}_j para todo $j \in \{1, \dots, k\}$, y finalmente se suma $\bar{\mathbf{x}}$.

Al ser W ortonormal, cualquier \mathbf{x}_n puede ser reconstruido *sin error* con D vectores \mathbf{w}_j . Es decir, tomando $k = D$ tendremos que $W \in \mathbb{R}^{D \times D}$ y por tanto

$$\mathbf{x}_n = \hat{\mathbf{x}}_n = \bar{\mathbf{x}} + \sum_{j=1}^D z_j^n \mathbf{w}_j^t$$

Es decir, los vectores reconstruidos son los originales¹. Esto se puede conseguir, por ejemplo, con $W = I$ (matriz identidad).

El error de reconstrucción para $k < D$ dimensiones puede calcularse como

$$\text{error}_k = \sum_{n=1}^N \|\mathbf{x}_n - \hat{\mathbf{x}}_n\|^2$$

¹Realmente lo que se obtiene son los vectores originales expresados en los ejes de coordenadas definidos por la matriz de proyección W completa.

Teniendo en cuenta que $\mathbf{x}_n = \bar{\mathbf{x}} + \sum_{j=1}^D z_j^n \mathbf{w}_j$ y $\hat{\mathbf{x}}_n = \bar{\mathbf{x}} + \sum_{j=1}^k z_j^n \mathbf{w}_j$

$$\begin{aligned}
\text{error}_k &= \sum_{n=1}^N \|\mathbf{x}_n - \hat{\mathbf{x}}_n\|^2 \\
&= \sum_{n=1}^N \left\| \left(\bar{\mathbf{x}} + \sum_{j=1}^D z_j^n \mathbf{w}_j \right) - \left(\bar{\mathbf{x}} + \sum_{j=1}^k z_j^n \mathbf{w}_j \right) \right\|^2 \\
&= \sum_{n=1}^N \left\| \sum_{j=k+1}^D z_j^n \mathbf{w}_j \right\|^2 \\
&= \sum_{n=1}^N \left(\sum_{j=k+1}^D z_j^n \mathbf{w}_j \right)^t \left(\sum_{j=k+1}^D z_j^n \mathbf{w}_j \right) \\
&= \sum_{n=1}^N \left(\sum_{j=k+1}^D z_j^n \mathbf{w}_j^t \right) \left(\sum_{j=k+1}^D z_j^n \mathbf{w}_j \right)
\end{aligned}$$

Desarrollando el sumatorio

$$\text{error}_k = \sum_{n=1}^N (z_{k+1}^n \mathbf{w}_{k+1}^t + \dots + z_D^n \mathbf{w}_D^t) (z_{k+1}^n \mathbf{w}_{k+1} + \dots + z_D^n \mathbf{w}_D)$$

Aplicando la propiedad distributiva y usando la ortonormalidad tendremos:

$$\begin{aligned}
\text{error}_k &= \sum_{n=1}^N (z_{k+1}^n \mathbf{w}_{k+1}^t) (z_{k+1}^n \mathbf{w}_{k+1} + z_{k+2}^n \mathbf{w}_{k+2} + \dots + z_D^n \mathbf{w}_D) + \\
&\quad (z_{k+2}^n \mathbf{w}_{k+2}^t) (z_{k+1}^n \mathbf{w}_{k+1} + z_{k+2}^n \mathbf{w}_{k+2} + \dots + z_D^n \mathbf{w}_D) + \dots + \\
&\quad (z_D^n \mathbf{w}_D^t) (z_{k+1}^n \mathbf{w}_{k+1} + z_{k+2}^n \mathbf{w}_{k+2} + \dots + z_D^n \mathbf{w}_D)
\end{aligned}$$

$$\begin{aligned}
&= \sum_{n=1}^N \left(z_{k+1}^n \right)^2 \mathbf{w}_{k+1}^t \mathbf{w}_{k+1} + z_{k+1}^n z_{k+2}^n \mathbf{w}_{k+1}^t \mathbf{w}_{k+2} + \dots + z_{k+1}^n z_D^n \mathbf{w}_{k+1}^t \mathbf{w}_D + \\
&\quad z_{k+2}^n z_{k+1}^n \mathbf{w}_{k+2}^t \mathbf{w}_{k+1} + \left(z_{k+2}^n \right)^2 \mathbf{w}_{k+2}^t \mathbf{w}_{k+2} + \dots + z_{k+2}^n z_D^n \mathbf{w}_{k+2}^t \mathbf{w}_D + \dots + \\
&\quad z_D^n z_{k+1}^n \mathbf{w}_D^t \mathbf{w}_{k+1} + z_D^n z_{k+2}^n \mathbf{w}_D^t \mathbf{w}_{k+2} + \dots + \left(z_D^n \right)^2 \mathbf{w}_D^t \mathbf{w}_D \\
&= \sum_{n=1}^N \left(z_{k+1}^n \right)^2 + \left(z_{k+2}^n \right)^2 + \dots + \left(z_D^n \right)^2 = \sum_{n=1}^N \sum_{j=k+1}^D \left(z_j^n \right)^2
\end{aligned}$$

Retomando el valor de $z_j^n = \mathbf{w}_j^t (\mathbf{x}_n - \bar{\mathbf{x}})$

$$\begin{aligned}
\text{error}_k &= \sum_{n=1}^N \sum_{j=k+1}^D \left(z_j^n \right)^2 = \sum_{n=1}^N \sum_{j=k+1}^D \left(\mathbf{w}_j^t (\mathbf{x}_n - \bar{\mathbf{x}}) \right)^2 \\
&= \sum_{n=1}^N \sum_{j=k+1}^D \mathbf{w}_j^t (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^t \mathbf{w}_j
\end{aligned}$$

Intercambiando sumatorios

$$\text{error}_k = \sum_{j=k+1}^D \sum_{n=1}^N \mathbf{w}_j^t (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^t \mathbf{w}_j$$

Como las \mathbf{w}_j son independientes de n se pueden sacar del sumatorio interno, con lo cual

$$\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \left(\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^t \right) \mathbf{w}_j$$

Dado que la matriz de covarianzas de los datos $\Sigma_{\mathcal{X}} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) (\mathbf{x}_n - \bar{\mathbf{x}})^t$, queda finalmente que

$$\text{error}_k = N \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

Para la derivación del error, se optimiza respecto a la matriz de proyección W . Por tanto, no hay dependencia del número de datos N , por lo que generalmente usaremos:

$$\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

Derivada del error de reconstrucción

Nuestra función objetivo a minimizar es el error de reconstrucción $\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$ mediante la matriz de proyección W a k dimensiones. Así, el problema de optimización se formula como

$$\widehat{W} = \underset{W \in \mathbb{R}^{D \times k}}{\operatorname{argmin}} \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j = \underset{W \in \mathbb{R}^{D \times k}}{\operatorname{argmax}} \sum_{j=1}^k \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

Simplificando el problema anterior al caso de la proyección del conjunto de entrenamiento a una única dimensión dado por \mathbf{w} , esto se puede formular como

$$\hat{\mathbf{w}} = \underset{\mathbf{w} \in \mathbb{R}^D}{\operatorname{argmax}} \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} \quad \text{sujeto a que} \quad \mathbf{w}^t \mathbf{w} = 1$$

Este es un problema de maximización con restricciones que puede formularse a través de los multiplicadores de Lagrange, de forma que queda como

$$\hat{\mathbf{w}} = \underset{\mathbf{w} \in \mathbb{R}^D}{\operatorname{argmax}} \max_{\lambda \in \mathbb{R}} \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})$$

Para la optimización se procede a derivar e igualar a cero. Para ello, primero debemos identificar el tipo de función E que vamos a derivar, que en este caso es

$$E = \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})$$

Por análisis de dimensiones se puede observar que ambos términos son escalares. Ahora se debe proceder a la derivación respecto a cada una de las variables de optimización: el vector de proyección \mathbf{w} y el multiplicador de Lagrange λ .

Derivada respecto a λ

La derivada respecto al multiplicador de Lagrange λ , que es un escalar, es trivial. La derivada del primer término es cero y la derivada del segundo resulta en

$$\frac{\partial E}{\partial \lambda} = 1 - \mathbf{w}^t \mathbf{w} = 0 \rightarrow \mathbf{w}^t \mathbf{w} = 1$$

Simplemente nos recuerda que \mathbf{w} debe ser de módulo unitario

Derivada respecto a \mathbf{w}

La derivada de la función escalar E respecto al vector $\mathbf{w} = (w_1 \cdots w_D)^t$ es

$$\frac{\partial E}{\partial \mathbf{w}} = \left(\frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \dots, \frac{\partial E}{\partial w_D} \right)$$

Resulta en un vector fila donde la componente j es la derivada de E respecto a w_j . Por simplicidad, hagamos la derivada respecto a w_1 desarrollando E

$$\frac{\partial E}{\partial w_1} = \frac{\partial \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})}{\partial w_1} = \frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_1} + \frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_1}$$

Haciendo primero la derivada del segundo sumando

$$\begin{aligned} \frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_1} &= \lambda \frac{\partial (1 - \sum_{i=1}^D w_i^2)}{\partial w_1} \\ &= \lambda \frac{\partial (1 - (w_1^2 + w_2^2 + \dots + w_D^2))}{\partial w_1} = \lambda (-2w_1) = -2\lambda w_1 \end{aligned}$$

En general, tendríamos $\frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_j} = -2\lambda w_j$, con lo cual, si realizáramos la derivada del segundo término respecto al vector \mathbf{w} completo se obtiene

$$\frac{\partial \lambda (1 - (w_1^2 + w_2^2 + \dots + w_D^2))}{\partial \mathbf{w}} = (-2\lambda w_1, -2\lambda w_2, \dots, -2\lambda w_D) = -2\lambda \mathbf{w}^t$$

Respecto a la derivada del primer sumando

$$\begin{aligned} \frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_1} &= \\ &= \frac{\partial (\sum_{j=1}^D w_1 \Sigma_{1j} w_j + \sum_{j=1}^D w_2 \Sigma_{2j} w_j + \dots + \sum_{j=1}^D w_D \Sigma_{Dj} w_j)}{\partial w_1} \\ &= \frac{\partial (w_1 \Sigma_{11} w_1 + w_1 \Sigma_{12} w_2 + \dots + w_1 \Sigma_{1D} w_D)}{\partial w_1} + \\ &\quad \frac{\partial (w_2 \Sigma_{21} w_1 + w_2 \Sigma_{22} w_2 + \dots + w_2 \Sigma_{2D} w_D)}{\partial w_1} + \dots + \\ &\quad \frac{\partial (w_D \Sigma_{D1} w_1 + w_D \Sigma_{D2} w_2 + \dots + w_D \Sigma_{DD} w_D)}{\partial w_1} \\ &= (2w_1 \Sigma_{11} + \Sigma_{12} w_2 + \dots + \Sigma_{1D} w_D) + w_2 \Sigma_{21} + \dots + w_D \Sigma_{D1} \\ &= (\Sigma_{11} w_1 + \Sigma_{12} w_2 + \dots + \Sigma_{1D} w_D) + (w_1 \Sigma_{11} + w_2 \Sigma_{21} + \dots + w_D \Sigma_{D1}) \\ &= \sum_{j=1}^D \Sigma_{1j} w_j + \sum_{i=1}^D w_i \Sigma_{i1} \end{aligned}$$

Teniendo en cuenta que $\Sigma_{\mathcal{X}}$ es simétrica y, por tanto, $\Sigma_{ij} = \Sigma_{ji}$, queda como

$$2 \sum_{i=1}^D w_i \Sigma_{i1} = 2 \mathbf{w}^t \Sigma_{\bullet 1}$$

Donde $\Sigma_{\bullet i}$ indica la i -ésima columna de $\Sigma_{\mathcal{X}}$. Por tanto, en general para cualquier w_k tendríamos que

$$\frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_k} = 2\mathbf{w}^t \Sigma_{\bullet k}$$

Por tanto, si realizáramos la derivada del primer término respecto al vector \mathbf{w} completo tendríamos

$$\frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial \mathbf{w}} = (2\mathbf{w}^t \Sigma_{\bullet 1}, 2\mathbf{w}^t \Sigma_{\bullet 2}, \dots, 2\mathbf{w}^t \Sigma_{\bullet D}) = 2\mathbf{w}^t \Sigma_{\mathcal{X}}$$

En consecuencia, la derivada de E respecto a \mathbf{w} queda como

$$\frac{\partial E}{\partial \mathbf{w}} = 2\mathbf{w}^t \Sigma_{\mathcal{X}} - 2\lambda \mathbf{w}^t$$

Al igualar a cero

$$2\mathbf{w}^t \Sigma_{\mathcal{X}} - 2\lambda \mathbf{w}^t = 0 \rightarrow 2\mathbf{w}^t \Sigma_{\mathcal{X}} = 2\lambda \mathbf{w}^t \rightarrow \mathbf{w}^t \Sigma_{\mathcal{X}} = \lambda \mathbf{w}^t \rightarrow \Sigma_{\mathcal{X}} \mathbf{w} = \lambda \mathbf{w}$$

Es decir, \mathbf{w} es un vector propio con λ valor propio asociado.