# TEMA 4. MODELO DE ESPACIO VECTORIAL

# Contenidos

1. Conceptos previos.
   - 1.1 Recuperación ordenada.
   - 1.2 Puntuación de documentos.
   - 1.3 Frecuencia del término y su pesado.
   - 1.4 Frecuencia de documento.
2. Modelo de Espacio Vectorial
   - 2.1 Documentos como vectores
   - 2.2 Consultas como vectores
   - 2.3 Medir la similitud entre dos documentos en el espacio vectorial.
   - 2.4 Esquemas de pesado.

# Bibliografía


***A Introduction to Information Retrieval**:*
*Christopher D. Manning, Prabhakar Raghavan, Hinrich Schütze.*
*Cambridge University Press, **2009**.*
***Capítulo 6***

***Speech and Language Processing**: International Version, 2/E.*
*Daniel Jurafsky, James H. Martin.*
*Pearson International Edition, **2009**. ISBN-10: 0135041961.*
***Capítulo 23***

# 1. CONCEPTOS PREVIOS

1.1 Recuperación ordenada.

1.2 Puntuación de documentos.

1.3 Frecuencia del término y su pesado.

1.4 Frecuencia de documento.

.

# 1.1 Recuperación ordenada

Dada una consulta q y una colección C:

q: expresiones y operadores correspondientes a un lenguaje de consultas específico,

Recuperación booleana 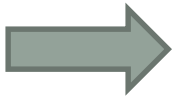

El sistema devuelve: un conjunto de documentos que satisfacen la expresión lógica correspondiente a la consulta (Las consultas Booleanas a menudo obtienen muy pocos o demasiados resultados)

q: texto plano (free text), forma asociada a la recuperación ordenada.

Recuperación ordenada 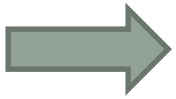

El sistema devuelve: un conjunto de documentos de la colección ordenado según relevancia.

- Objetivo: devolver en orden los documentos que con mayor probabilidad sean los más útiles para el usuario.

- Cuando el sistema genera un conjunto de resultados ordenados, el tamaño del conjunto resultante no es un problema:
  - Mostramos del resultado sólo el tope *K* ( ≈ 10).
  - No abrumamos al usuario
  - Premisa: el algoritmo de ordenación funciona.

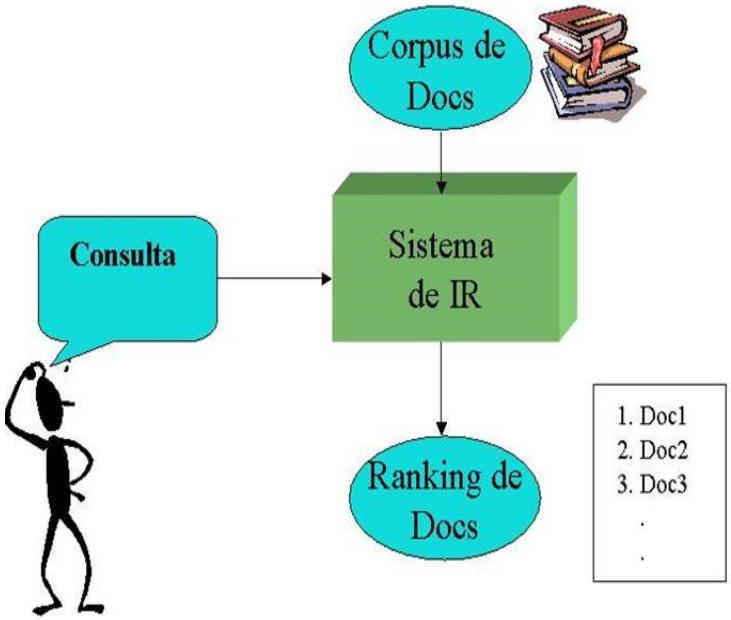

# 1.2 Puntuación (score) de documentos

## ¿Cómo ordenar documentos respecto a una consulta?

- Asignar una puntuación – dentro del rango [0, 1] – para cada documento es la base de la Recuperación ordenada de documentos.

- Esta puntuación mide cómo de bien “se emparejan“ el documento y la consulta.

# Emparejamiento Consulta-documento

Asignar una puntuación a un par (consulta, documento):

se basará en el peso de los términos de la consulta *q* en el documento *d.*

Para un término *t* de la consulta *q*:

- Si *t* no se encuentra en *d* → la puntuación será 0.
- ¿Cuanto más frecuente sea el *t* de la consulta *q* en el documento *d* más alta será la puntuación del *d?.*
- Estudiaremos alternativas para esto

# Métricas para puntuar dos conjuntos A y B

- **Solapamiento:**

  $$\text{overlap}(A,B) = |A \cap B|$$

  no está normalizado (prima los documentos mas grandes)

- **Coeficiente de Jaccard**:

  $$\text{jaccard}(A,B) = |A \cap B| \,/\, |A \cup B|$$

  $$\text{jaccard}(A,A) = 1$$

  $$\text{jaccard}(A,B) = 0 \quad \text{si} \quad A \cap B = 0$$

  - $A$ y $B$ no tienen porqué ser del mismo tamaño.
  - siempre se asigna un valor entre 0 y 1.

**Ejercicio#1**:Calcula la puntuación correspondiente al par consulta-documento calculado según overlap y jaccard,

Consulta: ***días*** *de* ***lluvia*** *en* ***primavera***
Documento 1: ***resbaló*** *en un* ***día*** *de* ***lluvia***
Documento 2: *la* ***lluvia ácida*** *es muy* ***perjudicial*** *para los* ***árboles****, sobre todo en la* ***primavera*** *que es cuando* ***florecen.***

# Ejercicio#1_Solución:

Calcula la puntuación correspondiente al par consulta-documento calculado según overlap y jaccard,

Consulta: ***días*** *de* ***lluvia*** *en* ***primavera***
Documento 1: ***resbaló*** *en un* ***día*** *de* ***lluvia***
Documento 2: *la* ***lluvia ácida*** *es muy* ***perjudicial*** *para los* ***árboles****, sobre todo en la* ***primavera*** *que es cuando* ***florecen.***

overlap$(q,d1) = |Q \cap D1| = 2$
overlap$(q,d2) = |Q \cap D2| = 2$

jaccard$(q,d1) = |Q \cap D1| / |Q \cup D1| = 2/4$
jaccard$(q,d2) = |Q \cap D2| / |Q \cup D2| = 2/7$

Nótese que $|Q \cap D|$ representa el número de términos que coinciden.

# Recordemos…

## Matriz Incidencia Binaria término-documento

Cada documento (término) se representa por un vector binario $\in \{0,1\}^{|V|}$

| | Antony and Cleopatra | Julius Caesar | The Tempest | Hamlet | Othello | Macbeth |
|---|---|---|---|---|---|---|
| Antony | 1 | 1 | 0 | 0 | 0 | 1 |
| Brutus | 1 | 1 | 0 | 1 | 0 | 0 |
| Caesar | 1 | 1 | 0 | 1 | 1 | 1 |
| Calpurnia | 0 | 1 | 0 | 0 | 0 | 0 |
| Cleopatra | 1 | 0 | 0 | 0 | 0 | 0 |
| mercy | 1 | 0 | 1 | 1 | 1 | 1 |
| worser | 1 | 0 | 1 | 1 | 1 | 0 |

**Ejemplo.**

Consulta: Brutus AND Caesar AND NOT Calpurnia,

110100 AND 110111 AND 101111 (Compl. De Calpurnia)= 100100

Respuesta: "*Antony and Cleopatra* " y "*Hamlet*"

Todos los términos se consideran igual de importantes para evaluar su relevancia sobre una consulta.

# Matriz contador término-documento

Considera el número de ocurrencias de un término en un documento:

| | Antony and Cleopatra | Julius Caesar | The Tempest | Hamlet | Othello | Macbeth |
|---|---|---|---|---|---|---|
| Antony | 157 | 73 | 0 | 0 | 0 | 0 |
| Brutus | 4 | 157 | 0 | 1 | 0 | 0 |
| Caesar | 232 | 227 | 0 | 2 | 1 | 1 |
| Calpurnia | 0 | 10 | 0 | 0 | 0 | 0 |
| Cleopatra | 57 | 0 | 0 | 0 | 0 | 0 |
| mercy | 2 | 0 | 3 | 5 | 5 | 1 |
| worser | 2 | 0 | 1 | 1 | 1 | 0 |

- Cada documento se representa por un vector contador en $\mathbb{N}^{|V|}$: una columna de la matriz
- La frecuencia de *t* en *d* es considerado para evaluar su relevancia sobre una consulta (Mod. Boleano: si f>0 peso=1 sino peso= 0).

- La representación mediante un vector no considera el orden de las palabras en un documento.

- *Julia es mas valiente que Pedro* y *Pedro es mas valiente que Julia* *representan el mismo vector.*

- Esto es conocido como modelo de *Bolsa de Palabras (Bag of words)*.

# 1.3 Frecuencia del término($f_{t,d}$) y su pesado($tf_{t,d}$)

- La **frecuencia** del término *t* en el documento *d* ($f_{t,d}$): se define como el número de veces que *t* ocurre en *d*.

¿Cómo podemos usar *f* cuando calculamos la puntuación del par consulta-documento?

Un documento con 10 ocurrencias del término es más relevante que un documento con 1 ocurrencia,…PERO NO 10 VECES MÁS.

- La relevancia no se incrementa proporcionalmente con su frecuencia, en caso contrario se primaría los documentos de mayor talla.

El **peso** de la frecuencia del término *t* en *d* se representa por $\mathrm{tf}_{t,d}$

- El pesado ***log*** (muy extendido):

$$tf_{t,d} = \begin{cases} 1 + \log_{10} \mathrm{f}_{t,d}, & \text{si } \mathrm{f}_{t,d} > 0 \\ 0, & \text{otro caso} \end{cases}$$

$$f_{t,d} \rightarrow tf_{t,d}: \; 0 \rightarrow 0,\; 1 \rightarrow 1,\; 2 \rightarrow 1.3,\; 10 \rightarrow 2,\; 1000 \rightarrow 4,..$$

# **Puntuación** para el par consulta-documento.

- Es la suma de los pesos de los términos *t que aparecen* en ambos *q* y *d*:

$$\text{puntuación} = \sum_{t \in q \cap d} (\text{tf}_{t,d})$$

- Con un pesado tomando ***log***

$$\text{puntuación} = \sum_{t \in q \cap d} (1 + \log \text{f}_{t,d})$$

- La puntuación es 0 si ninguno de los términos de la consulta se encuentra en el documento.

# 1.4. Frecuencia de documento

- Los términos raros son más informativos que los términos frecuentes.

- Considera un término en la consulta que sea raro en la colección (p.e., *diplodocus*) → Un documento conteniendo este término raro es muy probable que sea relevante para la consulta.

Deseable asignar un peso alto para términos raros.

- Los términos frecuentes son menos informativos que los raros (véase las stop words).

- Considera un término en la consulta que sea frecuente en la colección de la industria automovilística (p.e., *coche*)

  - Un documento conteniendo este término es más probable que sea relevante para la consulta que otro que no lo tenga, pero esto no puede ser el único indicador de relevancia.

  - Para términos frecuentes deseamos un peso alto pero más bajo que para los términos raros.

Usaremos la frecuencia de documento (***df***) para capturarlo.

# Peso idf

- **$df_t$** es la frecuencia de documento de *t*: el número de documentos de la colección que contienen el término *t*
  - $df_t \leq N$
  - *siendo N el número total de documentos de la colección.*

- Definimos **$idf_t$** (frecuencia de documento inversa de *t*),

$$idf_t = \log_{10}(N/df_t)$$

$idf_t$ es 0 para los términos que aparecen en todos los documentos

# Ejercicio#2. Calcular idf de los términos (nºdocs *N* =1 millón)

| term | $df_t$ | $idf_t$ |
|---|---|---|
| calpurnia | 1 | 6 |
| animal | 100 | 4 |
| sunday | 1,000 | 3 |
| fly | 10,000 | 2 |
| under | 100,000 | 1 |
| the | 1,000,000 | 0 |

$$\text{idf}_t = \log\left(N/\text{df}_t\right)$$

Hay un valor idf para cada término *t* en una colección.

log 1=0; log 10=1; log 100=2; log 1.000=3; log 10.000=4; log 100.000 = 5; log 1.000.000=6….

# Efecto de idf sobre la ordenación

- idf afecta a la ordenación de documentos para consultas con al menos dos términos.

- Ejemplo.

  q: persona caprichosa,

las ocurrencias de caprichosa contarán mucho más en la ordenación final que las ocurrencias de persona.

# Pesado tfxidf$_{t,d}$

El peso **tfxidf** (nombrado alternativamente tf.idf o tf-idf ) de un término t es el producto de su peso tf y su peso idf.

$$w_{t,d} = tf_{t,d} \times idf_t = (1 + \log(f_{t,d})) \times \log(N / df_t)$$

**tfxidf$_{t,d}$** asigna a un término ***t*** un peso en el documento *d*, tal que es:

1. Alto cuando *t* sucede muchas veces dentro de un pequeño número de documentos.
2. Bajo cuando *t* sucede muy pocas veces, o cuando sucede en muchos documentos.
3. El más bajo cuando *t* sucede en todos los documentos.

# 2. MODELO DE ESPACIO VECTORIAL

2.1 Documentos como vectores

2.2 Consultas como vectores

2.3 Medir la similitud entre dos documentos en el espacio vectorial.

2.4 Esquemas de pesado.

# Modelo de Espacio Vectorial

Las consultas y los documentos se representan como vectores en un espacio V-dimensional común.

V = nº de términos diferentes de la colección

Un eje por cada término

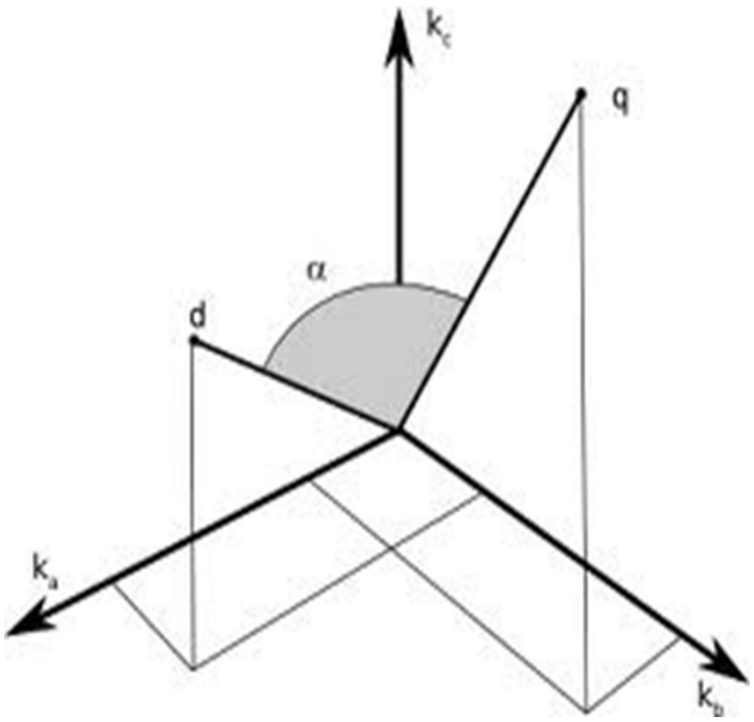


Modelo estándar en RI para:

- puntuación de documentos sobre una consulta,
- clasificación de documentos,
- agrupación de documentos.

# Ejemplo:

Receta de pollo frito ($d_j$): aparecen los términos `chicken`, `fried`, `oil` y `pepper` con frecuencias 8, 2, 7 y 4 respectivamente.

Receta de pollo escalfado ($d_k$): aparece el término `chicken` 6 veces

Consulta ($q$): `fried, chicken`

- Representamos las recetas *y la consulta como vectores:*

$$\vec{q} = (1,1,0,0) \quad \vec{d}_j = (8,2,7,4) \quad \vec{d}_k = (6,0,0,0)$$

- La colección se representa como una matriz de términos:

$$A = \begin{pmatrix} 8 & 6 \\ 2 & 0 \\ 7 & 0 \\ 4 & 0 \end{pmatrix}$$

# Documentos y consulta como puntos en el mismo espacio vectorial

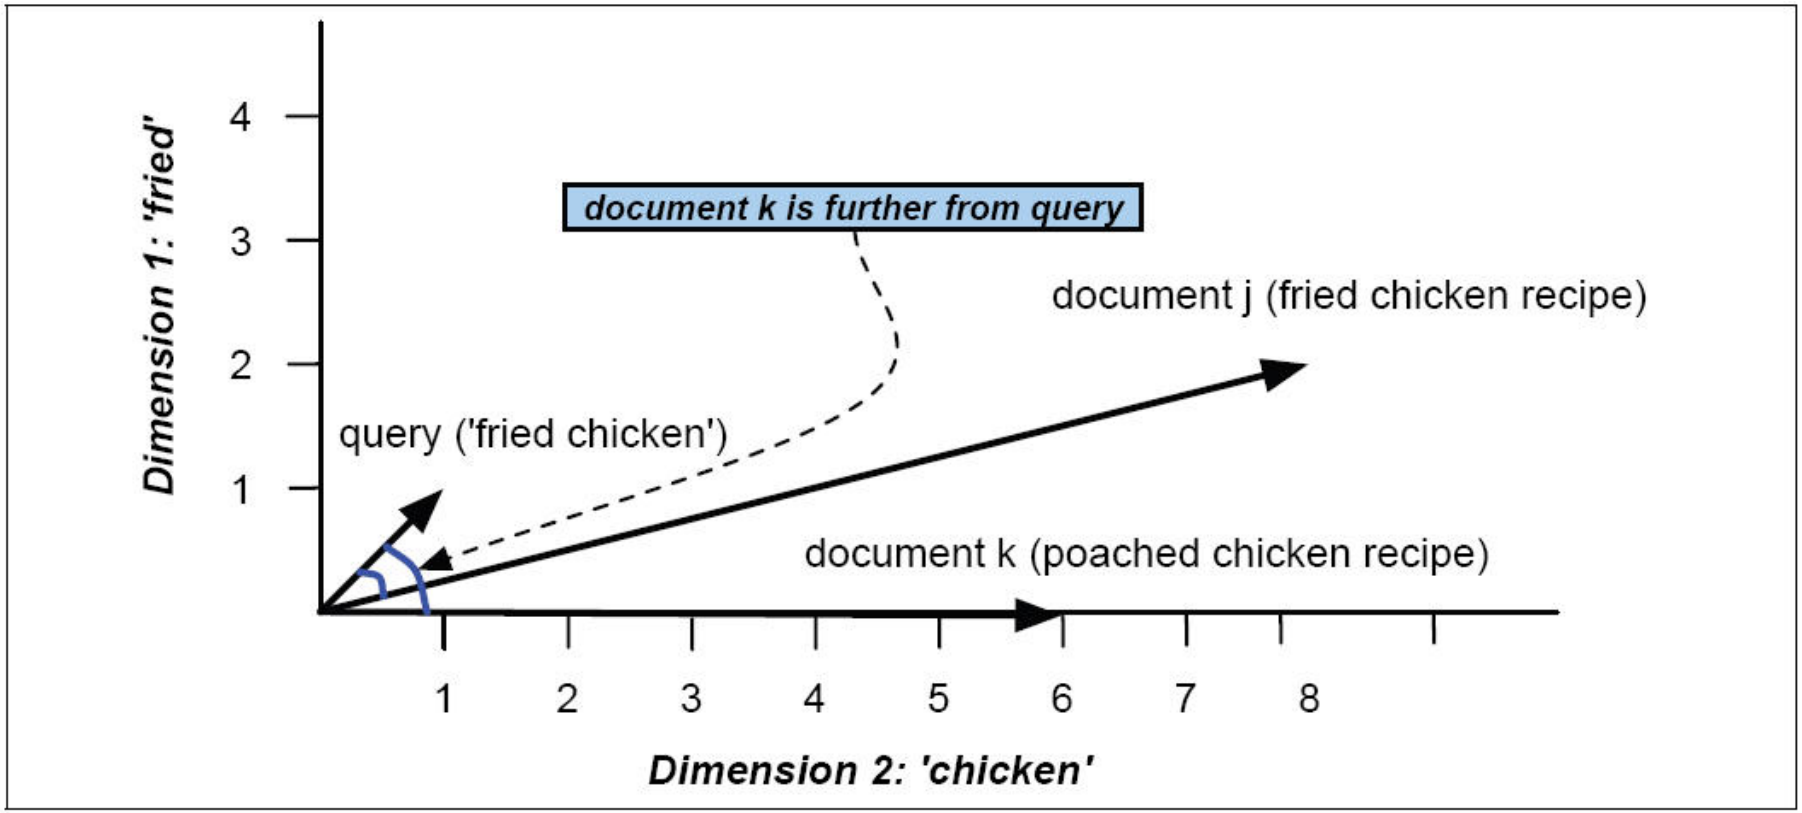

# 2.1 Documentos como vectores

- Así tenemos un espacio vectorial de |V|-dimensiones.
- Los términos son los ejes del espacio.
- Los documentos son puntos o vectores en este espacio.
- Muy alta-dimensión: decenas de millones de dimensiones cuando se aplica a un motor de búsqueda web.
- Son vectores muy dispersos, la mayoría de las entradas son cero.

# Matriz binaria → contador → pesos

| | Antony and Cleopatra | Julius Caesar | The Tempest | Hamlet | Othello | Macbeth |
|---|---|---|---|---|---|---|
| Antony | 5.25 | 3.18 | 0 | 0 | 0 | 0.35 |
| Brutus | 1.21 | 6.1 | 0 | 1 | 0 | 0 |
| Caesar | 8.59 | 2.54 | 0 | 1.51 | 0.25 | 0 |
| Calpurnia | 0 | 1.54 | 0 | 0 | 0 | 0 |
| Cleopatra | 2.85 | 0 | 0 | 0 | 0 | 0 |
| mercy | 1.51 | 0 | 1.9 | 0.12 | 5.25 | 0.88 |
| worser | 1.37 | 0 | 0.11 | 4.15 | 0.25 | 1.95 |

Cada documento se representa por un vector con los valores de pesos tfxidf $\in \mathbb{R}^{|V|}$

# 2.2 Consultas como vectores

- Paso1: representar las consultas como vectores en el espacio.

- Paso 2: ordenar los documentos de acuerdo a su proximidad a la consulta en este espacio.
  - proximidad = similitud de vectores
  - proximidad ≈ inversa de distancia

- Objetivo: ordenar los documentos más relevantes para la consulta de mayor a menor similitud

# 2.3 Medir la similitud entre dos documentos en el espacio vectorial.

- Uso del ángulo en vez de la distancia: El ángulo entre los dos documentos es 0 cuando se alcanza la similitud máxima.
- La distancia euclídea entre dos documentos "semánticamente" similares puede ser muy alta si son de longitudes muy diferentes. En cambio su ángulo se acercará a 0.

- **Objetivo**: Ordenar los documentos de acuerdo al ángulo con la consulta.

# Desde ángulos a cosenos

- Las dos nociones siguientes son equivalentes:
  - Ordenar documentos en orden creciente del ángulo entre la consulta y el documento
  - Ordenar documentos en orden decreciente del coseno entre la consulta y el documento (*cos* (0)=1)

- Coseno es una función monótona decreciente para el intervalo [$0^o$, $180^o$]

# ¿Qué documento es más similar a la consulta? Razonar la respuesta respecto al ángulo y el coseno.

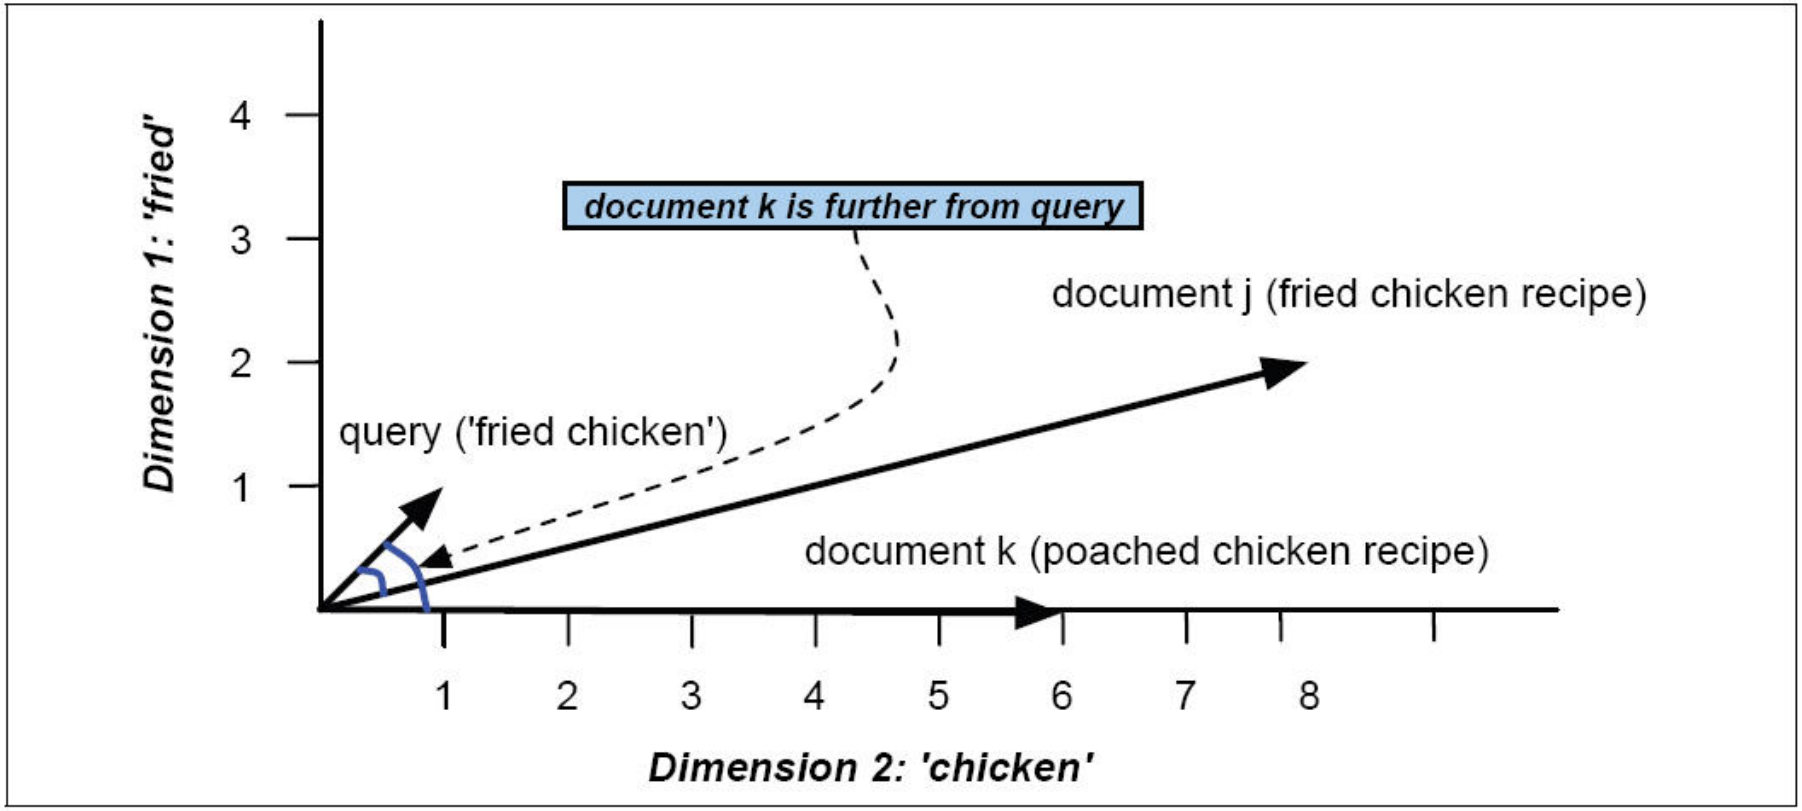

# Longitud-Normalización

Experimento: Si a un documento d le añadimos su propio contenido obteniendo el documento d′:

- “Semánticamente” d y d′ tienen el mismo contenido.
- La distancia entre los dos documentos puede ser grande por la distinta longitud de ambos documentos.

Necesitamos normalizar los vectores correspondientes a ambos documentos en función de su longitud.

# Longitud-Normalización

- Un vector puede normalizarse dividiendo cada uno de sus componentes por su longitud – para esto usamos la norma $L_2$ de dicho vector:

$$\|\vec{x}\|_2 = \sqrt{\sum_i x_i^2}$$

- De esta forma, los documentos d y d′ (d añadido a sí mismo) serían vectores idénticos después de la Longitud-normalización.
  - documentos largos y cortos ahora tienen pesos comparables.

# Coseno (consulta,documento)

producto escalar

Vectores normalizados

$$\cos(\vec{q},\vec{d}) = \frac{\vec{q} \bullet \vec{d}}{|\vec{q}||\vec{d}|} = \frac{\vec{q}}{|\vec{q}|} \bullet \frac{\vec{d}}{|\vec{d}|} = \frac{\sum_{i=1}^{|k|} q_i d_i}{\sqrt{\sum_{i=1}^{|k|} q_i^2} \sqrt{\sum_{i=1}^{|k|} d_i^2}}$$

$q_i$ representa el peso del término *i* en la consulta q ($w_{tq}$)
$d_i$ representa el peso del término *i* en el documento d ($w_{td}$)

# Coseno para vectores Longitud-normalizados

Para vectores Longitud-normalizados, la similitud del coseno es simplemente el producto punto (o producto escalar):

$$\cos(\vec{q},\vec{d}) = \vec{q} \bullet \vec{d} = \sum_{i=1}^{|V|} q_i d_i$$

# Similitud coseno entre 3 documentos

Cómo de similares son las novelas

SaS: *Sense and Sensibility*

PaP: *Pride and Prejudice*

WH: *Wuthering Heights*?

| term | SaS | PaP | WH |
|---|---|---|---|
| affection | 115 | 58 | 20 |
| jealous | 10 | 7 | 11 |
| gossip | 2 | 0 | 6 |
| wuthering | 0 | 0 | 38 |

Frecuencia de términos (conteo)

Para simplificar no hemos usado el idf

# Similitud coseno entre 3 documentos cont.

$$\cos(\vec{q},\vec{d}) = \vec{q} \bullet \vec{d} = \sum_{i=1}^{|V|} q_i d_i$$

Pesado **log frecuencia**

| term | SaS | PaP | WH |
|---|---|---|---|
| affection | 3.06 | 2.76 | 2.30 |
| jealous | 2.00 | 1.85 | 2.04 |
| gossip | 1.30 | 0 | 1.78 |
| wuthering | 0 | 0 | 2.58 |

Long-normalización de vectores

| term | SaS | PaP | WH |
|---|---|---|---|
| affection | 0.789 | 0.832 | 0.524 |
| jealous | 0.515 | 0.555 | 0.465 |
| gossip | 0.335 | 0 | 0.405 |
| wuthering | 0 | 0 | 0.588 |

cos(SaS,PaP)≈0.789 × 0.832 + 0.515 × 0.555 + 0.335 × 0.0 + 0.0 × 0.0 ≈ 0.94
cos(SaS,WH) ≈ 0.79
cos(PaP,WH) ≈ 0.69

# Cálculo puntuación coseno

## ALGORITMO PUNTUACIÓN_COSENO (q)

1. *Scores*[*N*] ← 0 /*N es el número de documentos
2. Inicializa *Length*[*N*]
3. **para cada** término *t* de *q*
4. **hacer** calcular $w_{t,q}$ **and** recorrer postings list para *t*
5. **para cada** par(*d*, $tf_{t,d}$) in postings list
6. **hacer** Scores [*d*]+= $w_{t,d}$ x $w_{t,q}$
7. **para cada** *d*
8. **hacer** *Scores*[*d*] =*Scores*[*d*] / *Length*[*d*]
9. **devuelve** los *K* componentes mejor puntuados de *Scores*[ ]

# Cálculo puntuación coseno

Scores

| $d_1$ | $d_2$ | … | $d_i$ | … | $d_N$ |
|---|---|---|---|---|---|
| 0 | 0 | | 0 | | 0 |

q

| | |
|---|---|
| $t_1$ | 0 |
| $t_2$ | 2 |
| … | |
| $t_n$ | 1 |
| … | |
| $t_V$ | 0 |

Índice invertido

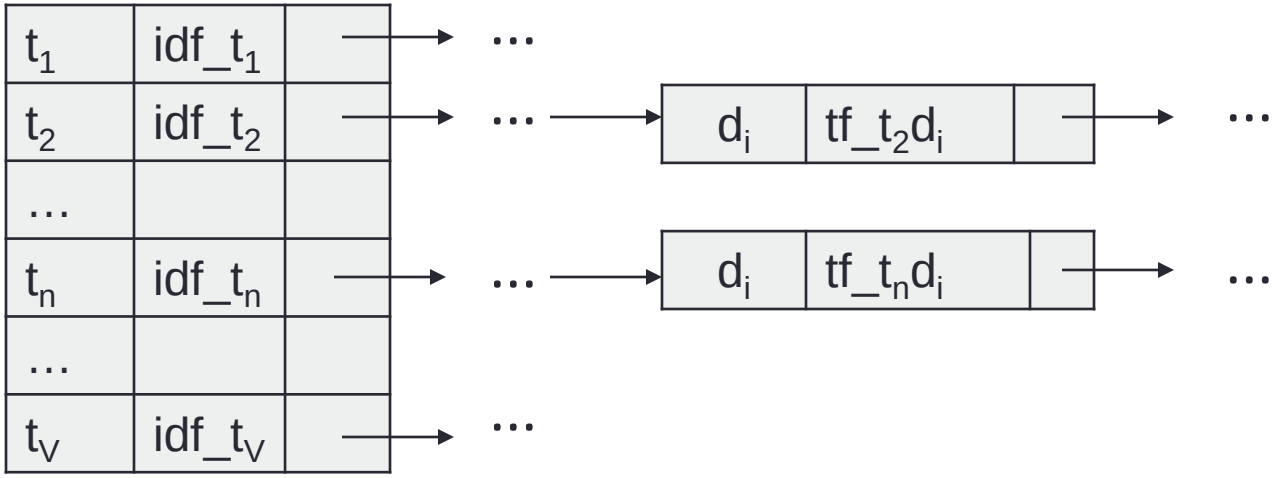

# Cálculo puntuación coseno

Scores

| $d_1$ | $d_2$ | … | $d_i$ | … | $d_N$ |
|---|---|---|---|---|---|
| | | | $w\_t_2q \times w\_t_2d_i$ | | |

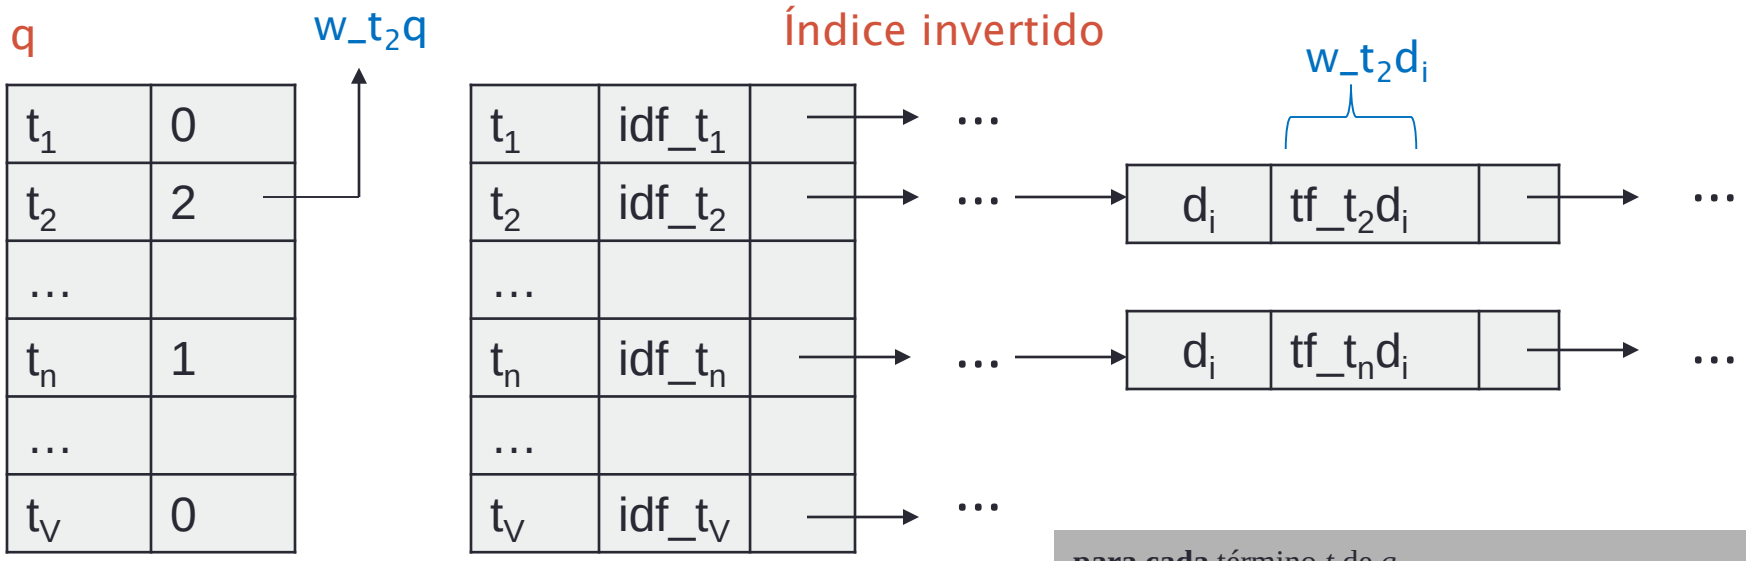


**para cada** término *t* de *q*
**hacer** calcular $w_{t,q}$ **and** recorrer postings list para *t*
**para cada** par(*d*, $tf_{t,d}$) in postings list
**hacer** Scores [*d*]+= $w_{t,d}$ x $w_{t,q}$
**para cada** *d*

# Cálculo puntuación coseno

Scores

| $d_1$ | $d_2$ | … | $d_i$ | … | $d_N$ |
|---|---|---|---|---|---|
| | | | $(w\_t_2q \times w\_t_2d_i) + \cdots + (w\_t_nq \times w\_t_nd_i)$ | | |

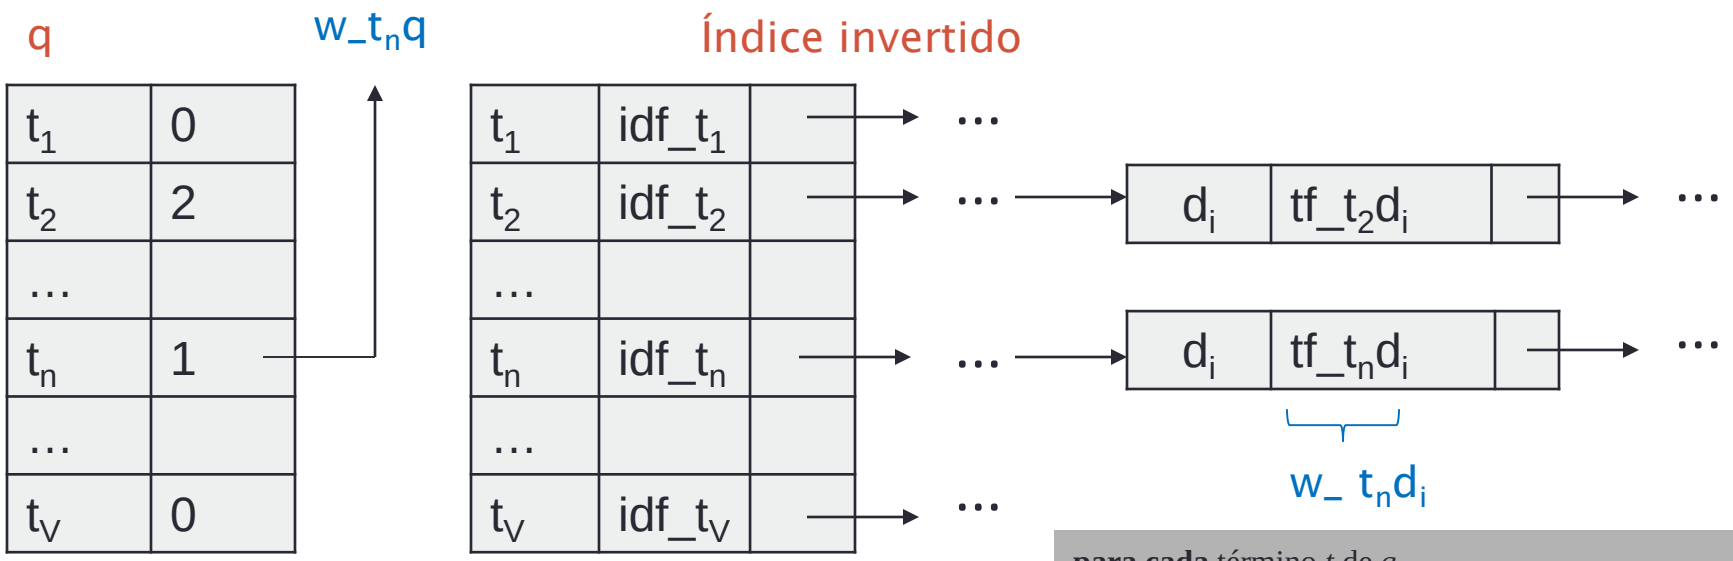


**para cada** término *t* de *q*
**hacer** calcular $w_{t,q}$ **and** recorrer postings list para *t*
**para cada** par(*d*, $tf_{t,d}$) in postings list
**hacer** Scores [*d*]+= $w_{t,d}$ x $w_{t,q}$
**para cada** *d*

# 2.4 Esquemas de pesado.

Esquemas de pesado se representan por *ddd.qqq*:

- *ddd* pesado del vector de documentos.
- *qqq* pesado del vector de consulta

(1ª letra: frecuencia término; 2ª letra: Frecuencia documento; 3ª Letra: Normalización)

| Term frequency | | Document frequency | | Normalization | |
|---|---|---|---|---|---|
| n (natural) | $\mathrm{tf}_{t,d}$ | n (no) | 1 | n (none) | 1 |
| l (logarithm) | $1 + \log(\mathrm{tf}_{t,d})$ | t (idf) | $\log \frac{N}{\mathrm{df}_t}$ | c (cosine) | $\frac{1}{\sqrt{w_1^2+w_2^2+\ldots+w_M^2}}$ |
| a (augmented) | $0.5 + \frac{0.5 \times \mathrm{tf}_{t,d}}{\max_t(\mathrm{tf}_{t,d})}$ | p (prob idf) | $\max\{0, \log \frac{N-\mathrm{df}_t}{\mathrm{df}_t}\}$ | u (pivoted unique) | $1/u$ |
| b (boolean) | $\begin{cases} 1 & \text{if } \mathrm{tf}_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$ | | | b (byte size) | $1/CharLength^{\alpha}$, $\alpha < 1$ |
| L (log ave) | $\frac{1+\log(\mathrm{tf}_{t,d})}{1+\log(\mathrm{ave}_{t \in d}(\mathrm{tf}_{t,d}))}$ | | | | |

*lnc.ltc*:

•el vector de documentos tiene una frecuencia de términos log-pesado, no idf y coseno normalizado
•el vector de consulta usa frecuencia de términos log-pesado, idf y coseno normalizado.

# Ejercicio#3. Calcular la puntuación del documento respecto a la consulta suponiendo una colección de 1.000.000 de documentos con un esquema de pesado **lnc.ltc**

*lnc.ltc*:

- el vector de documentos tiene una frecuencia de términos log-pesado, no idf y coseno normalizado
- el vector de consulta usa frecuencia de términos log-pesado, idf y coseno normalizado.

| Term | Consulta | | | | | | Documento | | | | Producto |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | $f_{t,q}$ | $tf_{t,q}$ | $df_t$ | $idf_t$ | $w_{t,d}$=tfxidf | L-Normaliz | $f_{t,d}$ | $tf_{t,d}$ | $w_{t,d}=tf_{t,d}$ | L-Normaliz | |
| auto | 0 | | 5000 | | | | 1 | | | | |
| mejor | 1 | | 50000 | | | | 0 | | | | |
| coche | 1 | | 10000 | | | | 1 | | | | |
| seguro | 1 | | 1000 | | | | 2 | | | | |

# Ejercicio#3_Solución. Calcular la puntuación del documento respecto a la consulta suponiendo una colección de 1.000.000 de documentos con un esquema de pesado **lnc.ltc**

| Term | Consulta | | | | | | Documento | | | | Producto |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | $f_{t,q}$ | $tf_{t,q}$ | $df_t$ | $idf_t$ | $w_{t,d}$=tfxidf | L-Normaliz | $f_{t,d}$ | $tf_{t,d}$ | $w_{t,d}=tf_{t,d}$ | L-Normaliz | |
| auto | 0 | 0 | 5000 | 2,3 | 0 | 0,00 | 1 | 1 | 1 | 0,52 | 0,00 |
| mejor | 1 | 1 | 50000 | 1,3 | 1,3 | 0,34 | 0 | 0 | 0 | 0,00 | 0,00 |
| coche | 1 | 1 | 10000 | 2 | 2 | 0,52 | 1 | 1 | 1 | 0,52 | 0,27 |
| seguro | 1 | 1 | 1000 | 3 | 3 | 0,78 | 2 | 1,3 | 1,3 | 0,68 | 0,53 |

Puntuación = Cos(q,d)=0+0+0.27+0.53 = 0.8

# Ejercicio#4. Similitud entre 4 documentos esquema pesado **lnc** (log-**n**oidf-**c**oseno)

**Similitud entre 4 documentos esquema pesado lnc**

Pesado Log

L-normalizacion

| term | SaS | PaP | WH | WH+WH | SaS | PaP | WH | WH+WH | SaS | PaP | WH | WH+WH |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| affection | 115 | 58 | 20 | 40 | 3,06 | 2,76 | 2,30 | 2,60 | 0,789 | 0,832 | 0,524 | 0,522 |
| jealous | 10 | 7 | 11 | 22 | 2,00 | 1,85 | 2,04 | 2,34 | 0,515 | 0,555 | 0,465 | 0,470 |
| gossip | 2 | 0 | 6 | 12 | 1,30 | 0,00 | 1,78 | 2,08 | 0,335 | 0,000 | 0,405 | 0,417 |
| wuthering | 0 | 0 | 38 | 76 | 0,00 | 0,00 | 2,58 | 2,88 | 0,000 | 0,000 | 0,588 | 0,578 |

**cos(SaS,PaP) ≈** 0,94

**cos(SaS,Wh) ≈** 0,79

**cos(SaS,Wh+Wh) ≈** 0,79

**cos(PaP,Wh) ≈** 0,69

**cos(PaP,Wh+Wh)≈** 0,69

**cos(Wh,Wh+Wh) ≈** 1,00

¿Qué podemos observar a la vista de los resultados?

# Resumen

- Representar la consulta como un vector tfxidf pesado
- Representar cada documento como un vector tfxidf pesado
- Calcular la puntuación similitud del coseno para el vector de la consulta y para el vector de cada documento
- Ordenar documentos respecto a la consulta por puntuación
- Devolver los *K* (p.e. K=10) primeros documentos al usuario.