

Examen de Aprendizaje Automático
ETSINF, Universitat Politècnica de València, 24 de enero de 2022

Apellidos:

Nombre:

Grupo:

Cuestiones (2 puntos; tiempo estimado: 30 minutos)

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma 1/2 puntos y cada fallo resta 1/6 puntos.

- 1 ☐ A Sea S un conjunto de 1000 datos supervisados o etiquetados. En el diseño de un sistema de reconocimiento de formas se utiliza el método de *validación cruzada en 10 bloques* y se obtienen los errores siguientes: (1,1,1,1,1,1,1,1,1,1). Indicar cual de las siguientes afirmaciones es incorrecta.

- A) El test efectivo es de 100 muestras
- B) El error estimado es $p_e = 1.0\%$
- C) El intervalo de confianza al 95 % es ± 0.6
- D) El tamaño de entrenamiento efectivo es de 900 muestras

- 2 ☐ C En el problema de optimización con restricciones

$$\begin{array}{ll} \text{minimizar} & q(\Theta), \quad \Theta \in \mathbb{R}^D \\ \text{sujeito a} & v_i(\Theta) \leq 0, \quad 1 \leq i \leq k \end{array}$$

se cumplen las condiciones complementarias de Karush-Kuhn-Tucker $\alpha_i^* v_i(\Theta^*) = 0$ para $1 \leq i \leq k$. Indicar cuál de las siguientes afirmaciones se deduce de ellas:

- A) Si para un i , $\alpha_i^* = 0$, entonces $v_i(\Theta^*) > 0$
- B) Si para un i , $\alpha_i^* = 0$, entonces $v_i(\Theta^*) = 0$,
- C) Si para un i , $\alpha_i^* > 0$, entonces $v_i(\Theta^*) = 0$
- D) Si para un i , $v_i(\Theta^*) = 0$, entonces $\alpha_i^* = 0$


- 3 ☐ B En el problema de aprendizaje de modelos probabilísticos con variables observables \mathbf{x}_n y latentes \mathbf{z}_n , la log-verosimilitud se expresa como:

$$L_S(\Theta) = \sum_{n=1}^N \log \left(\sum_{\mathbf{z}_n} P(\mathbf{x}_n, \mathbf{z}_n | \Theta) \right)$$

y se utiliza la técnica esperanza-maximización (EM). Indicar cuál de las siguientes afirmaciones es cierta:

- A) En cada iteración, el paso E consiste en obtener una estimación de todas las variables \mathbf{x}_n y \mathbf{z}_n , y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{x}_n y \mathbf{z}_n obtenidas en el paso E.
- B) En cada iteración, el paso E consiste en obtener una estimación de los valores de las variables latentes \mathbf{z}_n , y el paso M, obtener los parámetros óptimos de Θ utilizando los estimadores de \mathbf{z}_n obtenidas en el paso E.
- C) En cada iteración, el paso E consiste en obtener los valores de las variables latentes \mathbf{z}_n que maximizan la función objetivo $L_S(\Theta)$, y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{z}_n obtenidas en el paso E.
- D) En cada iteración, el paso E consiste en obtener los valores de todas las variables \mathbf{x}_n y \mathbf{z}_n que maximizan la función $L_S(\Theta)$, y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{x}_n y \mathbf{z}_n obtenidas en el paso E.

- 4 ☐ B En la red bayesiana



¿cuál de las relaciones siguientes es falsa en general?

- A) $P(a, b) = P(a) P(b)$
- B) $P(a, d) = P(a) P(d)$
- C) $P(d, c | a) = P(d | a) P(c | a)$
- D) $P(b, d) = P(b) P(d)$

Problema 1 (3 puntos; tiempo estimado: 30 minutos)

Se dispone de un conjunto de entrenamiento en \mathbb{R}^2 con el que se pretende entrenar un modelo basado en máquinas de vectores soporte. Los multiplicadores de Lagrange óptimos obtenidos para $C = 10$ son:

i	1	2	3	4	5	6	7	8
x_{i1}	3	2	4	2	2	4	1	4
x_{i2}	4	5	4	2	3	2	4	3
Clase	-1	-1	-1	+1	-1	+1	+1	-1
α_i^*	0	0	0	0	10	9.11	7.11	6.22

- Obtener la función discriminante lineal correspondiente
- Representar gráficamente la frontera lineal de separación entre clases y las muestras de entrenamiento, indicando cuáles son vectores soporte.
- Clasificar la muestra $(6, 5)^t$.

a) Pesos de la función discriminante:

$$\theta^* = c_5 \alpha_5^* \mathbf{x}_5 + c_6 \alpha_6^* \mathbf{x}_6 + c_7 \alpha_7^* \mathbf{x}_7 + c_8 \alpha_8^* \mathbf{x}_8$$

$$\theta_1^* = (-1)(2)(10) + (+1)(4)(9.11) + (+1)(1)(7.11) + (-1)(4)(6.22) = -1.33$$

$$\theta_2^* = (-1)(3)(10) + (+1)(2)(9.11) + (+1)(4)(7.11) + (-1)(3)(6.22) = -2.00$$

Usando el vector soporte \mathbf{x}_7 (que verifica la condición : $0 < \alpha_1^* < C$)

$$\theta_0^* = c_7 - \theta^{*t} \mathbf{x}_7 = 1 - ((-1.33)(1) - (2.00)(4)) = 10.33$$


Función discriminante: $\phi(\mathbf{x}) = 10.33 - 1.33x_1 - 2x_2$

b) Frontera de separación y representación gráfica:

Ecuación de la frontera lineal de separación: $10.33 - 1.33x_1 - 2.00x_2 = 0 \rightarrow x_2 = -0.665x_1 + 5.165$.

Los vectores de entrenamiento son todos los de la tabla. De ellos, los vectores soporte son: $(1, 4)^t, (2, 3)^t, (4, 2)^t, (4, 3)^t$.

Representación gráfica:




c) Clasificación de la muestra $(6, 5)^t$:

El valor de la función discriminante para $(6, 5)^t$ es: $\theta_0^* + 6\theta_1^* + 5\theta_2^* = 10.33 + 6(-1.33) + 5(-2.00) = -7.65 < 0 \Rightarrow$ clase -1.

Problema 2 (3 puntos; tiempo estimado: 30 minutos)

La red hacia adelante (“feedforward”) de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de oculta de tipo *sigmoid* y lineal en el nodo de la capa de salida, y factor de aprendizaje $\rho = 1.0$.



Dados unos pesos iniciales $\theta_1 = \theta_2 = \theta_3 = \theta_4 = \theta_5 = 1.0$, un vector de entrada $\mathbf{x}^t = (0, 1)$ y su valor deseado de salida $t = +1$, Calcular:

- las salidas de todas las unidades
- los correspondientes errores en el nodo de la capa de salida y en el de la capa oculta.
- Los nuevos valores de los pesos de las conexiones

Pista: La actualización de pesos en esta red sigue la misma formulación que en el BackProp para el perceptrón multicapa convencional: el incremento de peso es $\Delta\theta = \rho z \delta$, donde ρ es el factor de aprendizaje, z es la entrada del arco asociado al peso θ , y δ es el error que se observa en la salida de la unidad a la que llega ese arco, multiplicado por la derivada de la función de activación.

- Las salidas de todas las unidades

$$\phi_1^1 = \theta_1 + \theta_2 x_2 = 1.0 + 1.0 \cdot 1.0 = 2.0$$

$$s_1^1 = \frac{1}{1 + \exp(-\phi_1^1)} = 0.880797$$

$$\phi_1^2 = \theta_4 + \theta_3 x_1 + \theta_5 s_1^1 = 1.0 + 1.0 \cdot 0.0 + 1.0 \cdot 0.880797 = 1.880797 \quad s_1^2 = \phi_1^2 = 1.880797$$

- El error en la capa de salida es:

$$\delta_1^2 = (t_1 - s_1^2) = (1.0 - 1.880797) = -0.880797$$

El error en la capa de oculta es:

$$\delta_1^1 = (\delta_1^2 \theta_5) s_1^1 (1 - s_1^1) = ((-0.880797) \cdot 1.0) \cdot 0.880797 \cdot (1 - 0.880797) = -0.092478$$

- Los nuevos pesos son:

$$\theta_1 = \theta_1 + \rho \delta_1^1 (+1) = 1.0 + 1.0 (-0.092478) \cdot 1.0 = 0.90752$$

$$\theta_2 = \theta_2 + \rho \delta_1^1 x_2 = 1.0 + 1.0 (-0.092478) \cdot 1.0 = 0.90752$$

$$\theta_3 = \theta_3 + \rho \delta_1^2 x_1 = 1.0 + 1.0 (-0.880797) \cdot 0.0 = 1.0$$

$$\theta_4 = \theta_4 + \rho \delta_1^2 (+1) = 1.0 + 1.0 (-0.880797) \cdot 1.0 = 0.119203$$

$$\theta_5 = \theta_5 + \rho \delta_1^2 s_1^1 = 1.0 + 1.0 (-0.880797) \cdot 0.880797 = 0.224196$$

Problema 3 (2 puntos; tiempo estimado: 20 minutos)


Considerar la red bayesiana \mathcal{R} definida como $P(X, Y, Z, V, W) = P(X) P(Y | X) P(Z | X) P(V | Y) P(W | Z)$, cuyas variables aleatorias, W , X , Y , Z y V toman valores en el conjunto $\{a, b\}$. Las distribuciones de probabilidad asociadas son como sigue:

- $P(X)$ es uniforme: $P(X = a) = P(X = b)$,
- $P(Y | X)$, $P(Z | X)$, $P(V | Y)$ y $P(W | Z)$ son idénticas a la siguiente tabla $P(A | B)$:

$P(A B)$		$A : a$	b
$B :$	a	1/3	2/3
	b	1/4	3/4

- Representar gráficamente la red.
- Obtener una expresión simplificada de $P(W, Y, Z, V | X)$ en función de las distribuciones que definen \mathcal{R} y calcular $P(W = b, Y = b, Z = b, V = b | X = a)$
- Calcular $P(V = b | X = a)$,

- Representación gráfica de la red:



- Expresión simplificada de $P(W, Y, Z, V | X)$:

$$\begin{aligned}
 P(W, Y, Z, V | X) &= \frac{P(W, X, Y, Z, V)}{P(X)} = \frac{\cancel{P(X)} P(Y | X) P(Z | X) P(W | Z) P(V | Y)}{\cancel{P(X)}} \\
 &= P(Y | X) P(Z | X) P(W | Z) P(V | Y)
 \end{aligned}$$

$$P(W = b, Y = b, Z = b, V = b | X = a) = \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{3}{4} \cdot \frac{3}{4} = \frac{36}{144} = 0.25$$

- Calcular $P(V = b | X = a)$:

$$\begin{aligned}
 P(V | X) &= \frac{P(V, X)}{P(X)} = \sum_{y, z, w \in \{a, b\}} P(Y = y | X) P(Z = z | X) P(W = w | Z = z) P(V | Y = y) \\
 P(V = b | X = a) &= \sum_{y, z, w \in \{a, b\}} P(Y = y | X = a) P(Z = z | X = a) P(W = w | Z = z) P(V = b | Y = y) \\
 &= \sum_{y, z \in \{a, b\}} P(Y = y | X = a) P(Z = z | X = a) P(V = b | Y = y) \\
 &= \sum_{y \in \{a, b\}} P(Y = y | X = a) P(V = b | Y = y) \\
 &= P(Y = a | X = a) P(V = b | Y = a) + P(Y = b | X = a) P(V = b | Y = b) \\
 &= \frac{1}{3} \cdot \frac{2}{3} + \frac{2}{3} \cdot \frac{3}{4} = 0.8333
 \end{aligned}$$